

Plagiarism Detector v. 2942 - Originality Report 6/10/2026 2:09:13 PM

Analyzed document: BAB 2.pdf Licensed to: STIE MDP_License10


Comparison Preset: Rewrite Detected language: Id

Check type: Internet Check

TEE and encoding: PdfPig

Detailed document body analysis:

Relation chart:



Distribution graph:



Top sources of plagiarism: 10

	2%		52	1. https://web-crawler.plagiarism-detector.com/get-doc-pt?did=8UekPo24-zpFnQ
	2%		27	2. https://web-crawler.plagiarism-detector.com/get-doc-pt?did=80eiM4W_9jNjkw
	1%		23	3. https://web-crawler.plagiarism-detector.com/get-doc-pt?did=80ilPoa-9jRHnQ

Processed resources details: 82 - Ok / 8 - Failed

Important notes:

Wikipedia:	Google Books:	Ghostwriting services:	Anti-cheating:
[not detected]	[not detected]	[not detected]	[not detected]

UACE: UniCode Anti-Cheat Engine report:

1. Status: Analyzer On Normalizer On character similarity set to 100%
2. Detected UniCode contamination percent: 0% with limit of: 30%
3. Document not normalized: percent not reached 5%
4. All suspicious symbols will be marked in purple color: Abcd...
5. Invisible symbols found: 0
Assessment recommendation: No special action is required. Document is Ok.
Alphabet stats and symbol analyzes: UACE does not support the doc language! UACE logics skipped!

Active References (Urls Extracted from the Document):

No URLs detected

?

Excluded Urls:

No URLs detected

?

Included Urls:

No URLs detected

 Detailed document analysis:

BAB II PEMILIHAN SOLUSI 2.1 Alternatif Solusi 2.1.1 K-Nearest Neighbors Solusi pertama adalah menggunakan K-Nearest Neighbors (KNN) sebagai metode supervised learning yang sederhana dalam machine learning. Metode ini bekerja dengan

 **Plagiarism detected: 0.4%** <https://journal.mahesacenter.org/index.php/inco...> id: 1

mengklasifikasikan data baru berdasarkan kesamaan dengan data yang telah dilatih sebelumnya, di mana kesamaan tersebut dihitung dari jarak antara data menggunakan nilai k sebagai jumlah tetangga terdekat (Kaur, 2024). Dalam menentukan kesamaan berdasarkan jumlah tetangga terdekat, KNN mengukur jarak antara data latih dan uji menggunakan jenis perhitungan jarak (Tace, 2022). Salah satu metrik jarak yang digunakan adalah persamaan manhattan yang didefinisikan persamaan (2.1).
$$d(x, y) = \sum_{i=1}^n |x_i - y_i|$$
 (2.1) $d(x, y) = 1$ di mana $d(x, y)$ adalah jarak antara vektor x (data pelatihan) dan y (data pengujian), n adalah jumlah atribut, dan i adalah indeks atribut. Kelebihan KNN terletak pada kesederhanaan dalam menentukan parameter jumlah tetangga terdekat (k) dan metode pengukuran jarak. Metode ini mampu mengelola sampel data yang besar, meski dapat berdampak pada waktu pemrosesan (Abaye, 2020). Namun, pemilihan nilai k harus dipertimbangkan dengan teliti. Nilai k yang kecil sangat rentan terhadap noise dan menyebabkan overfitting. 16 17 Sementara nilai k yang besar dapat mengurangi pengaruh dari noise, meskipun meningkatkan kompleksitas komputasi (Cholil, 2021). Kelemahan utama dari KNN ketergantungannya pada kualitas dan ukuran dataset. Metode ini sangat sensitif outlier dan data yang hilang (missing), serta kurang cocok untuk data yang berdimensi tinggi (Rahmadini, 2023). KNN memerlukan komputasi yang intensif dan waktu pemrosesan akan meningkat seiring dengan pertambahan ukuran dataset (Abaye, 2020). Gambar 2.1 K-Nearest Neighbors Gambar 2.1 menunjukkan metode K-Nearest Neighbors (KNN) terdiri dari beberapa tahapan dalam proses klasifikasi, yaitu: 1. Memilih parameter jumlah tetangga terdekat (k). 2. Menghitung jarak setiap data uji dengan data latih menggunakan persamaan manhattan distance. 3. Mengurutkan hasil perhitungan jarak manhattan dimulai dari yang terkecil hingga yang terbesar. 4. Mengklasifikasikan data uji berdasarkan kelas mayoritas yang paling sering muncul dari (k) tetangga terdekat. 18 Pada solusi pertama, perancangan sistem irigasi cerdas menggunakan K-Nearest Neighbors (KNN), parameter yang digunakan adalah $k = 5$ dan jenis jarak yang digunakan adalah manhattan. Dataset ini dibagi menjadi 80% data latih dan 20% data uji, menghasilkan akurasi sebesar 99,8% (Kaur, 2024). 2.1.2 Support Vector Machine Solusi kedua adalah menggunakan

 **Plagiarism detected: 1.79%** <https://web-crawler.plagiarism-detector.com/ge...> + 2 id: 2

Support Vector Machine (SVM) sebagai metode supervised learning dalam machine learning, yang mampu menyelesaikan masalah klasifikasi dan regresi. SVM bekerja dengan mencari hyperplane terbaik yang memisahkan dua kelas dengan memaksimalkan margin. Metode ini mampu memisahkan data secara linier maupun non-linier.

SVM memiliki kelebihan dalam menghasilkan generalisasi yang tinggi, tahan terhadap noise dan outlier, serta mampu mengelola data yang tidak seimbang. Tidak hanya itu, SVM dapat menangani data berdimensi tinggi dengan jumlah sampel terbatas (Abaye, 2020). Kelemahan dari SVM adalah tidak cocok untuk himpunan data dengan jumlah sampel dan dimensi yang besar. Kinerja SVM dipengaruhi dalam pemilihan kernel dan nilai regulasi C , sehingga akurasi, kebutuhan komputasi dan waktu pemrosesan bervariasi (Abaye, 2020). 19 Gambar 2.2 Support Vector Machine Gambar 2.2 menunjukkan proses kerja dalam menentukan hyperplane dan memaksimalkan margin. SVM terdiri dari tiga komponen utama, yaitu hyperplane sebagai bidang pemisah terbaik antara dua kelas, margin yang merupakan jarak hyperplane dan jarak

 **Plagiarism detected: 0.58%** <https://web-crawler.plagiarism-detector.com/ge...> + 2 id: 3

terdekat dari masing-masing kelas, serta support vector yang merupakan data yang paling dekat

dengan hyperplane (Junus, 2023). Proses pelatihan SVM dimulai dengan himpunan data pelatihan $\{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$, di mana $x_i \in \mathbb{R}^d$ mewakili vektor fitur, dan $y_i \in \{-1, 1\}$ menunjukkan label kelas. Kedua kelas dapat memisahkan dengan sempurna oleh hyperplane, yang didefinisikan dengan persamaan (2.2).
$$w \cdot x + b = 0$$
 (2.2) di mana w adalah vektor bobot yang terkait dengan masing-masing fitur data, x adalah vektor fitur data, dan b adalah nilai bias. Tujuan dari SVM adalah menemukan hyperplane yang memaksimalkan

margin, yaitu jarak antara dua kelas terhadap hyperplane. Margin tersebut dihitung $2 \| \mathbf{w} \|$ sebagai , di mana $\mathbf{w}$ merupakan norma dari vektor bobot $\mathbf{w}$. $\| \mathbf{w} \|$ 20 Untuk menemukan hyperplane terbaik, dilakukan proses optimasi melalui Quadratic Programming dengan meminimalkan fungsi pada persamaan (

 **Plagiarism detected: 1.16%** <https://web-crawler.plagiarism-detector.com/ge...> id: 4

2.3). $\min_w \frac{1}{2} \mathbf{w}^T \mathbf{w}$ dengan syarat: $(\mathbf{w} \cdot \mathbf{x}_i + b) \geq 1, i = 1, 2, 3,$

... (2.5) Optimisasi dapat diselesaikan dengan menerapkan metode lagrange multiplier yang ditunjukkan pada persamaan (2.6). $\frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum (\lambda_i (\mathbf{w} \cdot \mathbf{x}_i + b - 1))$ (2.6) $\lambda_i \geq 0$ adalah nilai lagrange multiplier. Untuk memperoleh nilai optimal dari $\mathbf{w}$ dan b , dilakukan penurunan fungsi terhadap $\mathbf{w}$ dan b , kemudian diubah menjadi nilai nol, sehingga menghasilkan syarat optimal yang ditunjukkan pada persamaan (2.7) dan persamaan (2.8). $\frac{\partial}{\partial \mathbf{w}} \sum = 0 \rightarrow \mathbf{w} = -\sum \lambda_i \mathbf{x}_i$ (2.7) $\frac{\partial}{\partial b} \sum = 0 \rightarrow \sum \lambda_i = 0$ (2.8) $\lambda_i \geq 0$ Persamaan lagrange multiplier diubah dengan substitusi turunan dari persamaan (2.7) dan persamaan (2.8), sehingga membentuk dualitas lagrange. Kemudian memaksimalkan dengan persamaan (2.9). $\max_{\lambda} \sum \lambda_i (\mathbf{x}_i \cdot \mathbf{x}_i) - \frac{1}{2} (\sum \lambda_i \mathbf{x}_i)^T (\sum \lambda_i \mathbf{x}_i)$ (2.9) $\lambda_i \geq 0$ Hasil dari persamaan (2.9) adalah 0, yang disebut sebagai support vectors untuk menentukan posisi hyperplane. Untuk memprediksi kelas dari data baru yang dimasukkan, dengan menggunakan persamaan (2.10). $\mathbf{w}^T \mathbf{x} + b \geq 1$ (2.10) $\mathbf{x}$ adalah support vector, dan $\mathbf{w}$ sebagai vektor data baru yang akan diprediksi. Untuk kasus kedua kelas yang tidak dapat dipisahkan secara sempurna, SVM menawarkan kernel trick untuk memisahkan data non-linier dengan mentransformasikan data ke ruang fitur berdimensi lebih tinggi (Kaur, 2024). Namun, dalam penelitian tersebut, menerapkan kernel linear yang pengukuran produk titik dari vektor data diruang aslinya, tanpa melakukan transformasi (Rabbani, 2023). Umumnya kernel linear mampu tahan overfitting dan proses pelatihan lebih cepat dibandingkan kernel non linear (Abaye, 2020). Persamaan kernel linear dapat didefinisikan pada persamaan (2.11). $\mathbf{x} \cdot \mathbf{y} = \mathbf{x} \cdot \mathbf{y}$ (2.11) Selain menerapkan kernel trick, SVM juga mampu menyelesaikan kasus tersebut dengan menerapkan soft margin dengan menambahkan variabel slack $\xi \geq 0$ yang berfungsi sebagai pengukur kesalahan dalam klasifikasi. Variabel ini dimasukkan ke dalam bentuk Quadratic Programming pada persamaan (2.12). $\min_w \frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum \lambda_i (\mathbf{w} \cdot \mathbf{x}_i + b - 1 + \xi_i)$ (2.12) $\lambda_i \geq 0, \xi_i \geq 0$ (2.13) Masalah optimasi dengan lagrange multiplier pada persamaan (2.6) dimodifikasi menjadi persamaan berikut: $\frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum (\lambda_i (\mathbf{w} \cdot \mathbf{x}_i + b - 1 + \xi_i))$ (2.14) $\lambda_i \geq 0, \xi_i \geq 0$ Persamaan dari maksimum dualitas lagrange multiplier dilakukan dengan memodifikasi menjadi persamaan (2.15). $\max_{\lambda, \xi} \sum \lambda_i (\mathbf{x}_i \cdot \mathbf{x}_i) - \frac{1}{2} (\sum \lambda_i \mathbf{x}_i)^T (\sum \lambda_i \mathbf{x}_i) - \sum \lambda_i \xi_i$ (2.15) $\lambda_i \geq 0, \xi_i \geq 0$ Parameter ξ yang digunakan untuk mengatur kesalahan klasifikasi yang diperbolehkan pada data latih. Nilai yang besar akan memperketat dan mengurangi toleransi kesalahan dengan memperkecil margin, namun berisiko overfitting. Sebaliknya, nilai yang kecil akan memberikan toleransi kesalahan dengan melebarkan margin, namun berisiko underfitting (Aryawan, 2023). Pada solusi kedua, perancangan sistem irigasi menggunakan Support Vector Machine (SVM), kernel yang digunakan adalah linear. Dataset ini dibagi menjadi 80% data latih dan 20% data uji, menghasilkan akurasi sebesar 99,3% (Kaur, 2024). 2.1.3 Random Forest Solusi ketiga menggunakan Random Forest (RF) adalah metode ensemble learning yang populer untuk klasifikasi maupun regresi. Metode ini bekerja dengan menggabungkan sejumlah Decision Tree yang terpisah, di mana setiap pohon menggunakan subset data yang dipilih secara acak melalui teknik bagging dan random feature selection (Abaye, 2020). Random Forest dikembangkan dari Classification dan Regression Tree (CART), yang merupakan teknik klasifikasi yang menganalisis data menggunakan Decision Tree (Lestari, 2024). 23 Setiap Decision Tree terdiri dari beberapa jenis simpul, yaitu simpul akar yang terletak di puncak dalam pohon. Simpul internal sebagai simpul percabangan yang memiliki satu input dan dua output, dan simpul daun. Simpul terakhir yang dikenal sebagai simpul daun yang hanya memiliki satu masukan tanpa menghasilkan keluaran tambahan (Rakhmat, 2023). Random Forest memiliki kemampuan generalisasi yang tinggi dengan membangun pohon yang beragam, sehingga mengurangi overfitting. Metode ini mampu memproses data dengan jumlah sampel dan dimensi yang besar, serta fitur kategoris. Keunggulan metode ini tahan terhadap data dengan outlier, noise, dan ketidakseimbangan (Abaye, 2020). Tidak hanya itu, Random Forest mampu menangani missing data (Zhu, 2020). Kelemahan dari Random Forest terletak pada kebutuhan

komputasi dan waktu pemrosesan yang dapat meningkat seiring bertambahnya jumlah dan kedalaman pohon, terutama dataset yang besar. Metode ini juga memerlukan spesifikasi prosesor tinggi untuk pemrosesan paralel. Oleh karena itu, pengaturan hyperparameter untuk membatasi jumlah dan kedalaman maksimum pohon yang dibangun sangat penting untuk mengurangi kebutuhan komputasi (Zhu, 2020). Gambar 2.3 Random Forest 24 Berdasarkan Gambar 2.3, Random Forest membangun sejumlah Decision Tree yang secara terpisah melalui teknik bagging (bootstrap aggregating), di mana sampel acak dari data pelatihan yang dipilih dengan penggantian (replacement). Setiap pohon dibangun tanpa pemangkasan dan menggunakan random feature selection. Proses ini diulangi hingga jumlah pohon yang ditentukan (Lestari, 2024). Random feature selection dilakukan untuk memilih sejumlah fitur secara acak yang digunakan pada setiap simpul saat membangun pohon. Dalam pengaturan ini, nilai yang lebih rendah dapat meningkatkan variasi dan mengurangi korelasi antar pohon, yang dapat memperkuat stabilitas saat penggabungan pohon (Yulianto, 2024). Untuk klasifikasi, nilai ini sering diatur dengan $\sqrt{p}$, di mana p adalah jumlah $\sqrt{p}$ fitur dalam dataset (Junus, 2023). Proses pembentukan Decision Tree dalam Random Forest dimulai dengan menentukan simpul akar. Selanjutnya, dilakukan pemisahan pada simpul untuk menentukan simpul terminal dan simpul daun berdasarkan kriteria terbaik dengan menghitung menggunakan Gini Index (Yulianti, 2023). Perhitungan Gini Index dan Gini Split dilakukan menggunakan persamaan (2.16) dan persamaan (2.17). $2 \sum_{i=1}^K p_i (1 - p_i) = 1 - \sum_{i=1}^K p_i^2$ (2.16) $p_i = 1$ di mana p_i adalah probabilitas dari kelas ke- i dalam simpul i , dan p_i adalah jumlah p_i total kelas. $1 - \sum_{i=1}^K p_i^2 = 1 - \sum_{i=1}^K \left(\frac{n_i}{n} \right)^2$ (2.17) $1 - \sum_{i=1}^K \left(\frac{n_i}{n} \right)^2$ di mana n_i dan n adalah jumlah sampel dalam subset setelah pemisahan, n_i dan $1 - n_i$ adalah simpul hasil pemisahan, serta n adalah jumlah total sampel pada simpul. 2.25 Pada solusi ketiga, perancangan sistem irigasi menggunakan Random Forest (RF), dengan membangun jumlah 100 pohon dan kriteria Gini Index. Dataset tersebut akan dibagi menjadi 80% untuk data latih dan 20% untuk data uji. Random Forest menghasilkan akurasi sebesar 99,98%, precision 99,96%, recall 99,99%, dan f1-score 99,97% (IORLIAM, 2022).

2.2 Analisis Pemilihan Solusi

Tabel 2.2 Analisis Pemilihan Solusi

Karakteristik Pendekatan Berdasarkan Solusi

Solusi Aspek Analisis Terpilih Pendekatan-1 Aspek Ekonomis Preprocessing:

Selama proses pelatihan KNN, kebutuhan komputasi - train_test_split (80 : bisa meningkat seiring bertambahnya ukuran dataset 20) (Abaye, 2020). - StandarScaler Aspek Manufakturabilitas - Waktu pemrosesan untuk melatih KNN menjadi Classifier: lama seiring bertambahnya ukuran dataset (Abaye, K-Nearest Neighbors 2020). Aspek Sustainabilitas ($p = 5$, metric: manhattan) Kemampuan pada KNN menghasilkan akurasi mencapai 99,3% (Kaur, 2024).

Pendekatan-2 Aspek Ekonomis Preprocessing:

Pemilihan kernel dan ukuran dataset seperti jumlah - train_test_split (80 : sampel yang besar dapat meningkatkan kebutuhan 20) komputasi selama proses pelatihan (Abaye, 2020). - StandarScaler Namun, SVM ramah dalam pengguna memori 26 Karakteristik Pendekatan Berdasarkan Solusi

Solusi Aspek Analisis Terpilih dengan hanya membangun batas keputusan Classifier: menggunakan subset data pelatihan yang disebut Support Vector Machine support vector (Palaniappan, 2024). (kernel: linear) Aspek Manufakturabilitas

Pemilihan kernel dan parameter C sangat memengaruhi proses pelatihan SVM. Umumnya, kernel linear jauh lebih cepat dibandingkan non- linear. Sementara itu, ukuran dataset yang sangat besar membuat proses pelatihan menjadi sangat lambat (Abaye, 2020). Aspek Sustainabilitas Kemampuan pada SVM menghasilkan akurasi sebesar 99,3% (Kaur, 2024).

Pendekatan-3 Aspek Ekonomis Preprocessing:

Selama melatih RF membutuhkan komputasi yang train_test_split (80 : 20) tinggi maupun rendah tergantung ukuran dataset, serta jumlah pohon dan kedalaman pohon yang Classifier: dibangun. Namun kebutuhan komputasi tersebut $\checkmark$ Random Forest dapat diminimalkan dengan membatasi kedalaman (n_estimators: 100 , pohon yang dibangun (Zhu, 2020). Kedalaman criterion:

Quotes detected: 0.04%

id: 5

'gini',

pohon terendah yang mampu menghasilkan kinerja max_features: 'sqrt', klasifikasi yang baik dan tetap konsisten akan dipilih bootstrap: True) untuk meminimalkan kebutuhan komputasi. Aspek Manufakturabilitas 27 Karakteristik Pendekatan Berdasarkan Solusi

Solusi Aspek Analisis Terpilih

Selain ukuran dataset, hyperparameter seperti jumlah pohon dan kedalaman pohon dapat memengaruhi waktu pelatihan. Untuk mempercepat proses tersebut dapat dilakukan dengan menerapkan pemrosesan paralel dan mengatur hyperparameter dengan membatasi kedalaman pohon, selain jumlah pohon yang dibangun (Zhu, 2020). Aspek Sustainabilitas Kemampuan pada RF menghasilkan akurasi mencapai 99,98% (IORLIAM, 2022).

Disclaimer:

This report must be correctly interpreted and analyzed by a qualified person who bears the evaluation responsibility!

Any information provided in this report is not final and is a subject for manual review and analysis. Please follow the guidelines:
Assessment recommendations

Plagiarism Detector - Your right to know the authenticity! ☐ SkyLine LLC