

Plagiarism Detector v. 2942 - Originality Report 6/10/2026 2:11:53 PM

Analyzed document: BAB 3.pdf Licensed to: STIE MDP_License10


Comparison Preset: Rewrite Detected language: Id

Check type: Internet Check

TEE and encoding: PdfPig

Detailed document body analysis:

Relation chart:



Distribution graph:



Top sources of plagiarism: 3

	5%		96	1. https://web-crawler.plagiarism-detector.com/get-doc-pt?did=8UihOYK_9DJAmg
	2%		43	2. https://esairina.medium.com/memahami-confusion-matrix-accuracy-precision-recall-spe...
	0.3%		13	3. https://web-crawler.plagiarism-detector.com/get-doc-pt?did=9EekPoy58zZHng

Processed resources details: 109 - Ok / 12 - Failed

Important notes:

Wikipedia:	Google Books:	Ghostwriting services:	Anti-cheating:
			
[not detected]	[not detected]	[not detected]	[not detected]

UACE: UniCode Anti-Cheat Engine report:

1. Status: Analyzer On Normalizer On character similarity set to 100%
2. Detected UniCode contamination percent: 0% with limit of: 30%
3. Document not normalized: percent not reached 5%
4. All suspicious symbols will be marked in purple color: <u>Abcd...</u>
5. Invisible symbols found: 0
Assessment recommendation: No special action is required. Document is Ok.
Alphabet stats and symbol analyzes: UACE does not support the doc language! UACE logics skipped!
Active References (Urls Extracted from the Document):

No URLs detected

?

Excluded Urls:

No URLs detected

?

Included Urls:

No URLs detected

? Detailed document analysis:

BAB III METODOLOGI Pada bagian ini, metodologi penelitian memiliki peran penting dalam memulai suatu penelitian dan pengembangan produk. Metodologi ini memberikan kerangka sistematis yang mencakup setiap tahapan yang harus dilalui, sehingga mendapatkan solusi dan tujuan yang diharapkan. Gambar 3.1 mengilustrasikan proses penelitian dan pengembangan produk yang dilakukan. Gambar 3.1 Alur Metodologi Penelitian

3.1 Identifikasi Masalah Identifikasi masalah adalah memainkan peran yang krusial sebelum merancang sebuah sistem. Tahapan ini dilakukan dengan mengeksplorasi berbagai masalah dari sumber seperti jurnal penelitian dan berita. Di samping itu, masalah juga didapatkan dari pengalaman pribadi dalam menghadapi tantangan dalam 28 29 menyiram tanaman. Untuk menemukan dan memverifikasi masalah tersebut dilakukan wawancara dengan berbagai narasumber yang ahli dalam pertanian. Dari hasil masalah yang didapatkan, petani mengalami kesulitan dalam menyiram tanaman karena metode pengelolaan tanaman masih dilakukan secara tradisional dan memiliki berbagai keterbatasan waktu, tenaga, dan sumber daya manusia. Metode ini menjadi masalah serius yang menyebabkan kegagalan panen dan mengurangi produktivitas pertanian, sehingga petani mengalami kerugian dan dapat mengancam keberlangsungan usaha.

3.2 Analisis Solusi Analisis solusi pada Bab 2 yang akan dievaluasi lebih lanjut dengan membandingkan akurasi, ketangguhan terhadap kualitas data yang beragam, biaya implementasi terkait kebutuhan komputasi. Hal ini dilakukan untuk menentukan metode mana yang terbaik, berdasarkan kemampuan mempelajari pola, memprediksi hasil yang akurat. Kebutuhan komputasi juga dilihat, namun bersifat opsional dan harus melihat spesifikasi mikrokontroler terlebih dahulu. Hasil akhir yang ditentukan Random Forest dipilih karena menghasilkan akurasi terbaik sebesar 99,98% (IORLIAM, 2022). Sedangkan K-Nearest Neighbors dan Support Vector Machine menghasilkan akurasi sebesar 99,3% (Kaur, 2024). Hal ini membuktikan metode ini lebih unggul pada kemampuan generalisasi dan melakukan prediksi waktu dan kebutuhan air pada tanaman untuk menyiram tanaman secara otomatis.

3.3 Pengumpulan Data Pengumpulan data memiliki peran penting dalam membangun machine learning untuk mempelajari pola data sebelum melakukan prediksi dan pengambilan keputusan. Dataset ini diambil dari penelitian yang dilakukan (Kaur, 2024) yang tersedia di Mendeley Data dan dapat diakses <https://data.mendeley.com/datasets/fpdwmm7nrb/1>. Dataset ini berisi 3000 sampel yang berisi kelembaban tanah, temperatur, dan kelembaban udara digunakan sebagai fitur data. Sedangkan target klasifikasi yaitu kondisi pompa, yaitu 0 dan 1. Tabel 3.1 menjelaskan karakteristik dan atribut pada data irigasi tanaman. Tabel 3.3 Penjelasan Atribut pada Data Irigasi

Atribut	Tipe Data	Range Nilai
Soil Moisture	float64	314,511 – 984,828
Temperature	float64	28,443 – 38,992
Air Humidity	float64	59,367 – 81,267
Pump	int64	0 dan 1

3.4 Pengembangan Model

3.4.1 Preprocessing Data Preprocessing data adalah langkah penting dalam mengelola data sebelum melatih metode machine learning. Tahapan ini dimulai dengan mencari missing data. Ada tiga jenis missing data, yaitu hilang sepenuhnya secara acak (missing completely at random), hilang secara acak (missing at random), dan hilang tidak secara acak (missing not at random). Gambar 3.2 menunjukkan analisis jumlah sampel data yang terindikasi missing data pada setiap fitur. Gambar 3.2 Jumlah Missing Value Pada Fitur Data Hasil analisis tersebut menunjukkan, fitur kelembaban tanah, suhu udara, dan kelembaban udara memiliki sampel data yang hilang, sehingga tidak diperlukan proses penanganan terhadap missing data. Selanjutnya, memilih fitur (X), yaitu kelembaban tanah, suhu udara, dan kelembaban udara, sedangkan target (y) adalah status pompa. Data kemudian dibagi menjadi 80% untuk training dan 20% untuk testing data. Gambar 3.3 menunjukkan training data memiliki 2400 sampel dengan 3 fitur, sedangkan testing data memiliki 600 sampel. Gambar 3.3 Hasil Pembagian Data Training dan Testing Data training digunakan untuk melatih model machine learning. Untuk data training dilakukan pengecekan outlier menggunakan matplotlib dan ketidakseimbangan data dapat dilihat melalui distribusi plot.

3.2 Gambar 3.4 Identifikasi Outlier Menggunakan Boxplot Gambar 3.4, hasil identifikasi menunjukkan setiap fitur tidak terindikasi outlier karena masih didalam batas whisker. Selain itu, distribusi data masih normal, dengan median yang relatif seimbang didalam rentang interquartile (IOR). Oleh karena itu, penerapan preprocessing tambahan tidak diperlukan. Gambar 3.5 Analisis Keseimbangan Data Menggunakan Plot Gambar 3.5 menunjukkan kelas target memiliki perbedaan sedikit, hal ini dibuktikan distribusi kelas target 0 mempunyai jumlah 1133 dengan persentase 52,79%, dan 1 mempunyai jumlah 47.21% artinya hanya 5.58%. sehingga tidak 33 diperlukan penanganan imbalance. Tabel 3.5 menyajikan distribusi kelas target berdasarkan

jumlah dan persentase. Tabel 3.5 Distribusi Kelas Target Target Jumlah Persentase 0 (ON) 1133 52.79% 1 (OFF) 1267 47.21% Dalam evaluasi kemampuan model dalam memprediksi status pompa dilakukan berdasarkan kondisi yang sudah dikategorikan dari data sensor. Sensor tersebut menghasilkan nilai dalam bentuk sinyal analog yang kemudian diubah menjadi sinyal digital menggunakan ADC (Analog to Digital Converter), sehingga data dari sensor dapat dibaca oleh sistem. Tabel 3.4 menyajikan nilai sensor dan kondisi kelembaban, yang dijelaskan oleh (Rosyid, 2022). Tabel 3.6 Kategori pada Kelembaban Tanah Nilai ADC Kondisi 289 - 397 Sangat Basah 398 - 507 Basah 508 - 617 Normal 618 - 726 Kering ≥ 727 Sangat Kering Tabel 3.5 menyajikan nilai sensor dan kondisi suhu udara, yang dijelaskan oleh (Pradana, 2023). 34 Tabel 3.7 Kategori pada Suhu Udara Nilai ADC Kondisi $\leq 23^{\circ}\text{C}$ Dingin $24^{\circ}\text{C} - 30^{\circ}\text{C}$ Normal $\geq 31^{\circ}\text{C}$ Panas Tabel 3.6 menyajikan nilai sensor dan kondisi kelembaban udara, yang dijelaskan oleh (Kusnadi, 2023). Tabel 3.8 Kategori pada Kelembaban Udara Nilai ADC Kondisi $\leq 55\%$ Kering $\geq 56\%$ Lembab Terakhir, untuk kelas klasifikasi disesuaikan dengan kategori kelembaban tanah, suhu udara, dan kelembaban udara yang dijelaskan dalam tabel. Namun kelembaban tanah adalah unsur yang memengaruhi terhadap pertumbuhan tanaman. Oleh karena itu, status kelas 1 sebagai OFF dan 0 sebagai ON. Gambar 3.6 menunjukkan hasil pengelompokan data irigasi ke dalam kategori yang telah dijelaskan sebelumnya. 35 Gambar 3.6 Hasil Pengelompokan Data Irigasi 3.4.2 Rancangan Random Forest Perancangan Random Forest menggunakan bahasa pemrograman Python dan library sklearn untuk memudahkan dalam pengembangan model. Implementasi RandomForestClassifier dengan hyperparameter tuning seperti $n_estimators = 100$, $criterion =$

Quotes detected: 0.06%

id: 1

'gini',

$max_features =$

Quotes detected: 0.06%

id: 2

'sqrt',

dan $bootstrap = \text{True}$. Secara umum, Random Forest membangun Decision Tree tanpa pemangkasan atau dibatasi. Namun, peningkatan pohon dapat meningkatkan kebutuhan komputasi. Untuk menghemat kebutuhan komputasi dapat dilakukan dengan hyperparameter tuning seperti max_depth (Akbar, 2023). Dalam proyek ini, hyperparameter max_depth ditentukan dalam rentang nilai 3 hingga 7. 36 Berdasarkan

Plagiarism detected: 2.86% <https://web-crawler.plagiarism-detector.com/ge...>

id: 3

penelitian yang dilakukan oleh (Oktafiani, 2024), Random Forest dengan $max_depth = 3$ mencapai akurasi 86,34%, $max_depth = 4$ mencapai akurasi 86,34%, nilai 5 mencapai akurasi 91,70%, $max_depth = 6$ mencapai akurasi 97,07%, dan $max_depth = 7$ mencapai akurasi 98,53%. Penelitian yang dilakukan oleh

(Baig, 2022) menunjukkan hyperparameter diatur dengan $max_depth = 3$ menghasilkan akurasi 97,96%, presisi 98,18%, recall 86,66%, AUC 0,932, dan waktu pelatihan 0,22 detik. $Max_depth = 4$ yang diatur menghasilkan akurasi 97,82%, presisi 99,79%, recall 84,21%, AUC 0,971, dan waktu pelatihan 0,259 detik. $Max_depth = 5$ yang diatur menghasilkan akurasi 99,14%, presisi 99,30%, recall 94,36%, AUC 0,971, dan waktu pelatihan 0,38 detik. $Max_depth = 6$ yang diatur menghasilkan akurasi 99,47%, presisi 99,60%, recall 96,53%, AUC 0,982, dan waktu pelatihan 0,44 detik. 3.5 Pengujian Pengujian dilakukan untuk memvalidasi kemampuan metode ini dalam menganalisis pola dan melakukan prediksi yang akurat sebelum mengintegrasikan ke dalam sistem. Parameter dalam pengujian menggunakan pengukuran metrik seperti confusion matrix, akurasi, presisi, recall, f1-score, dan AUC score. Confusion matrix adalah sebuah alat yang menyajikan informasi komparatif mengenai hasil klasifikasi yang dilakukan oleh sistem dengan membandingkan hasil klasifikasi yang sebenarnya dan model yang digunakan. 37 Gambar 3.7 Confusion Matrix TP (True Positive) mencerminkan jumlah prediksi yang benar untuk data positif, sedangkan TN (True Negative) mencerminkan jumlah prediksi yang benar untuk data negatif. Di sisi lain, FP (False Positif) menunjukkan jumlah prediksi yang salah untuk data positif, sementara FN (False Negative) menggambarkan jumlah prediksi yang salah untuk data negatif. Kedua kondisi ini menunjukkan adanya kesalahan dalam memprediksi pola data. Akurasi adalah ukuran yang menunjukkan seberapa kemampuan prediksi yang benar secara keseluruhan. Akurasi dapat dihitung dengan persamaan (3.1).
$$Accuracy = \frac{TP + TN}{TP + FP + FN + TN}$$
 Presisi untuk mengukur seberapa kemampuan model dalam

Plagiarism detected: 2.56% <https://esairina.medium.com/memahami-confu...>

id: 4

memprediksi kelas positif dengan benar dari keseluruhan kelas positif. Presisi dapat dihitung dengan persamaan (3.2).
$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$
 Recall untuk mengukur sejauh mana kemampuan model dalam prediksi yang benar untuk kelas positif dari

data positif secara keseluruhan. Recall dapat dihitung dengan persamaan (3.3).
$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$
 F1-score adalah alat ukur yang menggambarkan keseimbangan antara presisi dan recall. F1-score dapat dihitung melalui persamaan (3.4).
$$\text{F1-score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$
 AUC (Area Under Curve) score untuk mengevaluasi sejauh mana model mampu membedakan kelas positif dan negatif dengan benar. AUC ditemukan dari kurva ROC (Receiver Operating Characteristic). Terdapat berbagai indikator nilai AUC, yaitu sangat baik (0.9 - 1), baik (0.8 - 0.9), cukup (0.7 - 0.8), buruk (0.6 - 0.7) dan tidak memadai (0.6). 3.6 Implementasi Model Random Forest Pada proyek ini, implementasi Random Forest ke dalam sistem dilakukan untuk menciptakan sebuah sistem otomatisasi penyiraman atau irigasi cerdas. Proses ini dimulai dengan menggunakan micromlgen adalah pustaka sumber terbuka yang dikembangkan untuk menghadirkan machine learning ke mikrokontroler. Pada dasarnya, pustaka ini mengubah kode dari model ML seperti Random Forest yang sudah dilatih menjadi kode C++ yang dioptimalkan agar mikrokontroler dapat berjalan. Dalam proses ini, parameter max_depth dari masing-masing nilai akan dipilih berdasarkan hasil kinerja dalam memprediksi dan pengguna memori yang dievaluasi. Hal ini dilakukan untuk mengurangi pengguna memori dan meningkatkan efisiensi komputasi, namun dengan hasil kinerja yang terbaik. 3.7 Hasil Hasil yang diharapkan dari implementasi sistem penyiraman otomatis atau irigasi cerdas menggunakan Random Forest adalah terciptanya sistem prediksi yang akurat mengenai waktu dan kebutuhan air yang tepat untuk penyiraman tanaman. Sistem ini diharapkan dapat menjadi solusi untuk meringankan pekerjaan petani, menjaga dan meningkatkan produktivitas pertanian, hingga mendukung keberlanjutan usaha dalam pertanian.

Disclaimer:

This report must be correctly interpreted and analyzed by a qualified person who bears the evaluation responsibility!

Any information provided in this report is not final and is a subject for manual review and analysis. Please follow the guidelines:
[Assessment recommendations](#)

Plagiarism Detector - Your right to know the authenticity! © SkyLine LLC