


## BAB III

### METODOLOGI

Pada bagian ini, metodologi penelitian memiliki peran penting dalam memulai suatu penelitian dan pengembangan produk. Metodologi ini memberikan kerangka sistematis yang mencakup setiap tahapan yang harus dilalui, sehingga mendapatkan solusi dan tujuan yang diharapkan. Gambar 3.1 mengilustrasikan proses penelitian dan pengembangan produk yang dilakukan.



**Gambar 3.1 Alur Metodologi Penelitian**

#### **3.1 Identifikasi Masalah**

Identifikasi masalah adalah memainkan peran yang krusial sebelum merancang sebuah sistem. Tahapan ini dilakukan dengan mengeksplorasi berbagai masalah dari sumber seperti jurnal penelitian dan berita. Di samping itu, masalah juga didapatkan dari pengalaman pribadi dalam menghadapi tantangan dalam

menyiram tanaman. Untuk menemukan dan memverifikasi masalah tersebut dilakukan wawancara dengan berbagai narasumber yang ahli dalam pertanian.

Dari hasil masalah yang didapatkan, petani mengalami kesulitan dalam menyiram tanaman karena metode pengelolaan tanaman masih dilakukan secara tradisional dan memiliki berbagai keterbatasan waktu, tenaga, dan sumber daya manusia. Metode ini menjadi masalah serius yang menyebabkan kegagalan panen dan mengurangi produktivitas pertanian, sehingga petani mengalami kerugian dan dapat mengancam keberlangsungan usaha.

### 3.2 Analisis Solusi

Analisis solusi pada Bab 2 yang akan dievaluasi lebih lanjut dengan membandingkan akurasi, ketangguhan terhadap kualitas data yang beragam, biaya implementasi terkait kebutuhan komputasi. Hal ini dilakukan untuk menentukan metode mana yang terbaik, berdasarkan kemampuan mempelajari pola, memprediksi hasil yang akurat. Kebutuhan komputasi juga dilihat, namun bersifat opsional dan harus melihat spesifikasi mikrokontroler terlebih dahulu.

Hasil akhir yang ditentukan *Random Forest* dipilih karena menghasilkan akurasi terbaik sebesar 99,98% (IORLIAM, 2022). Sedangkan *K-Nearest Neighbors* dan *Support Vector Machine* menghasilkan akurasi sebesar 99,3% (Kaur, 2024). Hal ini membuktikan metode ini lebih unggul pada kemampuan generalisasi dan melakukan prediksi waktu dan kebutuhan air pada tanaman untuk menyiram tanaman secara otomatis.

### 3.3 Pengumpulan Data

Pengumpulan data memiliki peran penting dalam membangun machine learning untuk mempelajari pola data sebelum melakukan prediksi dan pengambilan keputusan. Dataset ini diambil dari penelitian yang dilakukan (Kaur, 2024) yang tersedia di *Mendeley Data* dan dapat diakses <https://data.mendeley.com/datasets/fpdwmm7nrb/1>. Dataset ini berisi 3000 sampel yang berisi kelembaban tanah, temperatur, dan kelembaban udara digunakan sebagai fitur data. Sedangkan target klasifikasi yaitu kondisi pompa, yaitu 0 dan 1. Tabel 3.1 menjelaskan karakteristik dan atribut pada data irigasi tanaman.

**Tabel 3.3 Penjelasan Atribut pada Data Irigasi**

| Atribut              | Tipe Data      | Keterangan                                             |
|----------------------|----------------|--------------------------------------------------------|
| <i>Soil Moisture</i> | <i>float64</i> | Data kelembaban tanah yang bernilai 314,511 – 984,828. |
| <i>Temperature</i>   | <i>float64</i> | Data suhu udara yang bernilai 28,443 – 38,992.         |
| <i>Air Humidity</i>  | <i>float64</i> | Data kelembaban udara yang bernilai 59,367 – 81,267.   |
| <i>Pump Data</i>     | <i>int64</i>   | Label klasifikasi kondisi pompa dengan status 0 dan 1. |

### 3.4 Pengembangan Model

#### 3.4.1 *Preprocessing Data*

*Preprocessing* data adalah langkah penting dalam mengelola data sebelum melatih metode *machine learning*. Tahapan ini dimulai dengan mencari *missing data*. Ada tiga jenis missing data, yaitu hilang sepenuhnya secara acak (*missing*

*completely at random*), hilang secara acak (*missing at random*), dan hilang tidak secara acak (*missing not at random*). Gambar 3.2 menunjukkan analisis jumlah sampel data yang terindikasi missing data pada setiap fitur.

Jumlah sampel yang terindikasi missing value  
pada fitur data:

| Fitur Data    | Jumlah missing |
|---------------|----------------|
| Soil Moisture | 0              |
| Temperature   | 0              |
| Air Humidity  | 0              |
| Pump Data     | 0              |

**Gambar 3.2 Jumlah Missing Value Pada Fitur Data**


Hasil analisis tersebut menunjukkan, fitur kelembaban tanah, suhu udara, dan kelembaban udara memiliki sampel data yang hilang, sehingga tidak diperlukan proses penanganan terhadap missing data.

Selanjutnya, memilih fitur (X), yaitu kelembaban tanah, suhu udara, dan kelembaban udara, sedangkan target (y) adalah status pompa. Data kemudian dibagi menjadi 80% untuk *training* dan 20% untuk *testing* data. Gambar 3.3 menunjukkan *training* data memiliki 2400 sampel dengan 3 fitur, sedangkan *testing* data memiliki 600 sampel.

```
x_train shape (features): (2400, 3)
y_train shape (targets): (2400,)
X_test shape (features): (600, 3)
y_test shape (targets): (600,)
```


**Gambar 3.3 Hasil Pembagian Data *Training* dan *Testing***

Data *training* digunakan untuk melatih model *machine learning*. Untuk data *training* dilakukan pengecekan *outlier* menggunakan *matplotlib* dan ketidakseimbangan data dapat dilihat melalui distribusi *plot*.



**Gambar 3.4 Identifikasi Outlier Menggunakan Boxplot**

Gambar 3.4, hasil identifikasi menunjukkan setiap fitur tidak terindikasi *outlier* karena masih didalam batas *whisker*. Selain itu, distribusi data masih normal, dengan median yang relatif seimbang didalam rentang *interquartile (IQR)*. Oleh karena itu, penerapan *preprocessing* tambahan tidak diperlukan.



**Gambar 3.5 Analisis Keseimbangan Data Menggunakan Plot**

Gambar 3.5 menunjukkan kelas target memiliki perbedaan sedikit, hal ini dibuktikan distribusi kelas target 0 mempunyai jumlah 1133 dengan persentase 52,79%, dan 1 mempunyai jumlah 1271 artinya hanya 55,8%. sehingga tidak

diperlukan penanganan *imbalance*. Tabel 3.5 menyajikan distribusi kelas target berdasarkan jumlah dan persentase.

**Tabel 3.5 Distribusi Kelas Target**

| Target  | Jumlah | Persentase |
|---------|--------|------------|
| 0 (ON)  | 1133   | 52.79%     |
| 1 (OFF) | 1267   | 47.21%     |

Dalam evaluasi kemampuan model dalam memprediksi status pompa dilakukan berdasarkan kondisi yang sudah dikategorikan dari data sensor. Sensor tersebut menghasilkan nilai dalam bentuk sinyal analog yang kemudian diubah menjadi sinyal digital menggunakan ADC (*Analog to Digital Converter*), sehingga data dari sensor dapat dibaca oleh sistem. Tabel 3.4 menyajikan nilai sensor dan kondisi kelembaban, yang dijelaskan oleh (Rosyid, 2022).

**Tabel 3.6 Kategori pada Kelembaban Tanah**

| Nilai ADC  | Kondisi       |
|------------|---------------|
| 289 - 397  | Sangat Basah  |
| 398 – 507  | Basah         |
| 508 – 617  | Normal        |
| 618 - 726  | Kering        |
| $\geq 727$ | Sangat Kering |

Tabel 3.5 menyajikan nilai sensor dan kondisi suhu udara, yang dijelaskan oleh (Pradana, 2023).

**Tabel 3.7 Kategori pada Suhu Udara**

| Nilai ADC                                 | Kondisi |
|-------------------------------------------|---------|
| $\leq 23^{\circ}\text{C}$                 | Dingin  |
| $24^{\circ}\text{C} - 30^{\circ}\text{C}$ | Normal  |
| $\geq 31^{\circ}\text{C}$                 | Panas   |

Tabel 3.6 menyajikan nilai sensor dan kondisi kelembaban udara, yang dijelaskan oleh (Kusnadi, 2023).

**Tabel 3.8 Kategori pada Kelembaban Udara**

| Nilai ADC   | Kondisi |
|-------------|---------|
| $\leq 55\%$ | Kering  |
| $\geq 56\%$ | Lembab  |

Terakhir, untuk kelas klasifikasi disesuaikan dengan kategori kelembaban tanah, suhu udara, dan kelembaban udara yang dijelaskan dalam tabel. Namun kelembaban tanah adalah unsur yang memengaruhi terhadap pertumbuhan tanaman. Oleh karena itu, status kelas 1 sebagai *OFF* dan 0 sebagai *ON*. Gambar 3.6 menunjukkan hasil pengelompokan data irigasi ke dalam kategori yang telah dijelaskan sebelumnya.

| Soil Moisture | Soil Moisture Category | Temperature | Temperature Category | Air Humidity | Air Humidity Category | Pump Data | Pump Data Category |
|---------------|------------------------|-------------|----------------------|--------------|-----------------------|-----------|--------------------|
| 904.010567    | Sangat Kering          | 36.437388   | Panas                | 45.943540    | Kering                | 0         | Hidup              |
| 712.948906    | Kering                 | 27.784112   | Normal               | 72.418063    | Lembab                | 0         | Hidup              |
| 936.291835    | Sangat Kering          | 31.569001   | Panas                | 74.514258    | Lembab                | 0         | Hidup              |
| 968.903367    | Sangat Kering          | 38.965269   | Panas                | 54.469896    | Kering                | 0         | Hidup              |
| 324.277473    | Sangat Basah           | 26.030362   | Normal               | 76.347692    | Lembab                | 1         | Mati               |
| 913.180235    | Sangat Kering          | 18.312291   | Dingin               | 55.694261    | Lembab                | 0         | Hidup              |
| 513.896668    | Normal                 | 26.844001   | Normal               | 38.437523    | Kering                | 1         | Mati               |
| 438.570864    | Basah                  | 34.798523   | Panas                | 59.963820    | Lembab                | 1         | Mati               |
| 479.149079    | Basah                  | 35.376513   | Panas                | 58.645799    | Lembab                | 1         | Mati               |
| 756.236072    | Sangat Kering          | 38.409771   | Panas                | 78.450592    | Lembab                | 0         | Hidup              |
| 362.667297    | Sangat Basah           | 38.242742   | Panas                | 54.790690    | Kering                | 1         | Mati               |
| 604.454506    | Normal                 | 20.007003   | Dingin               | 72.031064    | Lembab                | 1         | Mati               |
| 883.084539    | Sangat Kering          | 27.054185   | Normal               | 63.933662    | Lembab                | 0         | Hidup              |
| 763.805514    | Sangat Kering          | 34.644965   | Panas                | 78.417435    | Lembab                | 0         | Hidup              |
| 936.624424    | Sangat Kering          | 30.076570   | Panas                | 68.188881    | Lembab                | 0         | Hidup              |
| 634.688173    | Kering                 | 38.773692   | Panas                | 58.171497    | Lembab                | 1         | Mati               |
| 809.420996    | Sangat Kering          | 24.281108   | Normal               | 41.160053    | Kering                | 0         | Hidup              |

**Gambar 3.6 Hasil Pengelompokan Data Irigasi**

### 3.4.2 Rancangan *Random Forest*

Perancangan *Random Forest* menggunakan bahasa pemrograman *Python* dan *library sklearn* untuk memudahkan dalam pengembangan model. Implementasi *RandomForestClassifier* dengan *hyperparameter tuning* seperti *n\_estimators* = 100, *criterion* = 'gini', *max\_features* = 'sqrt', dan *bootstrap* = *True*. Secara umum, *Random Forest* membangun *Decision Tree* tanpa pemangkasan atau dibatasi. Namun, peningkatan pohon dapat meningkatkan kebutuhan komputasi. Untuk menghemat kebutuhan komputasi dapat dilakukan dengan *hyperparameter tuning* seperti *max\_depth* (Akbar, 2023). Dalam proyek ini, *hyperparameter max\_depth* ditentukan dalam rentang nilai 3 hingga 7.



Berdasarkan penelitian yang dilakukan oleh (Oktafiani, 2024), *Random Forest* dengan  $max\_depth = 3$  mencapai akurasi 86,34%,  $max\_depth = 4$  mencapai akurasi 86,34%, nilai 5 mencapai akurasi 91,70%,  $max\_depth = 6$  mencapai akurasi 97,07%, dan  $max\_depth = 7$  mencapai akurasi 98,53%.

Penelitian yang dilakukan oleh (Baig, 2022) menunjukkan *hyperparameter* diatur dengan  $max\_depth = 3$  menghasilkan akurasi 97,96%, presisi 98,18%, *recall* 86,66%, *AUC* 0,932, dan waktu pelatihan 0,22 detik.  $Max\_depth = 4$  yang diatur menghasilkan akurasi 97,82%, presisi 99,79%, *recall* 84,21%, *AUC* 0,971, dan waktu pelatihan 0,259 detik.  $Max\_depth = 5$  yang diatur menghasilkan akurasi 99,14%, presisi 99,30%, *recall* 94,36%, *AUC* 0,971, dan waktu pelatihan 0,38 detik.  $Max\_depth = 6$  yang diatur menghasilkan akurasi 99,47%, presisi 99,60%, *recall* 96,53%, *AUC* 0,982, dan waktu pelatihan 0,44 detik.

### 3.5 Pengujian

Pengujian dilakukan untuk memvalidasi kemampuan metode ini dalam menganalisis pola dan melakukan prediksi yang akurat sebelum mengintegrasikan ke dalam sistem. Parameter dalam pengujian menggunakan pengukuran metrik seperti *confusion matrix*, akurasi, presisi, *recall*, *f1-score*, dan *AUC score*.

*Confusion matrix* adalah sebuah alat yang menyajikan informasi komparatif mengenai hasil klasifikasi yang dilakukan oleh sistem dengan membandingkan hasil klasifikasi yang sebenarnya dan model yang digunakan.

|                  |              | Actual Values |              |
|------------------|--------------|---------------|--------------|
|                  |              | Positive (1)  | Negative (0) |
| Predicted Values | Positive (1) | TP            | FP           |
|                  | Negative (0) | FN            | TN           |

**Gambar 3.7 Confusion Matrix**

*TP* (*True Positive*) mencerminkan jumlah prediksi yang benar untuk data positif, sedangkan *TN* (*True Negative*) mencerminkan jumlah prediksi yang benar untuk data negatif. Di sisi lain, *FP* (*False Positif*) menunjukkan jumlah prediksi yang salah untuk data positif, sementara *FN* (*False Negative*) menggambarkan jumlah prediksi yang salah untuk data negatif. Kedua kondisi ini menunjukkan adanya kesalahan dalam memprediksi pola data.

Akurasi adalah ukuran yang menunjukkan seberapa kemampuan prediksi yang benar secara keseluruhan. Akurasi dapat dihitung dengan persamaan (3.1).

$$Accuracy = \frac{T_p + T_n}{T_p + T_n + F_p + F_n} \quad (3.1)$$

Presisi untuk mengukur seberapa kemampuan model dalam memprediksi kelas positif dengan benar dari keseluruhan kelas positif. Presisi dapat hitung dengan persamaan (3.2).

$$Precision = \frac{T_p}{T_p + F_p} \quad (3.2)$$

*Recall* untuk mengukur sejauh mana kemampuan model dalam prediksi yang benar untuk kelas positif dari data positif secara keseluruhan. *Recall* dapat dihitung dengan persamaan (3.3).

$$Recall = \frac{T_p}{T_p + F_n} \quad (3.3)$$

*F1-score* adalah alat ukur yang menggambarkan keseimbangan antara presisi dan recall. *F1-score* dapat dihitung melalui persamaan (3.4).

$$F1 - score = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (3.4)$$

*AUC (Area Under Curve) score* untuk mengevaluasi sejauh mana model mampu membedakan kelas positif dan negatif dengan benar. *AUC* ditemukan dari kurva *ROC (Receiver Operating Characteristic)*. Terdapat berbagai indikator nilai *AUC*, yaitu sangat baik (0.9 - 1), baik (0.8 - 9), cukup (0.7 – 0.8), buruk (0.6 – 0.7) dan tidak memadai (<0.6).

### 3.6 Implementasi Model *Random Forest*

Pada proyek ini, implementasi *Random Forest* ke dalam sistem dilakukan untuk menciptakan sebuah sistem otomatisasi penyiraman atau irigasi cerdas. Proses ini dimulai dengan menggunakan *micromlgen* adalah pustaka sumber terbuka yang dikembangkan untuk menghadirkan *machine learning* ke mikrokontroler. Pada dasarnya, pustaka ini mengubah kode dari model *ML* seperti *Random Forest* yang sudah dilatih menjadi kode *C++* yang dioptimalkan agar mikrokontroler dapat berjalan.

Dalam proses ini, parameter *max\_depth* dari masing-masing nilai akan dipilih berdasarkan hasil kinerja dalam memprediksi dan pengguna memori yang

dievaluasi. Hal ini dilakukan untuk mengurangi pengguna memori dan meningkatkan efisiensi komputasi, namun dengan hasil kinerja yang terbaik.

### **3.7 Hasil**

Hasil yang diharapkan dari implementasi sistem penyiraman otomatis atau irigasi cerdas menggunakan *Random Forest* adalah terciptanya sistem prediksi yang akurat mengenai waktu dan kebutuhan air yang tepat untuk penyiraman tanaman. Sistem ini diharapkan dapat menjadi solusi untuk meringankan pekerjaan petani, menjaga dan meningkatkan produktivitas pertanian, hingga mendukung keberlanjutan usaha dalam pertanian.