

Laporan Hasil Pengecekan Plagiarisme

<https://plagiarism-detector.com>

1/6

Plagiarism Detector v. 2942 - Originality Report 6/10/2026 1:58:40 PM

Analyzed document: BAB 1.pdf Licensed to: STIE MDP_License10

Comparison Preset: Rewrite Detected language: Id

Check type: Internet Check

TEE and encoding: PdfPig

Detailed document body analysis:

Relation chart:

Plagiarism 0% Original 100%
Quotes 0% AI 0%



Distribution graph:



Top sources of plagiarism: 5

0.4%	10	1. https://web-crawler.plagiarism-detector.com/get-doc-pt?did=8kekPo279DJAnw
0.3%	6	2. https://plai.ac.id/
0.2%	6	3. https://web-crawler.plagiarism-detector.com/get-doc-pt?did=_kekPo059zFEmw

Processed resources details: 99 - Ok / 7 - Failed

Important notes:

Wikipedia:	Google Books:	Ghostwriting services:	Anti-cheating:
			
[not detected]	[not detected]	[not detected]	[not detected]

UACE: UniCode Anti-Cheat Engine report:

1. Status: Analyzer On Normalizer On character similarity set to 100%
2. Detected UniCode contamination percent: 0% with limit of: 30%
3. Document not normalized: percent not reached 5%
4. All suspicious symbols will be marked in purple color: Abcd...
5. Invisible symbols found: 0
Assessment recommendation: No special action is required. Document is Ok.
Alphabet stats and symbol analyzes: UACE does not support the doc language! UACE logics skipped!

Active References (Urls Extracted from the Document):

No URLs detected
 Excluded Urls:
No URLs detected
 Included Urls:
No URLs detected

Detailed document analysis:

BAB I PENDAHULUAN 1.1 Latar Belakang Pertanian adalah kegiatan yang dilakukan oleh individu maupun kelompok untuk menghasilkan berbagai bahan dari sumber daya alam yang dapat memenuhi kebutuhan pokok dan tambahan manusia (Kynta, 2024). Salah satu sub sektor pertanian adalah hortikultura, merujuk pada kegiatan budidaya tanaman di pekarangan atau kebun untuk memenuhi kebutuhan sehari-hari seperti sayuran, buah-buahan, dan tanaman hias (Bharata, 2023). Jumlah keterlibatan rumah tangga dalam kegiatan pertanian di Indonesia mengalami kenaikan 8,74% dengan 28.419.396 rumah tangga (Badan Pusat Statistik, 2023). Hal ini yang menunjukkan sektor memiliki peran penting dalam menghasilkan bahan pangan dan baku untuk kebutuhan masyarakat dan industri. Umumnya, Tanaman dapat ditanam di berbagai daerah dengan daratan yang rendah maupun tinggi. Namun, petani masih mengandalkan musim hujan sebagai waktu yang tepat untuk memulai menanam (Makmur, 2023). Hal ini dikarenakan kelembaban tanah memiliki peranan yang penting dalam menyimpan ketersediaan air yang diperlukan bagi tanaman (Hermanto, 2023). Kondisi kelembaban tanah dapat dipengaruhi berbagai faktor seperti curah hujan, jenis tanah, dan laju evapotranspirasi (Hermanto, 2023). Pada dasarnya Evapotranspirasi terdiri dari dua komponen, yaitu evaporasi adalah proses penguapan air dari permukaan tanah, sedangkan transpirasi sebuah proses penguapan air dari jaringan tanaman menjadi uap (Sofia, 2023). Laju 1 2 evapotranspirasi sangat dipengaruhi dari faktor-faktor tertentu seperti iklim dan jenis tanaman (Fausan, 2021). Oleh karena itu, ketersediaan air dalam tanah menjadi sumber kebutuhan tanaman yang penting untuk menggantikan cairan tanaman yang hilang diakibatkan selama proses tersebut. Dalam kegiatan pengelolaan kelembaban tanah sangat penting untuk menjaga tanaman tetap sehat dan tumbuh dengan baik, sehingga menghasilkan panen yang maksimal. Kelembaban tanah yang tidak teratur dapat menghambat pertumbuhan tanaman bahkan dapat menyebabkan gagal panen (Hermanto, 2023). Untuk memenuhi kebutuhan air, penyiraman tanaman harus dilakukan yang sesuai dengan tingkat kelembaban tanah (Subagja, 2023). Namun hingga saat ini, proses menyiram tanaman masih dilakukan secara manual dengan alat sederhana. Tanaman dengan jumlah yang perlu disiram sangat banyak, sehingga sering kali muncul kendala dalam mendistribusi air secara merata. Selain itu, pemilik tanaman sering meninggalkan tanaman dalam waktu yang lama tanpa pengawasan, yang dapat menyebabkan tanaman mati akibat kurangnya perawatan yang diperlukan (Hasani, 2023). Mereka sering mengandalkan pengetahuan dan pengalaman pribadi dalam menentukan jumlah air dan waktu yang dibutuhkan untuk memulai menyiram tanaman (Anggarda, 2023). Namun, perubahan iklim secara mendadak membuat prediksi lahan menjadi tidak akurat (Ningrum, 2023). Kondisi ini mengakibatkan pengelolaan tanaman menjadi kurang efisien dan pemborosan, serta menurunnya produktivitas pertanian (Anggarda, 2023). 3 Hasil wawancara yang dilakukan dengan Havizman SP., M.Si., selaku kepala bidang produksi Dinas Perkebunan Sumatera Selatan, mengungkapkan bahwa petani mengalami kesulitan dalam mengelola kondisi tanaman akibat keterbatasan alat pengukuran dan penyiraman yang masih dilakukan secara tradisional, yang dapat menguras tenaga terutama lahan yang besar. Kondisi ini mengakibatkan kesalahan dalam pemberian air pada tanaman, sehingga tanaman mudah terkena serangan jamur dan penyakit karena kelebihan air, atau keterlambatan perkembangan tanaman karena kekurangan air. Hasil wawancara yang dilakukan dengan Kemas Muhammad Ridhuan, selaku penyuluh pertanian UPTD Balai Pengembangan dan Produksi Benih Tanaman Pangan Dan Hortikultura, mengatakan dalam kegiatan memantau musim dan mengukur kelembaban tanah yang manual dianggap tidak efisien. Hal ini terutama dirasakan dengan adanya fenomena alam seperti El Nino, yang semakin memperburuk efisiensi pengelolaan lahan. Ketergantungan pada teknik tradisional ini sering kali mengalami penurunan hasil panen, bahkan kegagalan panen yang dapat memicu krisis ekonomi. Hasil wawancara yang dilakukan dengan Lili Rozali, S.Kom., SP, selaku kasubbag umum dan kepegawaian Dinas Pertanian Tanaman Pangan dan Hortikultura Provinsi Sumatera Selatan, menjelaskan penggunaan cangkul untuk mengukur kadar air dalam tanah dan membuat saluran irigasi selain selang dinilai memakan waktu dan tenaga. Selain itu, metode manual yang menyebabkan pemberian air dan pupuk pada tanaman menjadi tidak sesuai, hingga mengakibatkan pertumbuhan tanaman menjadi kurang optimal. 4 Hasil wawancara yang dilakukan dengan Denny Satria Mandala Putra, selaku direktur Quarnic Farm, menjelaskan kesulitan dalam mengelola tanaman selama musim kemarau. Dalam memantau kelembaban tanah menggunakan alat ukur yang memerlukan proses menusuk dan mencabut secara berulang kali, yang cukup merepotkan bagi petani. Selain itu, penyiraman tanaman dilakukan dengan membawa selang dan tidak merata. Metode ini dianggap tidak efisien dari segi waktu maupun

tenaga, serta meningkatkan risiko tanaman terkena penyakit dan pertumbuhan yang tidak seragam. Kemajuan teknologi seperti internet of things dan kecerdasan buatan telah memberikan manfaat yang positif di berbagai sektor pertanian. Salah satu cabang dari kecerdasan buatan yang banyak digunakan adalah machine learning. Machine learning adalah kemampuan mesin untuk belajar dan melakukan prediksi atau mengambil keputusan secara otomatis berdasarkan data yang tersedia. Pertanian modern sangat membutuhkan teknologi, terutama dalam pengelolaan irigasi maupun penyiraman tanaman (Anggarda, 2023).

Perancangan sistem otomatisasi penyiraman atau irigasi cerdas dengan internet of things dari penggabungan dari internet sebagai jaringan komputer dan things sebagai objek fisik (Hermanto, 2023). Teknologi ini yang diterapkan pada sistem ini memungkinkan petani bisa memantau dan mengelola penyiraman atau irigasi secara jauh. Tidak hanya itu, sistem ini juga dilengkapi fitur untuk melakukan penyiraman tanaman secara otomatis (Omega, 2023). Sistem ini menggunakan berbagai sensor seperti Automatic Weather Stations (AWS), kelembaban tanah, dan sensor faktor lingkungan lainnya yang dapat 5 memengaruhi pertumbuhan tanaman. Setiap sensor melakukan pengumpulan data dan dikirimkan ke mikrokontroler untuk memantau dan melakukan prediksi penyiraman tanaman (Kaur, 2024). Penerapan machine learning, sistem melakukan prediksi penyiraman tanaman dengan rekomendasi waktu dan kebutuhan air pada tanaman berdasarkan cuaca, kelembaban tanah, dan faktor-faktor lainnya yang memengaruhi tanaman (Anggarda, 2023). Sistem otomatisasi penyiraman atau irigasi cerdas pada tanaman yang berbasis internet of things dan machine learning memberikan keuntungan bagi petani. Pertama, sistem dapat menghemat waktu dan tenaga petani dalam mengukur kelembaban tanah dan menyiram tanaman. Kedua, tingkat akurasi tinggi sistem menjadi solusi untuk mengoptimalkan pengguna air. Ketiga, sistem memberikan rekomendasi yang akurat, untuk memastikan ketersediaan air dalam tanah pada tanaman tetap terjaga (Anggarda, 2023). Sistem otomatisasi penyiraman atau irigasi cerdas tanaman, sebagaimana dijelaskan dalam latar belakang, memberikan kontribusi besar dalam mendukung petani dalam mengelola lahan atau tanaman yang lebih efisien, meningkatkan hasil produktivitas, serta mendukung berkelanjutan dalam praktik pertanian.

1.2 Rumusan Masalah

Sebagaimana masalah yang ditemukan dalam latar belakang, pengelolaan lahan yang dilakukan secara tradisional dinilai tidak efisien dan sering kali terjadi kesalahan dalam pemberian air pada tanaman, termasuk mendistribusi air yang tidak merata. Selain itu, petani tidak dapat meninggalkan tanaman dalam waktu lama. Kondisi ini merugikan petani, yang diakibatkan kegagalan panen, penurunan 6 produktivitas, bahkan mengancam keberlangsungan usaha pertanian. Oleh karena itu, diperlukan digitalisasi di sektor pertanian, seperti penerapan sistem otomatisasi penyiraman atau irigasi cerdas berbasis internet of things dan Random Forest sebagai model machine learning.

1.3 Analisis Terhadap Batasan

1.3.1 Analisis dari Aspek Ekonomis

dilakukan untuk menilai keterbatasan ekonomi dari sebuah produk yang akan dikembangkan, baik pengembang dan pengguna. Dari sudut pandang pengembang, selama membangun sistem irigasi cerdas, lahan yang digunakan berukuran 1.5 x 1.5 meter yang dilengkapi 1 sensor kelembaban tanah dan jaringan irigasi yaitu 1 selang dan 3 sprinkler. Berikut biaya estimasi perangkat keras yang akan dibangun dapat dilihat pada Tabel 1.1.

Nama Barang	Harga Satuan	Jumlah	Jumlah Harga
ESP32 DOIT	Rp 68.900	1	Rp 68.900
DevKit V1	Rp 68.900	1	Rp 68.900
Sensor Kelembaban Tanah	Rp 13.300	1	Rp 13.300
Kapasitif 2.0V DHT22	Rp 22.900	1	Rp 22.900
Relay 5V	Rp 7.500	1	Rp 7.500
Baterai UPS 12V 8AH	Rp 7.500	1	Rp 7.500
Panel Surya 60WP	Rp 379.000	1	Rp 379.000
Controller Charger Solar	Rp 7.000	1	Rp 7.000
Pompa Air 80 PSI	Rp 78.500	1	Rp 78.500
Step Down	Rp 9.900	1	Rp 9.900
Sprinkler	Rp 1.500	3	Rp 4.500
Selang 5 Meter	Rp 34.500	1	Rp 34.500
Box Panel 30x40	Rp 240.000	1	Rp 240.000
Total Biaya Perangkat Keras Keseluruhan			Rp 859.100

Layanan hosting dirancang untuk mendukung sistem dalam memantau dan mengatur irigasi atau penyiraman tanaman dari jarak jauh melalui internet. Untuk kebutuhan hosting, digunakan Virtual Private Server (VPS) dari layanan Hostinger dengan paket KVM 2 seharga Rp 215.229/bulan. Paket ini memberikan spesifikasi meliputi 2 vCPU core, 8 GB RAM, 100 GB NVMe disk space, 8 TB bandwidth, dan sistem operasi Linux. Hasil analisis terkait estimasi biaya modal yang menunjukkan bahwa perangkat keras akan dijual dengan harga berkisar antara Rp 500.000 – Rp 600.000. Sementara itu, biaya berlangganan bulanan diterapkan pada kisaran Rp 10.000 – Rp 50.000.

Tabel 1.2 menampilkan hasil penjualan produk yang disepakati melalui hasil wawancara yang telah dilakukan dengan sejumlah organisasi.

1.2 Analisis dari Aspek Ekonomis No. Organisasi

Aspek Ekonomis Harga perangkat keras belum bisa diusulkan, namun Dinas Perkebunan Provinsi 1 berlangganan bulanan berkisar Rp 15.000 sampai Rp Sumatera Selatan 30.000 per bulan. 8 No. Organisasi Aspek Ekonomis Untuk biaya jual pada perangkat keras dan UPTD Balai Pengembangan langganan setiap bulan masih belum bisa diberikan, 2 dan Produksi

Benih Tanaman karena produk ini perlu dievaluasi dan Pangan dan Hortikultura demonstrasikan terlebih dahulu pada dinas pertanian dan pengguna. Saat ini, biaya layanan berlangganan diusulkan Rp 10.000 per bulan. Namun perangkat keras harus Dinas Pertanian Tanaman didemonstrasikan dengan mempertimbangkan 3 Pangan dan Hortikultura akurasi, kompleksitas, dan manfaat yang diberikan bagi petani, serta kebutuhan perangkat dan kualitas layanan internet. Untuk perangkat keras harus sepadan dengan 4 Qur'anic Farm manfaat bagi petani. Sedangkan langganan bulanan yang diusulkan mulai dari Rp 20.000 per bulan. Seperti yang ditunjukkan pada Tabel 1.1, harga final produk, termasuk perangkat keras dan biaya langganan bulanan, masih belum dapat dipastikan. Oleh karena itu, produk ini memerlukan uji coba dan didemonstrasikan untuk memastikan bahwa manfaat yang diberikan bagi petani sepadan dengan harga jual yang ditetapkan. 1.3.2 Analisis dari Aspek Manufakturabilitas Aspek manufakturabilitas memainkan peran yang penting dalam menetapkan jadwal yang realistis dalam pengembangan produk. Hal ini mencakup 9 penentuan batas waktu yang harus diikuti untuk menyelesaikan produk secara efisien. Tabel 1.3 menjelaskan hasil jadwal batas waktu dalam membangun sistem yang sudah ditentukan oleh masing-masing organisasi. Tabel 1.3 Analisis dari Aspek Manufakturabilitas UPTD Balai Pengembangan Dinas Perkebunan Dinas Pertanian dan Produksi Aspek Provinsi Sumatera Tanaman Pangan Qur'anic Farm Benih Tanaman Selatan dan Hortikultura Pangan dan Hortikultura Membangun Perangkat Keras ✓ ✓ ✓ ✓ (1 Bulan) Membangun Kecerdasan ✓ ✓ ✓ ✓ Buatan (3 Minggu) Membangun Database (1 ✓ ✓ ✓ ✓ Minggu) Membangun REST API Laravel ✓ ✓ ✓ ✓ (2 minggu) Membangun Aplikasi Android ✓ ✓ ✓ ✓ (1 Bulan) Total Waktu 3 Bulan 2 Minggu Pengerjaan 1.3.3 Analisis dari Aspek Sustainabilitas Aspek sustainabilitas dilakukan untuk menilai sejauh mana produk dapat memberikan dan mempertahankan manfaat bagi pengguna, sekaligus menjaga 10 reputasi produk yang positif. Tabel 1.4 menjelaskan hasil kesepakatan sustainabilitas produk yang ditetapkan oleh setiap organisasi. Tabel 1.4 Analisis dari Aspek Sustainabilitas UPTD Balai Pengembangan Dinas Perkebunan Dinas Pertanian dan Produksi Aspek Provinsi Sumatera Tanaman Pangan Qur'anic Farm Benih Tanaman Selatan dan Hortikultura Pangan dan Hortikultura Sistem membaca data kelembaban tanah, suhu udara, ✓ ✓ ✓ ✓ dan kelembaban udara dari sensor dalam 2 detik Sistem melakukan prediksi kebutuhan air ✓ ✓ ✓ ✓ pada tanaman dalam 2 detik 1.4 Analisis Terhadap Karakteristik Solusi Pada Tabel 1.5 akan menjelaskan mengenai masalah yang dihadapi petani dan solusi yang telah ditemukan untuk mengatasi masalah tersebut. Tabel 1.5 Analisis dari Karakteristik Solusi No. Masalah Fungsi Petani menghadapi tantangan dalam Sistem ini menggunakan sensor 1 mengukur kelembaban tanah dan kondisi kelembaban tanah dan sensor cuaca cuaca secara manual (AWS) yang real-time, sehingga 11 No. Masalah Fungsi memberikan data yang presisi dan terkini Sistem ini dibangun untuk menyiram Jumlah tanaman yang perlu disiram tanaman secara merata ke seluruh lahan 2 cukup banyak, petani merasa kesulitan dengan membangun jaringan irigasi dalam menyiram tanaman secara merata menggunakan selang yang terhubung dengan pompa air Penerapan internet of things dan Petani tidak bisa meninggalkan lahan machine learning memungkinkan 3 yang terlalu lama karena meningkatkan petani dapat meninggalkan tanaman risiko kematian pada tanaman yang cukup lama Sistem ini memanfaatkan teknologi Metode tradisional dalam merawat internet of things dan machine learning tanaman sering kali membutuhkan waktu 4 guna meningkatkan efisiensi dalam dan tenaga yang besar, serta berisiko pengguna waktu dan tenaga, sekaligus menurunkan produktivitas pertanian. mendorong produktivitas pertanian Penerapan kecerdasan buatan seperti machine learning dalam suatu sistem Petani kesulitan menentukan kebutuhan 5 dapat melakukan prediksi, memberikan air untuk memulai menyiram tanaman rekomendasi, dan menyiram tanaman secara otomatis 1.5 Pemilihan Solusi Dalam perancangan sistem irigasi cerdas dengan teknologi kecerdasan buatan, setidaknya tiga metode machine learning yang akan dipertimbangkan, yaitu 12 K-Nearest Neighbors (KNN), Support Vector Machine (SVM), dan Random Forest (RF). Pemilihan metode dilakukan dengan meninjau jurnal penelitian yang membahas pengguna metode machine learning, karakteristik dataset, tahapan preprocessing data yang dilakukan, dan hyperparameter tuning. Penelitian yang pertama kali dilakukan oleh (Tace, 2022) dalam mengembangkan sistem irigasi cerdas berbasis IoT dan ML dapat menghemat pengguna air dan pengeluaran biaya. Data diperoleh dari sensor mengukur kelembaban tanah, suhu udara, kelembaban, serta curah hujan. Hasil dari metode K-Nearest Neighbors dengan $\kappa = 3$ menunjukkan akurasi sebesar 98,3% dan RMSE 0,12. Penelitian yang kedua dilakukan oleh (Singh, 2022) menunjukkan Random Forest (RF) mencapai akurasi 85%, precision 88%, recall 82%, dan f1-score 85%. Sementara Support Vector Machine (SVM) menghasilkan kinerja yang lebih baik dengan akurasi 90%, precision 92%, recall 88%, dan f1-score 90%. Penelitian yang ketiga dilakukan oleh (Abo-Zahhad, 2023) menggunakan dataset yang mencakup parameter

lingkungan seperti kelembaban tanah, suhu, dan kelembaban udara. Dataset tersebut digunakan untuk klasifikasi kebutuhan irigasi yang memiliki lima kategori klasifikasi yaitu, not needed, needed, average, needed, dan highly needed. Klasifikasi KNN dengan parameter $\kappa = 5$ dan euclidean distance menghasilkan akurasi sebesar 98,6% dan Root Mean Square Error (RMSE) sebesar 0,10. Hasil ini menunjukkan KNN dapat memprediksi kebutuhan irigasi tanaman. Penelitian yang keempat dilakukan oleh (Mujawar, 2023) untuk memantau dan memprediksi kebutuhan air pada lahan pertanian padi. Sistem ini dirancang untuk mengoptimalkan irigasi berdasarkan kondisi lingkungan secara real-time 13 dengan harapan dapat meningkatkan produktivitas pertanian padi. Parameter utama yang digunakan dalam penelitian ini meliputi kelembaban tanah, suhu, kelembaban udara, dan tingkat ketinggian air. Hasil penelitian menunjukkan SVM menghasilkan akurasi 93,2%, sementara RF menunjukkan akurasi sebesar 86,5%, mengindikasikan SVM memiliki performa yang lebih baik dalam memprediksi kebutuhan irigasi pada skenario tersebut. Penelitian kelima yang dilakukan oleh (Kaur, 2024) menggunakan data yang diperoleh dari sensor kelembaban tanah, suhu, kelembaban udara, dan aktivitas pompa. Kemudian data tersebut dibagi menjadi 80% untuk pelatihan dan 20% untuk pengujian. Hasil klasifikasi RF mencapai akurasi sebesar 99,8%, sementara SVM dengan kernel linear dan KNN dengan manhattan distance dan $\kappa = 5$ masing-masing mencapai akurasi 99,3%. Hal ini menunjukkan bahwa akurasi klasifikasi Random Forest lebih unggul dari SVM dan KNN. Penelitian keenam yang dilakukan oleh (Rafrin, 2024) menggunakan data berisi 1.387 sampel yang meliputi kelembaban tanah, temperatur, dan kelembaban udara masing-masing mewakili tiga kelas. Data tersebut kemudian dibagi menjadi 70% untuk pelatihan dan 30% untuk pengujian. Metode Random Forest dengan hyperparameter seperti 100 pohon, min_samples_split: 2, dan gini index menghasilkan akurasi mencapai 94%. Penelitian ketujuh yang dilakukan oleh (Bhavani, 2022) menggunakan metode preprocessing data seperti K-Means Clustering untuk membagi data menjadi dua kelompok, yaitu needs irrigation dan not needed. Hasil klasifikasi metode SVM menunjukkan akurasi sebesar 89,11%, precision sebesar 90,01%, dan 14 recall sebesar 87,03%. Sementara metode KNN mencapai akurasi 91,05%, precision 92,16%, dan recall 91,11%. Penelitian kedelapan yang dilakukan oleh (Sumarudin, 2021) menunjukkan bahwa dataset yang digunakan terdiri dari tiga kelas pada kolom label, yaitu 10% katup terbuka, 25% katup terbuka, dan 50% katup terbuka. Dataset tersebut dibagi menjadi 90% untuk training dan 10% untuk testing. Metode Support Vector Machine (SVM) dengan kernel linear, gamma auto, dan cost (γ) = 2 menghasilkan akurasi sebesar 95%, precision 94,3%, recall 91%, dan f1-score 92,7%. Penelitian kesembilan yang dilakukan oleh (Kumar, 2024) menerapkan Correlation-Based Feature Selection (CFS) dan K-Means Clustering. Metode SVM dengan kernel radial basic function (rbf) menghasilkan akurasi 98,5, precision 98,3%, recall 99,6%, f1-score 97%, dan specificity 98,7%. Penerapan metode SVM berhasil menghemat penggunaan air hingga 42% dibandingkan dengan metode irigasi tradisional. Penelitian kesepuluh yang dilakukan oleh (IORLIAM, 2022) dengan menggunakan 100.000 sampel data yang mencakup kelembaban tanah, suhu, kelembaban udara, dan waktu, serta label status pompa (On = 1, Off = 0). Dataset ini dibagi menjadi 70% untuk training dan 30% untuk testing. Metode RF dengan 100 pohon dan gini index menghasilkan akurasi 99,98%, precision 99,96%, recall 99,99%, dan f1-score 99,97%. 1.6 Skenario Pemanfaatan Produk Oleh Pengguna Pada proyek ini untuk perangkat keras yang terdiri dari sensor dan mikrokontroler. Dalam sistem ini, sensor ini akan mengumpulkan data secara real- 15 time dan akurat, seperti suhu dan kelembaban, serta sensor lainnya. Data ini dikirimkan ke sistem untuk memantau tanaman dan memprediksi penyiraman tanaman secara otomatis. Untuk perangkat lunak akan digunakan petani dalam memantau dan mengatur irigasi melalui jarak jauh dengan koneksi internet, tidak hanya itu aplikasi dapat dipakai untuk manajemen berbagai perangkat keras seperti mengatur koneksi WiFi dan mengubah nama perangkat. 1.7 Tujuan Tujuan dari capstone project untuk mengimplementasikan sistem otomatisasi penyiraman atau irigasi cerdas tanaman dengan teknologi berbasis internet of things dan machine learning yang menyediakan solusi untuk membantu petani dalam mengelola lahan, khususnya penyiraman atau irigasi pada tanaman yang sudah dijelaskan sebelumnya.

Disclaimer:

This report must be correctly interpreted and analyzed by a qualified person who bears the evaluation responsibility!

Any information provided in this report is not final and is a subject for manual review and analysis. Please follow the guidelines:
Assessment recommendations

Plagiarism Detector - Your right to know the authenticity! © SkyLine LLC

Plagiarism Detector v. 2942 - Originality Report 6/10/2026 2:09:13 PM

Analyzed document: BAB 2.pdf Licensed to: STIE MDP_License10

Comparison Preset: Rewrite Detected language: Id

Check type: Internet Check

TEE and encoding: PdfPig

Detailed document body analysis:

Relation chart:

Plagiarism 3.94% Original 96.02%
Quotes 0.04% AI 0%



Distribution graph:



Top sources of plagiarism: 10

- | Source | Percentage | Count | URL |
|--|------------|-------|-----|
| 1. https://web-crawler.plagiarism-detector.com/get-doc-pt?did=8UekPo24-zpFnQ | 2% | 52 | |
| 2. https://web-crawler.plagiarism-detector.com/get-doc-pt?did=80eiM4W_9jNjkw | 2% | 27 | |
| 3. https://web-crawler.plagiarism-detector.com/get-doc-pt?did=80ilPoa-9jRHnQ | 1% | 23 | |

Processed resources details: 82 - Ok / 8 - Failed

Important notes:

Wikipedia:	Google Books:	Ghostwriting services:	Anti-cheating:
			
[not detected]	[not detected]	[not detected]	[not detected]

UACE: UniCode Anti-Cheat Engine report:

- Status: Analyzer **On** Normalizer **On** character similarity set to **100%**
- Detected UniCode contamination percent: **0%** with limit of: 30%
- Document not normalized: percent not reached 5%
- All suspicious symbols will be marked in purple color: **Abcd...**
- Invisible symbols found: 0

Assessment recommendation:

No special action is required. Document is Ok.

Alphabet stats and symbol analyzes:

UACE does not support the doc language! UACE logics skipped!

Active References (Urls Extracted from the Document):

No URLs detected
 Excluded Urls:
No URLs detected
 Included Urls:
No URLs detected

BAB II PEMILIHAN SOLUSI 2.1 Alternatif Solusi 2.1.1 K-Nearest Neighbors Solusi pertama adalah menggunakan K-Nearest Neighbors (KNN) sebagai metode supervised learning yang sederhana dalam machine learning. Metode ini bekerja dengan

 **Plagiarism detected: 0.4%** <https://journal.mahesacenter.org/index.php/inco...> id: 1

mengklasifikasikan data baru berdasarkan kesamaan dengan data yang telah

dilatih sebelumnya, di mana kesamaan tersebut dihitung dari jarak antara data menggunakan nilai k sebagai jumlah tetangga terdekat (Kaur, 2024). Dalam menentukan kesamaan berdasarkan jumlah tetangga terdekat, KNN mengukur jarak antara data latih dan uji menggunakan jenis perhitungan jarak (Tace, 2022). Salah satu metrik jarak yang digunakan adalah persamaan manhattan yang didefinisikan persamaan (2.1).
$$d(x, y) = \sum_{i=1}^n |x_i - y_i|$$
 (2.1) $k = 1$ di mana $d(x, y)$ adalah jarak antara vektor x (data pelatihan) dan y (data pengujian), n adalah jumlah atribut, dan i adalah indeks atribut. Kelebihan KNN terletak pada kesederhanaan dalam menentukan parameter jumlah tetangga terdekat (k) dan metode pengukuran jarak. Metode ini mampu mengelola sampel data yang besar, meski dapat berdampak pada waktu pemrosesan (Abaye, 2020). Namun, pemilihan nilai k harus dipertimbangkan dengan teliti. Nilai k yang kecil sangat rentan terhadap noise dan menyebabkan overfitting. 16 17 Sementara nilai k yang besar dapat mengurangi pengaruh dari noise, meskipun meningkatkan kompleksitas komputasi (Cholil, 2021). Kelemahan utama dari KNN ketergantungannya pada kualitas dan ukuran dataset. Metode ini sangat sensitif outlier dan data yang hilang (missing), serta kurang cocok untuk data yang berdimensi tinggi (Rahmadini, 2023). KNN memerlukan komputasi yang intensif dan waktu pemrosesan akan meningkat seiring dengan pertambahan ukuran dataset (Abaye, 2020). Gambar 2.1 K-Nearest Neighbors Gambar 2.1 menunjukkan metode K-Nearest Neighbors (KNN) terdiri dari beberapa tahapan dalam proses klasifikasi, yaitu: 1. Memilih parameter jumlah tetangga terdekat (k). 2. Menghitung jarak setiap data uji dengan data latih menggunakan persamaan manhattan distance. 3. Mengurutkan hasil perhitungan jarak manhattan dimulai dari yang terkecil hingga yang terbesar. 4. Mengklasifikasikan data uji berdasarkan kelas mayoritas yang paling sering muncul dari (k) tetangga terdekat. 18 Pada solusi pertama, perancangan sistem irigasi cerdas menggunakan K-Nearest Neighbors (KNN), parameter yang digunakan adalah $k = 5$ dan jenis jarak yang digunakan adalah manhattan. Dataset ini dibagi menjadi 80% data latih dan 20% data uji, menghasilkan akurasi sebesar 99,8% (Kaur, 2024). 2.1.2 Support Vector Machine Solusi kedua adalah menggunakan

 **Plagiarism detected: 1.79%** <https://web-crawler.plagiarism-detector.com/ge...> + 2 id: 2

Support Vector Machine (SVM) sebagai metode supervised learning dalam machine learning, yang mampu menyelesaikan masalah klasifikasi dan regresi. SVM bekerja dengan mencari hyperplane terbaik yang memisahkan dua kelas dengan memaksimalkan margin. Metode ini mampu memisahkan data secara linier maupun non-linier.

SVM memiliki kelebihan dalam menghasilkan generalisasi yang tinggi, tahan terhadap noise dan outlier, serta mampu mengelola data yang tidak seimbang. Tidak hanya itu, SVM dapat menangani data berdimensi tinggi dengan jumlah sampel terbatas (Abaye, 2020). Kelemahan dari SVM adalah tidak cocok untuk himpunan data dengan jumlah sampel dan dimensi yang besar. Kinerja SVM dipengaruhi dalam pemilihan kernel dan nilai regulasi C , sehingga akurasi, kebutuhan komputasi dan waktu pemrosesan bervariasi (Abaye, 2020). 19 Gambar 2.2 Support Vector Machine Gambar 2.2 menunjukkan proses kerja dalam menentukan hyperplane dan memaksimalkan margin. SVM terdiri dari tiga komponen utama, yaitu hyperplane sebagai bidang pemisah terbaik antara dua kelas, margin yang merupakan jarak hyperplane dan jarak

 **Plagiarism detected: 0.58%** <https://web-crawler.plagiarism-detector.com/ge...> + 2 id: 3

terdekat dari masing-masing kelas, serta support vector yang merupakan data yang paling dekat

dengan hyperplane (Junus, 2023). Proses pelatihan SVM dimulai dengan himpunan data pelatihan $\{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$, di mana $x_i \in \mathbb{R}^d$ mewakili vektor fitur, dan $y_i \in \{1, -1\}$ menunjukkan label kelas. Kedua kelas dapat memisahkan dengan sempurna oleh hyperplane, yang didefinisikan dengan persamaan (2.2).
$$w \cdot x + b = 0$$
 (2.2) di mana w adalah vektor bobot yang terkait dengan masing-masing fitur data, x adalah vektor fitur data, dan b adalah nilai bias. Tujuan dari SVM adalah menemukan hyperplane yang memaksimalkan

margin, yaitu jarak antara dua kelas terhadap hyperplane. Margin tersebut dihitung $2 \| \mathbf{w} \|$ sebagai , di mana $\mathbf{w}$ merupakan norma dari vektor bobot $\mathbf{w}$. $\| \mathbf{w} \| \leq 20$ Untuk menemukan hyperplane terbaik, dilakukan proses optimasi melalui Quadratic Programming dengan meminimalkan fungsi pada persamaan (

 **Plagiarism detected: 1.16%** <https://web-crawler.plagiarism-detector.com/ge...> id: 4

2.3). $\min_{\mathbf{w}} \frac{1}{2} \| \mathbf{w} \|^2$ dengan syarat: $(\mathbf{w} \cdot \mathbf{x}_i + b) \geq 1, i = 1, 2, 3,$

... (2.5) Optimisasi dapat diselesaikan dengan menerapkan metode lagrange multiplier yang ditunjukkan pada persamaan (2.6). $\frac{1}{2} \| \mathbf{w} \|^2 + \sum (\alpha_i (\mathbf{w} \cdot \mathbf{x}_i + b - 1))$ (2.6) $\alpha_i \geq 0$ di mana $\alpha_i \geq 0$ adalah nilai lagrange multiplier. Untuk memperoleh nilai optimal dari $\mathbf{w}$ dan b , dilakukan penurunan fungsi terhadap $\mathbf{w}$ dan b , kemudian diubah menjadi nilai nol, sehingga menghasilkan syarat optimal yang ditunjukkan pada persamaan (2.7) dan persamaan (2.8). $\frac{\partial}{\partial \mathbf{w}} (\frac{1}{2} \| \mathbf{w} \|^2 + \sum (\alpha_i (\mathbf{w} \cdot \mathbf{x}_i + b - 1))) = 0 \rightarrow \mathbf{w} = - \sum \alpha_i \mathbf{x}_i$ (2.7) $\frac{\partial}{\partial b} (\frac{1}{2} \| \mathbf{w} \|^2 + \sum (\alpha_i (\mathbf{w} \cdot \mathbf{x}_i + b - 1))) = 0 \rightarrow \sum \alpha_i = 1$ (2.8) Persamaan lagrange multiplier diubah dengan substitusi turunan dari persamaan (2.7) dan persamaan (2.8), sehingga membentuk dualitas lagrange. Kemudian memaksimalkan dengan persamaan (2.9). $\max_{\alpha} \sum \alpha_i (\mathbf{x}_i \cdot \mathbf{x}_i + b) - \frac{1}{2} \| \sum \alpha_i \mathbf{x}_i \|^2$ dengan syarat: $\alpha_i \geq 0; \sum \alpha_i = 1, 2, 3, \dots; \mathbf{w} \cdot \mathbf{w} = 0$. Hasil dari persamaan (2.9) adalah 0, yang disebut sebagai support vectors untuk menentukan posisi hyperplane. Untuk memprediksi kelas dari data baru yang dimasukkan, dengan menggunakan persamaan (2.10). $\frac{1}{2} \| \mathbf{w} \|^2 + \sum (\alpha_i (\mathbf{w} \cdot \mathbf{x}_i + b - 1))$ (2.10) $\alpha_i \geq 0$ di mana α_i adalah support vector, dan sebagai vektor data baru yang akan diprediksi. Untuk kasus kedua kelas yang tidak dapat dipisahkan secara sempurna, SVM menawarkan kernel trick untuk memisahkan data non-linier dengan mentransformasikan data ke ruang fitur berdimensi lebih tinggi (Kaur, 2024). Namun, dalam penelitian tersebut, menerapkan kernel linear yang pengukuran produk titik dari vektor data di ruang aslinya, tanpa melakukan transformasi (Rabbani, 2023). Umumnya kernel linear mampu tahan overfitting dan proses pelatihan lebih cepat dibandingkan kernel non linear (Abaye, 2020). Persamaan kernel linear dapat didefinisikan pada persamaan (2.11). $\mathbf{w} \cdot \mathbf{w} = \mathbf{w} \cdot \mathbf{w}$ (2.11) Selain menerapkan kernel trick, SVM juga mampu menyelesaikan kasus tersebut dengan menerapkan soft margin dengan menambahkan variabel slack $\xi \geq 0$ yang berfungsi sebagai pengukur kesalahan dalam klasifikasi. Variabel ini dimasukkan ke dalam bentuk Quadratic Programming pada persamaan (2.12). $\min_{\mathbf{w}, b, \xi} \frac{1}{2} \| \mathbf{w} \|^2 + \sum (\alpha_i (\mathbf{w} \cdot \mathbf{x}_i + b - 1 - \xi_i))$ dengan syarat: $(\mathbf{w} \cdot \mathbf{x}_i + b) \geq 1 - \xi_i, \xi_i \geq 0, i = 1, 2, 3, \dots$ (2.13) Masalah optimasi dengan lagrange multiplier pada persamaan (2.6) dimodifikasi menjadi persamaan berikut: $\frac{1}{2} \| \mathbf{w} \|^2 + \sum (\alpha_i (\mathbf{w} \cdot \mathbf{x}_i + b - 1 - \xi_i)) + \sum (\beta_i \xi_i)$ (2.14) $\beta_i \geq 0$ Persamaan dari maksimum dualitas lagrange multiplier dilakukan dengan memodifikasi menjadi persamaan (2.15). $\max_{\alpha, \beta} \sum \alpha_i (\mathbf{x}_i \cdot \mathbf{x}_i + b) - \frac{1}{2} \| \sum \alpha_i \mathbf{x}_i \|^2 + \sum \beta_i \xi_i$ dengan syarat: $0 \leq \xi_i \leq \xi_i; \sum \alpha_i = 1, 2, 3, \dots; \beta_i \geq 0$. Parameter β_i yang digunakan untuk mengatur kesalahan klasifikasi yang diperbolehkan pada data latih. Nilai yang besar akan memperketat dan mengurangi toleransi kesalahan dengan memperkecil margin, namun berisiko overfitting. Sebaliknya, nilai yang kecil akan memberikan toleransi kesalahan dengan melebarkan margin, namun berisiko underfitting (Aryawan, 2023). Pada solusi kedua, perancangan sistem irigasi menggunakan Support Vector Machine (SVM), kernel yang digunakan adalah linear. Dataset ini dibagi menjadi 80% data latih dan 20% data uji, menghasilkan akurasi sebesar 99,3% (Kaur, 2024). 2.1.3 Random Forest Solusi ketiga menggunakan Random Forest (RF) adalah metode ensemble learning yang populer untuk klasifikasi maupun regresi. Metode ini bekerja dengan menggabungkan sejumlah Decision Tree yang terpisah, di mana setiap pohon menggunakan subset data yang dipilih secara acak melalui teknik bagging dan random feature selection (Abaye, 2020). Random Forest dikembangkan dari Classification dan Regression Tree (CART), yang merupakan teknik klasifikasi yang menganalisis data menggunakan Decision Tree (Lestari, 2024). 2.3 Setiap Decision Tree terdiri dari beberapa jenis simpul, yaitu simpul akar yang terletak di puncak dalam pohon. Simpul internal sebagai simpul percabangan yang memiliki satu input dan dua output, dan simpul daun. Simpul terakhir yang dikenal sebagai simpul daun yang hanya memiliki satu masukan tanpa menghasilkan keluaran tambahan (Rakhmat, 2023). Random Forest memiliki kemampuan generalisasi yang tinggi dengan membangun pohon yang beragam, sehingga mengurangi overfitting. Metode ini mampu memproses data dengan jumlah sampel dan dimensi yang besar, serta fitur kategoris. Keunggulan metode ini tahan terhadap data dengan outlier, noise, dan ketidakseimbangan (Abaye, 2020). Tidak hanya itu, Random Forest mampu menangani missing data (Zhu, 2020). Kelemahan dari Random Forest terletak pada kebutuhan

komputasi dan waktu pemrosesan yang dapat meningkat seiring bertambahnya jumlah dan kedalaman pohon, terutama dataset yang besar. Metode ini juga memerlukan spesifikasi prosesor tinggi untuk pemrosesan paralel. Oleh karena itu, pengaturan hyperparameter untuk membatasi jumlah dan kedalaman maksimum pohon yang dibangun sangat penting untuk mengurangi kebutuhan komputasi (Zhu, 2020). Gambar 2.3 Random Forest 24 Berdasarkan Gambar 2.3, Random Forest membangun sejumlah Decision Tree yang secara terpisah melalui teknik bagging (bootstrap aggregating), di mana sampel acak dari data pelatihan yang dipilih dengan penggantian (replacement). Setiap pohon dibangun tanpa pemangkasan dan menggunakan random feature selection. Proses ini diulangi hingga jumlah pohon yang ditentukan (Lestari, 2024). Random feature selection dilakukan untuk memilih sejumlah fitur secara acak yang digunakan pada setiap simpul saat membangun pohon. Dalam pengaturan ini, nilai yang lebih rendah dapat meningkatkan variasi dan mengurangi korelasi antar pohon, yang dapat memperkuat stabilitas saat penggabungan pohon (Yulianto, 2024). Untuk klasifikasi, nilai ini sering diatur dengan $\sqrt{p}$, di mana p adalah jumlah $\sqrt{p}$ fitur dalam dataset (Junus, 2023). Proses pembentukan Decision Tree dalam Random Forest dimulai dengan menentukan simpul akar. Selanjutnya, dilakukan pemisahan pada simpul untuk menentukan simpul terminal dan simpul daun berdasarkan kriteria terbaik dengan menghitung menggunakan Gini Index (Yulianti, 2023). Perhitungan Gini Index dan Gini Split dilakukan menggunakan persamaan (2.16) dan persamaan (2.17). $2 \sum_{k=1}^K p_k (1 - p_k)$ (2.16) $\frac{1}{n} \sum_{k=1}^K p_k (1 - p_k)$ (2.17) di mana p_k adalah probabilitas dari kelas ke- k dalam simpul, dan n adalah jumlah total kelas. $\frac{1}{n} \sum_{k=1}^K p_k (1 - p_k)$ (2.17) $\frac{1}{n} \sum_{k=1}^K p_k (1 - p_k)$ (2.17) di mana p_k dan n adalah jumlah sampel dalam subset setelah pemisahan, n dan $1 - p_k$ adalah simpul hasil pemisahan, serta n adalah jumlah total sampel pada simpul. 2.25 Pada solusi ketiga, perancangan sistem irigasi menggunakan Random Forest (RF), dengan membangun jumlah 100 pohon dan kriteria Gini Index. Dataset tersebut akan dibagi menjadi 80% untuk data latih dan 20% untuk data uji. Random Forest menghasilkan akurasi sebesar 99,98%, precision 99,96%, recall 99,99%, dan f1-score 99,97% (IORLIAM, 2022). 2.2 Analisis Pemilihan Solusi Tabel 2.2 Analisis Pemilihan Solusi Karakteristik Pendekatan Berdasarkan Solusi Solusi Aspek Analisis Terpilih Pendekatan-1 Aspek Ekonomis Preprocessing: Selama proses pelatihan KNN, kebutuhan komputasi - train_test_split (80 : bisa meningkat seiring bertambahnya ukuran dataset 20) (Abaye, 2020). - StandarScaler Aspek Manufakturabilitas - Waktu pemrosesan untuk melatih KNN menjadi Classifier: lama seiring bertambahnya ukuran dataset (Abaye, K-Nearest Neighbors 2020). Aspek Sustainabilitas (ϵ : 5, metric: manhattan) Kemampuan pada KNN menghasilkan akurasi mencapai 99,3% (Kaur, 2024). Pendekatan-2 Aspek Ekonomis Preprocessing: Pemilihan kernel dan ukuran dataset seperti jumlah - train_test_split (80 : sampel yang besar dapat meningkatkan kebutuhan 20) komputasi selama proses pelatihan (Abaye, 2020). - StandarScaler Namun, SVM ramah dalam pengguna memori 26 Karakteristik Pendekatan Berdasarkan Solusi Solusi Aspek Analisis Terpilih dengan hanya membangun batas keputusan Classifier: menggunakan subset data pelatihan yang disebut Support Vector Machine support vector (Palaniappan, 2024). (kernel: linear) Aspek Manufakturabilitas Pemilihan kernel dan parameter C sangat memengaruhi proses pelatihan SVM. Umumnya, kernel linear jauh lebih cepat dibandingkan non- linear. Sementara itu, ukuran dataset yang sangat besar membuat proses pelatihan menjadi sangat lambat (Abaye, 2020). Aspek Sustainabilitas Kemampuan pada SVM menghasilkan akurasi sebesar 99,3% (Kaur, 2024). Pendekatan-3 Aspek Ekonomis Preprocessing: Selama melatih RF membutuhkan komputasi yang train_test_split (80 : 20) tinggi maupun rendah tergantung ukuran dataset, serta jumlah pohon dan kedalaman pohon yang Classifier: dibangun. Namun kebutuhan komputasi tersebut $\sqrt{p}$ Random Forest dapat diminimalkan dengan membatasi kedalaman (n_estimators: 100, pohon yang dibangun (Zhu, 2020). Kedalaman criterion:

Quotes detected: 0.04%

id: 5

'gini',

pohon terendah yang mampu menghasilkan kinerja max_features: 'sqrt', klasifikasi yang baik dan tetap konsisten akan dipilih bootstrap: True) untuk meminimalkan kebutuhan komputasi. Aspek Manufakturabilitas 27 Karakteristik Pendekatan Berdasarkan Solusi Solusi Aspek Analisis Terpilih Selain ukuran dataset, hyperparameter seperti jumlah pohon dan kedalaman pohon dapat memengaruhi waktu pelatihan. Untuk mempercepat proses tersebut dapat dilakukan dengan menerapkan pemrosesan paralel dan mengatur hyperparameter dengan membatasi kedalaman pohon, selain jumlah pohon yang dibangun (Zhu, 2020). Aspek Sustainabilitas Kemampuan pada RF menghasilkan akurasi mencapai 99,98% (IORLIAM, 2022).

Disclaimer:

This report must be correctly interpreted and analyzed by a qualified person who bears the evaluation responsibility!

Any information provided in this report is not final and is a subject for manual review and analysis. Please follow the guidelines:

Assessment recommendations

Plagiarism Detector - Your right to know the authenticity! ☐ SkyLine LLC

Plagiarism Detector v. 2942 - Originality Report 6/10/2026 2:11:53 PM

Analyzed document: BAB 3.pdf Licensed to: STIE MDP_License10

Comparison Preset: Rewrite Detected language: Id

Check type: Internet Check

TEE and encoding: PdfPig

Detailed document body analysis:

Relation chart:

Plagiarism 4.4% Original 95.51%
Quotes 0.08% AI 0%



Distribution graph:



Top sources of plagiarism: 3

- | Source | Percentage | Count | URL |
|--------|------------|-------|--|
| 1. | 5% | 96 | https://web-crawler.plagiarism-detector.com/get-doc-pt?did=8UihOYK_9DJAmg |
| 2. | 2% | 43 | https://esairina.medium.com/memahami-confusion-matrix-accuracy-precision-recall-spe... |
| 3. | 0.3% | 13 | https://web-crawler.plagiarism-detector.com/get-doc-pt?did=9EekPoy58zZHng |

Processed resources details: 109 - Ok / 12 - Failed

Important notes:

Wikipedia:	Google Books:	Ghostwriting services:	Anti-cheating:
			
[not detected]	[not detected]	[not detected]	[not detected]

UACE: UniCode Anti-Cheat Engine report:

- Status: Analyzer **On** Normalizer **On** character similarity set to **100%**
- Detected UniCode contamination percent: **0%** with limit of: 30%
- Document not normalized: percent not reached 5%
- All suspicious symbols will be marked in purple color: **Abcd...**
- Invisible symbols found: 0

Assessment recommendation:

No special action is required. Document is Ok.

Alphabet stats and symbol analyzes:

UACE does not support the doc language! UACE logics skipped!

Active References (Urls Extracted from the Document):

<https://plagiarism-detector.com>

2/5

No URLs detected

 Excluded Urls:

No URLs detected

 Included Urls:

No URLs detected

Detailed document analysis:

BAB III METODOLOGI Pada bagian ini, metodologi penelitian memiliki peran penting dalam memulai suatu penelitian dan pengembangan produk. Metodologi ini memberikan kerangka sistematis yang mencakup setiap tahapan yang harus dilalui, sehingga mendapatkan solusi dan tujuan yang diharapkan. Gambar 3.1 mengilustrasikan proses penelitian dan pengembangan produk yang dilakukan. Gambar 3.1 Alur Metodologi Penelitian 3.1 Identifikasi Masalah

Identifikasi masalah adalah memainkan peran yang krusial sebelum merancang sebuah sistem. Tahapan ini dilakukan dengan mengeksplorasi berbagai masalah dari sumber seperti jurnal penelitian dan berita. Di samping itu, masalah juga didapatkan dari pengalaman pribadi dalam menghadapi tantangan dalam 28 29 menyiram tanaman. Untuk menemukan dan memverifikasi masalah tersebut dilakukan wawancara dengan berbagai narasumber yang ahli dalam pertanian. Dari hasil masalah yang didapatkan, petani mengalami kesulitan dalam menyiram tanaman karena metode pengelolaan tanaman masih dilakukan secara tradisional dan memiliki berbagai keterbatasan waktu, tenaga, dan sumber daya manusia. Metode ini menjadi masalah serius yang menyebabkan kegagalan panen dan mengurangi produktivitas pertanian, sehingga petani mengalami kerugian dan dapat mengancam keberlangsungan usaha.

3.2 Analisis Solusi Analisis solusi pada Bab 2 yang akan dievaluasi lebih lanjut dengan membandingkan akurasi, ketangguhan terhadap kualitas data yang beragam, biaya implementasi terkait kebutuhan komputasi. Hal ini dilakukan untuk menentukan metode mana yang terbaik, berdasarkan kemampuan mempelajari pola, memprediksi hasil yang akurat. Kebutuhan komputasi juga dilihat, namun bersifat opsional dan harus melihat spesifikasi mikrokontroler terlebih dahulu. Hasil akhir yang ditentukan Random Forest dipilih karena menghasilkan akurasi terbaik sebesar 99,98% (IORLIAM, 2022). Sedangkan K-Nearest Neighbors dan Support Vector Machine menghasilkan akurasi sebesar 99,3% (Kaur, 2024). Hal ini membuktikan metode ini lebih unggul pada kemampuan generalisasi dan melakukan prediksi waktu dan kebutuhan air pada tanaman untuk menyiram tanaman secara otomatis.

3.3 Pengumpulan Data Pengumpulan data memiliki peran penting dalam membangun machine learning untuk mempelajari pola data sebelum melakukan prediksi dan pengambilan keputusan. Dataset ini diambil dari penelitian yang dilakukan (Kaur, 2024) yang tersedia di Mendeley Data dan dapat diakses <https://data.mendeley.com/datasets/fpdwmm7nrb/1>. Dataset ini berisi 3000 sampel yang berisi kelembaban tanah, temperatur, dan kelembaban udara digunakan sebagai fitur data. Sedangkan target klasifikasi yaitu kondisi pompa, yaitu 0 dan 1. Tabel 3.1 menjelaskan karakteristik dan atribut pada data irigasi tanaman. Tabel 3.3 Penjelasan Atribut pada Data Irigasi Atribut Tipe Data Keterangan Soil Moisture float64 Data kelembaban tanah yang bernilai 314,511 – 984,828. Temperature float64 Data suhu udara yang bernilai 28,443 – 38,992. Air Humidity float64 Data kelembaban udara yang bernilai 59,367 – 81,267. Pump Data int64 Label klasifikasi kondisi pompa dengan status 0 dan 1.

3.4 Pengembangan Model

3.4.1 Preprocessing Data Preprocessing data adalah langkah penting dalam mengelola data sebelum melatih metode machine learning. Tahapan ini dimulai dengan mencari missing data. Ada tiga jenis missing data, yaitu hilang sepenuhnya secara acak (missing 31 completely at random), hilang secara acak (missing at random), dan hilang tidak secara acak (missing not at random). Gambar 3.2 menunjukkan analisis jumlah sampel data yang terindikasi missing data pada setiap fitur. Gambar 3.2 Jumlah Missing Value Pada Fitur Data Hasil analisis tersebut menunjukkan, fitur kelembaban tanah, suhu udara, dan kelembaban udara memiliki sampel data yang hilang, sehingga tidak diperlukan proses penanganan terhadap missing data. Selanjutnya, memilih fitur (X), yaitu kelembaban tanah, suhu udara, dan kelembaban udara, sedangkan target (y) adalah status pompa. Data kemudian dibagi menjadi 80% untuk training dan 20% untuk testing data. Gambar 3.3 menunjukkan training data memiliki 2400 sampel dengan 3 fitur, sedangkan testing data memiliki 600 sampel. Gambar 3.3 Hasil Pembagian Data Training dan Testing Data training digunakan untuk melatih model machine learning. Untuk data training dilakukan pengecekan outlier menggunakan matplotlib dan ketidakseimbangan data dapat dilihat melalui distribusi plot.

3.2 Identifikasi Outlier Menggunakan Boxplot Gambar 3.4, hasil identifikasi menunjukkan setiap fitur tidak terindikasi outlier karena masih didalam batas whisker. Selain itu, distribusi data masih normal, dengan median yang relatif seimbang didalam rentang interquartile (IQR). Oleh karena itu, penerapan preprocessing tambahan tidak diperlukan. Gambar 3.5 Analisis Keseimbangan Data Menggunakan Plot Gambar 3.5 menunjukkan kelas target memiliki perbedaan sedikit, hal ini dibuktikan distribusi kelas target 0 mempunyai jumlah 1133 dengan persentase 52,79%, dan 1 mempunyai jumlah 47,21% artinya hanya 5,58%. sehingga tidak diperlukan penanganan imbalance. Tabel 3.5 menyajikan distribusi kelas target berdasarkan

jumlah dan persentase. Tabel 3.5 Distribusi Kelas Target Target Jumlah Persentase 0 (ON) 1133 52.79% 1 (OFF) 1267 47.21% Dalam evaluasi kemampuan model dalam memprediksi status pompa dilakukan berdasarkan kondisi yang sudah dikategorikan dari data sensor. Sensor tersebut menghasilkan nilai dalam bentuk sinyal analog yang kemudian diubah menjadi sinyal digital menggunakan ADC (Analog to Digital Converter), sehingga data dari sensor dapat dibaca oleh sistem. Tabel 3.4 menyajikan nilai sensor dan kondisi kelembaban, yang dijelaskan oleh (Rosyid, 2022). Tabel 3.6 Kategori pada Kelembaban Tanah Nilai ADC Kondisi 289 - 397 Sangat Basah 398 - 507 Basah 508 - 617 Normal 618 - 726 Kering ≥ 727 Sangat Kering Tabel 3.5 menyajikan nilai sensor dan kondisi suhu udara, yang dijelaskan oleh (Pradana, 2023). 34 Tabel 3.7 Kategori pada Suhu Udara Nilai ADC Kondisi $\leq 23^{\circ}\text{C}$ Dingin $24^{\circ}\text{C} - 30^{\circ}\text{C}$ Normal $\geq 31^{\circ}\text{C}$ Panas Tabel 3.6 menyajikan nilai sensor dan kondisi kelembaban udara, yang dijelaskan oleh (Kusnadi, 2023). Tabel 3.8 Kategori pada Kelembaban Udara Nilai ADC Kondisi $\leq 55\%$ Kering $\geq 56\%$ Lembab Terakhir, untuk kelas klasifikasi disesuaikan dengan kategori kelembaban tanah, suhu udara, dan kelembaban udara yang dijelaskan dalam tabel. Namun kelembaban tanah adalah unsur yang memengaruhi terhadap pertumbuhan tanaman. Oleh karena itu, status kelas 1 sebagai OFF dan 0 sebagai ON. Gambar 3.6 menunjukkan hasil pengelompokan data irigasi ke dalam kategori yang telah dijelaskan sebelumnya. 35 Gambar 3.6 Hasil Pengelompokan Data Irigasi 3.4.2 Rancangan Random Forest Perancangan Random Forest menggunakan bahasa pemrograman Python dan library sklearn untuk memudahkan dalam pengembangan model. Implementasi RandomForestClassifier dengan hyperparameter tuning seperti `n_estimators = 100`, `criterion =`

Quotes detected: 0.06%

id: 1

'gini',

`max_features =`

Quotes detected: 0.06%

id: 2

'sqrt',

dan `bootstrap = True`. Secara umum, Random Forest membangun Decision Tree tanpa pemangkasan atau dibatasi. Namun, peningkatan pohon dapat meningkatkan kebutuhan komputasi. Untuk menghemat kebutuhan komputasi dapat dilakukan dengan hyperparameter tuning seperti `max_depth` (Akbar, 2023). Dalam proyek ini, hyperparameter `max_depth` ditentukan dalam rentang nilai 3 hingga 7. 36 Berdasarkan

Plagiarism detected: 2.86% <https://web-crawler.plagiarism-detector.com/ge...>

id: 3

penelitian yang dilakukan oleh (Oktafiani, 2024), Random Forest dengan `max_depth = 3` mencapai akurasi 86,34%, `max_depth = 4` mencapai akurasi 86,34%, nilai 5 mencapai akurasi 91,70%, `max_depth = 6` mencapai akurasi 97,07%, dan `max_depth = 7` mencapai akurasi 98,53%. Penelitian yang dilakukan oleh

(Baig, 2022) menunjukkan hyperparameter diatur dengan `max_depth = 3` menghasilkan akurasi 97,96%, presisi 98,18%, recall 86,66%, AUC 0,932, dan waktu pelatihan 0,22 detik. `Max_depth = 4` yang diatur menghasilkan akurasi 97,82%, presisi 99,79%, recall 84,21%, AUC 0,971, dan waktu pelatihan 0,259 detik. `Max_depth = 5` yang diatur menghasilkan akurasi 99,14%, presisi 99,30%, recall 94,36%, AUC 0,971, dan waktu pelatihan 0,38 detik. `Max_depth = 6` yang diatur menghasilkan akurasi 99,47%, presisi 99,60%, recall 96,53%, AUC 0,982, dan waktu pelatihan 0,44 detik. 3.5 Pengujian Pengujian dilakukan untuk memvalidasi kemampuan metode ini dalam menganalisis pola dan melakukan prediksi yang akurat sebelum mengintegrasikan ke dalam sistem. Parameter dalam pengujian menggunakan pengukuran metrik seperti confusion matrix, akurasi, presisi, recall, f1-score, dan AUC score. Confusion matrix adalah sebuah alat yang menyajikan informasi komparatif mengenai hasil klasifikasi yang dilakukan oleh sistem dengan membandingkan hasil klasifikasi yang sebenarnya dan model yang digunakan. 37 Gambar 3.7 Confusion Matrix TP (True Positive) mencerminkan jumlah prediksi yang benar untuk data positif, sedangkan TN (True Negative) mencerminkan jumlah prediksi yang benar untuk data negatif. Di sisi lain, FP (False Positif) menunjukkan jumlah prediksi yang salah untuk data positif, sementara FN (False Negative) menggambarkan jumlah prediksi yang salah untuk data negatif. Kedua kondisi ini menunjukkan adanya kesalahan dalam memprediksi pola data. Akurasi adalah ukuran yang menunjukkan seberapa kemampuan prediksi yang benar secara keseluruhan. Akurasi dapat dihitung dengan persamaan (3.1).
$$\text{Akurasi} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{FP} + \text{FN} + \text{TN}}$$
 Presisi untuk mengukur seberapa kemampuan model dalam

Plagiarism detected: 2.56% <https://esairina.medium.com/memahami-confu...>

id: 4

memprediksi kelas positif dengan benar dari keseluruhan kelas positif. Presisi dapat hitung dengan persamaan (3.2). $\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}$ 38 Recall untuk mengukur sejauh mana kemampuan model dalam prediksi yang benar untuk kelas positif dari

data positif secara keseluruhan. Recall dapat dihitung dengan persamaan (3.3). $\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}$ (3.3) F1-score adalah alat ukur yang menggambarkan keseimbangan antara presisi dan recall. F1-score dapat dihitung melalui persamaan (3.4). $\text{F1-score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$ (3.4) AUC (Area Under Curve) score untuk mengevaluasi sejauh mana model mampu membedakan kelas positif dan negatif dengan benar. AUC ditemukan dari kurva ROC (Receiver Operating Characteristic). Terdapat berbagai indikator nilai AUC, yaitu sangat baik (0.9 - 1), baik (0.8 - 0.9), cukup (0.7 - 0.8), buruk (0.6 - 0.7) dan tidak memadai (0.6). 3.6 Implementasi Model Random Forest Pada proyek ini, implementasi Random Forest ke dalam sistem dilakukan untuk menciptakan sebuah sistem otomatisasi penyiraman atau irigasi cerdas. Proses ini dimulai dengan menggunakan micromlgen adalah pustaka sumber terbuka yang dikembangkan untuk menghadirkan machine learning ke mikrokontroler. Pada dasarnya, pustaka ini mengubah kode dari model ML seperti Random Forest yang sudah dilatih menjadi kode C++ yang dioptimalkan agar mikrokontroler dapat berjalan. Dalam proses ini, parameter max_depth dari masing-masing nilai akan dipilih berdasarkan hasil kinerja dalam memprediksi dan pengguna memori yang 39 dievaluasi. Hal ini dilakukan untuk mengurangi pengguna memori dan meningkatkan efisiensi komputasi, namun dengan hasil kinerja yang terbaik. 3.7 Hasil Hasil yang diharapkan dari implementasi sistem penyiraman otomatis atau irigasi cerdas menggunakan Random Forest adalah terciptanya sistem prediksi yang akurat mengenai waktu dan kebutuhan air yang tepat untuk penyiraman tanaman. Sistem ini diharapkan dapat menjadi solusi untuk meringankan pekerjaan petani, menjaga dan meningkatkan produktivitas pertanian, hingga mendukung keberlanjutan usaha dalam pertanian.

Disclaimer:

This report must be correctly interpreted and analyzed by a qualified person who bears the evaluation responsibility!

Any information provided in this report is not final and is a subject for manual review and analysis. Please follow the guidelines:
Assessment recommendations

Plagiarism Detector - Your right to know the authenticity! © SkyLine LLC

Plagiarism Detector v. 2942 - Originality Report 6/10/2026 2:17:37 PM

Analyzed document: BAB 4.pdf Licensed to: STIE MDP_License10

Comparison Preset: Rewrite Detected language: Id

Check type: Internet Check

TEE and encoding: PdfPig

Detailed document body analysis:

Relation chart:

Plagiarism 0% Original 100%
Quotes 0% AI 0%



Distribution graph:



Top sources of plagiarism: 1

 0.8% 12 1. <https://www.halodoc.com/artikel/panduan-lengkap-alat-ukur-suhu-udara-terkini>

Processed resources details: 108 - Ok / 4 - Failed

Important notes:

Wikipedia:	Google Books:	Ghostwriting services:	Anti-cheating:
			
[not detected]	[not detected]	[not detected]	[not detected]

UACE: UniCode Anti-Cheat Engine report:

1. Status: Analyzer **On** Normalizer **On** character similarity set to **100%**
2. Detected UniCode contamination percent: **0%** with limit of: 30%
3. Document not normalized: percent not reached 5%
4. All suspicious symbols will be marked in purple color: **Abcd...**
5. Invisible symbols found: 0

Assessment recommendation:

No special action is required. Document is Ok.

Alphabet stats and symbol analyzes:

UACE does not support the doc language! UACE logics skipped!

Active References (Urls Extracted from the Document):

No URLs detected

 Excluded Urls:

No URLs detected

 Included Urls:

No URLs detected

Detailed document analysis:

BAB IV PERANCANGAN 4.1 Spesifikasi Solusi Pada bagian ini menjelaskan beberapa spesifikasi solusi dari sistem otomatisasi penyiraman atau irigasi cerdas yang harus memenuhi fungsi, kinerja, dan karakteristik sesuai standar: 1. Perangkat Keras : a. Beberapa modul atau komponen dalam mikrokontroler seperti model machine learning, wifi, bluetooth, dan lainnya dapat beroperasi. b. Sensor kelembaban tanah, suhu, dan kelembaban udara mampu membaca dan mengirim ke mikrokontroler secara real-time. c. Sistem mampu melakukan prediksi kebutuhan air pada tanaman dengan waktu yang tepat dan menyiram tanaman secara otomatis. d. Sistem ini mengirimkan data sensor ke server untuk disimpan ke dalam database melalui koneksi internet. e. Sistem ini menjalankan perintah dari pengguna dari server dan internet, bahkan koneksi bluetooth untuk mengonfigurasi perangkat. 2. Aplikasi Mobile : a. Aplikasi dapat dijalankan smartphone yang sistem operasi Android dengan versi di atas sama dengan 5.1. b. Aplikasi dapat menghubungkan perangkat keras dengan bluetooth. 40 41 c. Aplikasi dapat menampilkan antarmuka yang berisi informasi tanaman, perangkat, dan pengaturan penyiraman atau irigasi. d. Aplikasi dapat mengelola dan konfigurasi perangkat keras melalui internet dan bluetooth (khusus mengganti nama perangkat keras dan mengatur koneksi wifi). 4.2 Rencana Pengujian Setelah pengembangan sistem selesai, langkah berikutnya adalah pengujian sistem. Pengujian ini sangat penting dilakukan sebelum sistem atau produk digunakan oleh petani. Tahapan ini bertujuan untuk menemukan kesalahan, mengevaluasi kinerja dan kualitas pada sistem atau produk. Dengan pengujian tersebut, dapat memastikan sistem atau produk berfungsi dengan baik dan memenuhi spesifikasi serta standar kebutuhan yang ditetapkan. Pengujian pertama, Random Forest dilakukan untuk mengevaluasi kinerja sebelum diimplementasikan ke mikrokontroler ESP32, sebagaimana dijelaskan pada bagian 3.5 sampai 3.7, pengujian ini menentukan nilai max_depth yang optimal yang dapat menghemat biaya komputasi. Untuk proses pengujian dilakukan dengan mencoba nilai max_depth mulai dari 3 hingga 7, di mana setiap nilai dievaluasi menggunakan metrik seperti akurasi, presisi, recall, f1-score, AUC score, serta ukuran memori model. Hasil dari pengujian dilakukan untuk memilih parameter max_depth yang menghasilkan performa terbaik berdasarkan metrik evaluasi dengan ukuran memori model yang rendah. Untuk pengujian kedua pada perangkat keras dan pengujian ketiga pada aplikasi mobile dilakukan menggunakan metode black box testing. Metode ini 42 berfokus pada analisis hasil input dan output dari sistem tanpa memerlukan pemahaman struktur kode yang mendasar. Pengujian kedua, sensor-sensor akan diuji dari membaca data, keakuratan dan ketahanan kondisi lingkungan. Berbagai modul atau komponen seperti wifi, bluetooth, model Random Forest pada mikrokontroler ESP32 diuji untuk memastikan sistem dapat beroperasi dengan baik. Selain itu, pengujian Random Forest dilakukan untuk memastikan sistem dapat memprediksi waktu dan kebutuhan air pada tanaman yang tepat. Pengujian ketiga, dilakukan pada aplikasi mobile dengan memeriksa modul atau komponen dalam aplikasi, kompatibilitas di berbagai perangkat, serta integrasi paket library yang digunakan. Pengujian ini juga melibatkan proses autentikasi akun seperti proses login dan register. Selain itu, pengujian operasi CRUD (Create, Read, Update, Delete) untuk data sektor dan perangkat keras yang dilakukan. Seluruh proses ini bertujuan untuk memastikan aplikasi memenuhi karakteristik, fungsi, dan kinerja sesuai dengan standar dan kebutuhan petani. 4.3 Perancangan Sistem 4.3.1 Perancangan Aplikasi Mobile Aplikasi mobile memainkan peran penting sebagai antarmuka bagi pengguna dalam memantau dan mengelola irigasi tanaman, serta melakukan konfigurasi perangkat dengan mudah. Desain aplikasi ini menggunakan framework Dart, yaitu Flutter, yang memungkinkan pengembangan aplikasi multiplatform dengan satu baris kode. Flutter memiliki kinerja yang tinggi, responsivitas yang baik, dan 43 antarmuka yang menarik, serta mempermudah dan mempercepat dalam proses pengembangan aplikasi mobile. Aplikasi ini dirancang khusus untuk platform Android, mengingat tingginya jumlah petani yang memanfaatkan smartphone. Selain itu, aplikasi ini akan dilengkapi dengan pustaka Bluetooth Low Energy (BLE), yang memungkinkan koneksi langsung dengan ESP32 untuk melakukan konfigurasi perangkat. Berikut gambar prototipe aplikasi yang dirancang dapat dilihat pada Gambar 4.1. 44 Gambar 4.1 Rancangan Aplikasi Mobile 45 4.3.2 Perancangan Model Random Forest Sesuai dengan penjelasan sebelumnya, metode machine learning merupakan bagian dari teknologi kecerdasan buatan yang memungkinkan mesin untuk mempelajari pola-pola data, kemudian melakukan prediksi dan pengambilan keputusan secara otomatis berdasarkan pola-pola data yang sudah dipelajari. Dalam bidang pertanian penerapan machine learning pada sistem penyiraman atau irigasi tanaman merupakan solusi yang bermanfaat untuk petani dalam merawat tanaman. Gambar 4.2 Rancangan Random Forest Berdasarkan Gambar 4.2, perancangan model ini diawali dengan pengambilan dataset terkait

irigasi. Langkah berikutnya adalah melakukan preprocessing data yang telah dijelaskan pada bagian 3.4. Setelah proses preprocessing selesai, model Random Forest dibangun dengan hyperparameter seperti `max_depth` yang telah ditentukan dan melakukan pengujian berdasarkan penjelasan pada bagian 3.5 dan 3.6.

4.3.3 Perancangan Sistem Perangkat Keras

Perancangan sistem perangkat keras yang penting diawali dengan membangun komponen perangkat keras utama, yaitu:

1. Mikrokontroler ESP32

ESP32 adalah modul mikrokontroler yang memiliki koneksi WiFi dan Bluetooth yang terintegrasi. Mikrokontroler ini memiliki CPU ditenagai Xtensa LX16 dual core. Memori yang digunakan adalah 448 KB ROM, 520 KB SRAM, dua memori RTC 8KB, dan memori flash 4MB. ESP32 memiliki kelebihan yaitu harga yang terjangkau, mempermudah dalam pengembangan, jumlah pin GPIO (General Purpose Input/Output) yang memadai. Selain itu, mikrokontroler ini efisiensi daya dan menghasilkan kesalahan yang rendah (Widyatmika, 2021).

Gambar 4.3 ini menampilkan penampakan mikrokontroler ESP32.

Gambar 4.3 Mikrokontroler ESP32

2. Capacitive Soil Moisture Sensor

Sensor kelembaban tanah adalah alat untuk mengukur kadar air dalam tanah. Alat ini memiliki dua probe yang mengalirkan arus listrik melalui tanah dan mengukur resistansi untuk menentukan kelembaban. Tanah yang basah memiliki resistansi rendah, sedangkan tanah kering memiliki resistansi tinggi, yang menghambat pengantaran listrik (Darmawan, 2020). Dalam perancangan sistem tersebut, berfokus menggunakan sensor tanah yang kapasitif tipe V2.0.

Gambar 4.4 ini menampilkan penampakan sensor tanah yang dipakai.

Gambar 4.4 Sensor Capacitive Soil Moisture Sensor

3. DHT22 Sensor

DHT22 adalah alat sensor untuk mengukur suhu dan kelembaban udara. Sensor ini bekerja dengan memanfaatkan kombinasi dari kapasitor dan termistor untuk mendeteksi kondisi udara, kemudian menghasilkan data melalui pin. DHT22 memiliki tingkat akurasi yang tinggi, kalibrasi otomatis, respons yang cepat dalam proses akuisisi data, serta harga yang terjangkau (Puspasari, 2020).

Gambar 4.5 ini menampilkan penampakan sensor DHT22 yang dipakai.

Gambar 4.5 Sensor DHT22

4. Relay Switch

Relay adalah alat yang berfungsi untuk menggerakkan kontraktor atau sakelar dengan memindahkan posisi hidup dan mati secara otomatis. Proses terbuka dan tertutup pada relay terjadi karena adanya efek induksi magnet yang muncul dari kumparan induksi listrik (Omega, 2023). Hal ini dapat disimpulkan mikrokontroler memberikan instruksi pada relay dengan reaksi untuk menghidupkan dan mematikan pompa air.

Gambar 4.6 ini menampilkan penampakan relay switch yang dipakai untuk mengontrol pompa air irigasi.

Gambar 4.6 Relay

5. Pompa Air

Pompa air dalam sistem irigasi adalah mesin mekanis yang dirancang untuk memindahkan air dari sumbernya, seperti sumur, sungai, atau jaringan air PAM, ke area yang akan disiram. Pompa ini bekerja dengan memanfaatkan sumber daya listrik untuk menarik air dengan tekanan yang cukup dari sumbernya kemudian mendorongnya ke saluran irigasi.

Gambar 4.8 menampilkan pompa air yang digunakan dalam sistem irigasi ini.

Gambar 4.7 Pompa Air

Setelah pembangunan perangkat keras selesai, selanjutnya membangun sistem mikrokontroler dengan menanamkan Random Forest yang telah dilatih ke dalam perangkat ESP32.

Implementasi Random Forest

Random Forest dilakukan sesuai dari penjelasan sebelumnya pada bagian 3.5 sampai 3.7. Skema perancangan sistem perangkat keras dapat dilihat pada Gambar 4.8.

Gambar 4.8 Rancangan Sistem Mikrokontroler ESP32

Gambar 4.9 Cara Kerja Sistem Irigasi Cerdas

Pada Gambar 4.9 menunjukkan cara kerja sistem irigasi cerdas pada perangkat keras. Sensor kelembaban tanah membaca kelembaban tanah sebagai kadar air dalam tanah. Sensor DHT22 membaca suhu udara dan kelembaban udara. Data yang diperoleh dari kedua sensor dikirimkan ke mikrokontroler ESP32 dalam setiap 1 detik (delay 1000 ms). Di dalam mikrokontroler, model Random Forest yang telah dilatih kemudian dikonversi ke dalam C++ dimanfaatkan untuk menganalisis data tersebut dan memprediksi kebutuhan air pada tanaman. Jika diperlukan, sistem akan melakukan penyiraman tanaman secara otomatis. Selama proses penyiraman, data dari sensor tersebut akan dikirimkan ke API untuk disimpan ke dalam database sebagai riwayat penyiraman.

4.4 Proses Verifikasi Perancangan

Tabel 4.1 menyajikan daftar item yang digunakan untuk memverifikasi dalam merancang sistem otomatisasi penyiraman atau irigasi cerdas tanaman.

Tabel 4.1 Penjelasan Atribut Verifikasi Perancangan

No.	Item Verifikasi	Keterangan
1	RandomForestClassifier	✓ yang berbeda melalui teknik bagging dan random feature selection. Menentukan jumlah Decision Tree yang dibangun untuk menghasilkan prediksi akhir.
2	<code>n_estimators</code>	Jumlah pohon yang banyak dapat meningkatkan ✓ akurat prediksi, meskipun memerlukan kebutuhan komputasi yang tinggi. Hyperparameter untuk menentukan kriteria terbaik untuk memisahkan setiap simpul dalam 3 criterion Decision Tree, yaitu pada root node, terminal ✓ node dan leaf node, untuk meminimalkan ketidakmurnian data. Pemilihan kriteria ini
52	No. Item Verifikasi	Keterangan bertujuan memastikan ketepatan pemisahan data dalam model prediksi. Menentukan jumlah fitur acak yang dipilih pada setiap simpul dapat

meningkatkan variasi dan 4 max_features ✓ mengurangi korelasi antar pohon, sehingga model lebih stabil dan generalisasi lebih baik. Mengatur agar Random Forest menggunakan teknik bagging (pengambilan sampel secara acak 5 bootstrap ✓ dengan penggantian), yang meningkatkan variasi setiap Decision Tree. Mengatur max_depth untuk membatasi kedalaman pohon sehingga mengurangi 6 max_depth ✓ kebutuhan komputasi, seperti memori dan waktu pemrosesan, sekaligus mencegah overfitting.

Disclaimer:

This report must be correctly interpreted and analyzed by a qualified person who bears the evaluation responsibility!

Any information provided in this report is not final and is a subject for manual review and analysis. Please follow the guidelines:

Assessment recommendations

Plagiarism Detector - Your right to know the authenticity! ☐ SkyLine LLC

Plagiarism Detector v. 2942 - Originality Report 12/06/2026 13.18.48

Analyzed document: BAB 5.pdf Licensed to: STIE MDP_License10

Comparison Preset: Rewrite Detected language: Id


Check type: Internet Check

TEE and encoding: PdfPig

Detailed document body analysis:

Relation chart:

Plagiarism 4.44% Original 94.21%
Quotes 1.35% AI 0%



Distribution graph:



Top sources of plagiarism: 13

3%	138	1.	https://web-crawler.plagiarism-detector.com/get-doc-pt?did=_kikOla_8zFHlg
3%	138	2.	https://web-crawler.plagiarism-detector.com/get-doc-pt?did=9EinPoa79TNHmQ
2%	58	3.	https://web-crawler.plagiarism-detector.com/get-doc-pt?did=80ekPoy_9jFGnA

Processed resources details: 92 - Ok / 5 - Failed

Important notes:

Wikipedia:	Google Books:	Ghostwriting services:	Anti-cheating:
[not detected]	[not detected]	[not detected]	[not detected]

UACE: UniCode Anti-Cheat Engine report:

- Status: Analyzer **On** Normalizer **On** character similarity set to **100%**
- Detected UniCode contamination percent: **0%** with limit of: 4%
- Document not normalized: percent not reached 5%
- All suspicious symbols will be marked in purple color: **Abcd...**
- Invisible symbols found: 0

Assessment recommendation:
No special action is required. Document is Ok.

Alphabet stats and symbol analyzes:
UACE does not support the doc language! UACE logics skipped!

Active References (Urls Extracted from the Document):

No URLs detected

? Excluded Urls:

No URLs detected

? Included Urls:

No URLs detected

Detailed document analysis:

BAB V IMPLEMENTASI DAN PENGUJIAN 5.1 Implementasi Perancangan 5.1.1 Implementasi Model Tahap ini dilakukan implementasi model dengan proses import library yang akan digunakan untuk preprocessing, implementasi model Random Forest, pengujian menggunakan metrik evaluasi, serta komponen pendukung lainnya. Gambar 5.1 menunjukkan source code yang digunakan dalam proses tersebut. Gambar 5.1 Implementasi Import Library Tahap berikutnya melakukan preprocessing untuk menyiapkan dataset sebelum digunakan dalam proses pelatihan model tersebut. Tahap preprocessing, diawali dengan pemeriksaan missing data, yang ditunjukkan pada Gambar 5.2. 53 54 Gambar 5.2 Implementasi Check Missing Value Kemudian, data tersebut dipisahkan menjadi fitur (x), dan target (y), di mana fitur mencakup kelembaban tanah, suhu udara, dan kelembaban udara, dan target adalah status pompa. Kemudian data dibagi menjadi 80% untuk training data dan 20% untuk testing data. Gambar 5.3 menunjukkan source code yang digunakan dalam proses tersebut. Gambar 5.3 Implementasi Pemisahan Fitur dan Pembagian Data Tahap selanjutnya, training data yang dihasilkan akan dilakukan pengecekan outlier menggunakan boxplot untuk visualisasi, sementara metode Interquartile Range (IQR) untuk validasi. Gambar 5.4 dan Gambar 5.5 menunjukkan source code yang digunakan dalam proses tersebut. 55 Gambar 5.4 Implementasi Visualisasi Boxplot Untuk Deteksi Outlier Gambar 5.5 Implementasi Metode IQR Untuk Deteksi Outlier Selanjutnya, dilakukan analisis keseimbangan kelas dengan membuat distribusi plot, serta tabel informasi yang terdiri dari fitur, jumlah data, dan persentase distribusi kelas, untuk mengidentifikasi ketidakseimbangan kelas berdasarkan selisih antara kelas mayoritas dan minoritas. Gambar 5.6 dan Gambar 5.7 menunjukkan source code yang digunakan untuk mengidentifikasi ketidakseimbangan kelas. 56 Gambar 5.6 Implementasi Analisis Keseimbangan Kelas Gambar 5.7 Implementasi Visualisasi Plot Keseimbangan Kelas Selanjutnya, dilakukan proses pengelompokan data ke dalam kategori berdasarkan kelembaban tanah, suhu udara, kelembaban udara, dan status udara. Gambar 5.8 menunjukkan source code fungsi pengelompokan data, sedangkan Gambar 5.9 menunjukkan source code yang digunakan untuk menampilkan hasil pengelompokan data. 57 Gambar 5.8 Implementasi Fungsi Untuk Pengelompokan Data 58 Gambar 5.9 Implementasi Lanjutan Proses Pengelompokan Data Setelah tahap preprocessing data, dilakukan pengembangan model Random Forest dengan menentukan hyperparameter, seperti $n_estimators = 100$, $criterion =$

Quotes detected: 0,03%

id: 1

'gini',

max_features =

Quotes detected: 0,03%

id: 2

'sqrt',

bootstrap = True, serta variasi nilai max_depth yang dijelaskan sebelumnya. Pada proses tersebut, nilai max_depth diatur dalam rentang 3 hingga 7, di mana setiap variasi tersebut digunakan dalam proses pelatihan 59 metode. Gambar 5.4 menunjukkan source code yang digunakan dalam proses pengembangan dan pelatihan model tersebut. Gambar 5.10 Implementasi Model Random Forest Setelah model dilatih, pengujian dilakukan untuk mengevaluasi kemampuan dalam memprediksi kebutuhan air pada tanaman. Evaluasi dilakukan dengan menggunakan metrik akurasi, classification report, confusion matrix, dan AUC (Area Under Curve). Gambar 5.11 hingga Gambar 5.13 menampilkan perhitungan dan visualisasi hasil pengujian. Gambar 5.11 Implementasi Pengukuran Metrik 60 Gambar 5.12 Implementasi Confusion Matrix Gambar 5.13 Implementasi Pengukuran ROC-AUC Terakhir, melakukan konversi model Random Forest yang telah dilatih dengan nilai max_depth terbaik ke dalam C++, sehingga menghasilkan kode (.h) yang akan diintegrasikan ke dalam sistem. Gambar 5.14 menunjukkan source code yang digunakan dalam proses konversi model Random Forest. 61 Gambar 5.14 Implementasi Konversi Random Forest ke C++ 5.1.2 Implementasi Perangkat Keras Tahap implementasi perangkat keras dilakukan dengan proses perakitan komponen utama, yaitu sensor kelembaban tanah kapasitif, sensor DHT22, mikrokontroler ESP32, relay, dan pompa air. Sementara komponen pendukung yang terdiri dari baterai, panel surya, solar charger controller, step-down, dan kerangka menara sebagai tempat pemasangan perangkat. Perakitan dimulai dengan menghubungkan baterai dan panel surya ke solar charger controller untuk mengatur proses pengisian dan distribusi daya. Output yang dihasilkan akan dihubungkan ke step-down pertama untuk menurunkan tegangan dari 12 V menjadi 7.5 V sebagai suplai daya ke ESP32

melalui breadboard. Sementara itu, step-down kedua digunakan untuk menurunkan tegangan 9.0 V sebagai suplai daya ke pompa air. Berikut konfigurasi pin GPIO pada sensor dan aktuator yang ditunjukkan pada Tabel 5.1. 62 Tabel 5.1 Konfigurasi Pin GPIO pada Sensor dan Aktuator No. Hardware Keterangan GPIO Voltase Capacitive Soil Membaca kondisi kelembaban tanah 1 32 5 V Moisture sebagai kadar air dalam tanah. Membaca suhu udara dan 2 DHT22 22 3 V kelembaban udara. 3 Relay 5V Mengontrol pompa air. 16 5 V Hasil implementasi perangkat keras bagian internal pada sistem irigasi otomatis

 Plagiarism detected: **1,45%** <https://web-crawler.plagiarism-detector.com/ge...> id: **3**

ditunjukkan pada Gambar 5.15 hingga Gambar 5.17. Gambar 5.15 Tampilan Rangkaian Kontrol Internal 63 Gambar 5.16 Tampilan Solar Charge Controller Gambar 5.17 Tampilan Pompa Air Hasil implementasi kerangka perangkat keras bagian outdoor pada sistem irigasi otomatis yang ditempatkan di lahan dapat ditunjukkan pada Gambar 5.

18. 64 Gambar 5.18 Tampilan Kerangka Perangkat Keras Sistem Irigasi Otomatis 5.1.3 Implementasi Database Tahap ini dilakukan implementasi database yang telah dirancang untuk menyimpan dan mengambil data melalui server, sehingga memungkinkan pengguna mengakses data dari jarak jauh. Hasil implementasi database yang menampilkan tabel dan relasi antar tabel dapat dilihat pada Gambar 5.19. 65 Gambar 5.19 Implementasi Desain Database Tabel users digunakan untuk menyimpan informasi akun pengguna dalam proses session dan autentikasi, sehingga pengguna dapat mengakses data yang berelasi serta layanan lainnya seperti MQTT. Selanjutnya, tabel sectors digunakan untuk menyimpan informasi lokasi atau area penempatan perangkat. Dalam satu sektor terdapat beberapa perangkat keras yang dapat dikelompokkan berdasarkan area tersebut. Selanjutnya, tabel devices digunakan untuk menyimpan informasi perangkat keras yang terdiri dari identitas perangkat, lokasi atau sektor yang dipilih, status, dan state perangkat. Terakhir, tabel irrigation histories digunakan untuk menyimpan riwayat penyiraman tanaman, baik secara otomatis maupun manual berdasarkan tipe 66 penyiraman, data sensor, dan tanggal riwayat tersebut. Satu perangkat dapat menghasilkan riwayat irigasi pada tanaman. 5.1.4 Implementasi Layanan Cloud Hosting Tahap implementasi layanan cloud hosting dengan jenis Virtual Private Server (VPS) dilakukan untuk menempatkan API Laravel, MySQL database server, dan Mosquitto MQTT broker agar penyimpanan data serta layanan dapat diakses oleh perangkat dan aplikasi client melalui internet. Sistem ini menggunakan sistem operasi Linux Ubuntu 24.04 dengan spesifikasi yang sudah dijelaskan sebelumnya. Untuk konfigurasi sistem dilakukan melalui CloudPanel, yang menyediakan layanan database berupa MySQL. Tampilan halaman utama yang berisi informasi dan pengaturan server pada Hostinger ditunjukkan pada Gambar 5.20. Gambar 5.20 Tampilan Halaman Ringkasan pada Admin Hostinger Proses implementasi dimulai dengan menginstal Mosquitto MQTT broker yang berperan sebagai server protokol machine-to-machine untuk mengatur pengiriman data dari publisher dan penerimaan data dari subscriber secara real- 67 time. Broker ini memiliki keunggulan, yaitu bandwidth dan komputasi yang ringan, latensi rendah, serta konektivitas yang baik. Instalasi Mosquitto dimulai dengan menjalankan perintah

 Quotes detected: **0,17%** id: **4**

```
'sudo apt install mosquitto mosquitto-clients -y'.
```

Selanjutnya, konfigurasi dilakukan dengan membuka berkas melalui perintah

 Quotes detected: **0,12%** id: **5**

```
'sudo nano /etc/mosquitto/mosquitto.conf'
```

untuk memastikan parameter listener 1883 dan allow_anonymous true sudah diatur, sebagaimana ditunjukkan pada Gambar 5.21. Gambar 5.21 Tampilan Konfigurasi Mosquitto MQTT Broker Setelah konfigurasi selesai, layanan tersebut dijalankan menggunakan perintah

 Quotes detected: **0,12%** id: **6**

```
'sudo systemctl start mosquitto'.
```

Sementara itu, perintah

 Quotes detected: **0,12%** id: **7**

```
'sudo systemctl enable mosquitto'
```

dilakukan agar layanan tersebut dapat berjalan secara otomatis saat VPS melakukan booting atau restart. Status aktivasi layanan Mosquitto MQTT broker dapat dilihat pada Gambar 5.22. 68 Gambar 5.22 Tampilan Status Mosquitto MQTT Broker Selanjutnya, implementasi Laravel

dilakukan dengan mengunggah berkas ke server melalui menu File Manager pada CloudPanel dalam format .zip, kemudian berkas tersebut diekstrak ke direktori

Quotes detected: **0,09%** id: 8
'files/htdocs/srv894639.hstgr.cloud'

Plagiarism detected: **1,3%** <https://web-crawler.plagiarism-detector.com/ge...> + 7 id: 9
yang dapat dilihat pada Gambar 5.23. 69 Gambar 5.23 Tampilan File Manager berisi Laravel pada CloudPanel Setelah implementasi Laravel selesai, tahap selanjutnya membuat dan mengonfigurasi database dengan memasukan nama database, username, dan password. Hasil database yang sudah ditambahkan dapat dilihat pada Gambar 5.

24. Gambar 5.24 Tampilan Konfigurasi Database MySQL pada CloudPanel Pengembangan Laravel dilakukan dengan membuat komponen utama yang terdiri dari model, controller, migration, console command, dan route. Controller berperan sebagai unit kendali yang memproses permintaan pengguna dan mengirim data dalam bentuk response berupa status code maupun status code yang disertai data dalam format JSON. Controller yang dibuat terdiri dari Auth Controller untuk 70 proses autentikasi seperti login dan register. User Controller untuk mengubah profile dan password pengguna. Sector Controller digunakan untuk menyimpan, mengupdate, dan menghapus sektor atau lokasi lahan. Device Controller digunakan untuk menyimpan, mengupdate seperti perubahan nama dan pemindahan sektor, serta menghapus perangkat keras. Sementara itu, Irrigation Histories Controller digunakan untuk menampilkan riwayat irigasi yang dapat difilter berdasarkan device id dan tanggal. File kelas controller yang sudah dibuat ditunjukkan pada Gambar 5.25. Gambar 5.25 File Kelas Controller pada Laravel Model berperan sebagai representasi dari tabel dalam database, yang dibuat terdiri dari User, Sector, Device, dan Irrigation Histories. Sementara itu, migration digunakan untuk membuat struktur database pada setiap tabel. Kemudian, proses pembuatan tabel dilakukan dengan perintah

Quotes detected: **0,09%** id: 10
'php artisan migrate'.

File model dan migration yang telah dibuat dapat dilihat pada Gambar 5.26 dan Gambar 5.27. 71 Gambar 5.26 File Kelas Model pada Laravel Gambar 5.27 File Migration pada Laravel Console command digunakan untuk menjalankan proses tertentu dengan perintah kustom. Salah satu command yang dibuat untuk menerima data dari MQTT broker secara real-time dan menyimpan data ke dalam database. File console command yang telah dibuat dapat dilihat pada Gambar 5.28. Gambar 5.28 File Kelas Console Command MqttWorker 72 Selanjutnya, membuat file konfigurasi agar command dapat berjalan secara otomatis saat VPS melakukan booting atau restart. File tersebut dibuat menggunakan perintah

Quotes detected: **0,17%** id: 11
'sudo vim /etc/supervisor/conf.d/mqtt-subcriber-worker.conf',

kemudian mengisi sesuai yang ditunjukkan pada Gambar 5.29. Gambar 5.29 File Konfigurasi Supervisor MqttWorker Setelah konfigurasi selesai, proses console command dijalankan menggunakan perintah

Quotes detected: **0,14%** id: 12
'sudo supervisorctl start "mqtt-subcriber-worker:*"'.

Sementara itu, route dibuat yang terdiri dari autentikasi seperti login dan register menggunakan metode POST. Route user menggunakan metode PATCH untuk mengubah profile maupun password. Route sektor dan perangkat menggunakan metode POST, PATCH, dan DELETE, sedangkan route untuk menampilkan riwayat irigasi tanaman menggunakan metode GET. 5.2 Pengujian 5.2.1 Pengujian Model Pengujian ini dilakukan dengan menganalisis pengaruh max_depth terhadap kemampuan dalam memprediksi air pada tanaman, serta kompleksitas yang 73 berdampak pengguna memori. Nilai max_depth akan diuji dalam rentang 3 hingga 7 secara terpisah untuk melihat perbedaan performa dan kebutuhan komputasi. Memilih parameter terbaik didasarkan pada performa yang diukur melalui metrik akurasi, precision, recall, f1-score, confusion matrix, dan AUC (Area Under Curve). Akan tetapi, efisiensi pengguna memori menjadi pertimbangan dalam pemilihan parameter tersebut, dikarenakan keterbatasan memori pada mikrokontroler. Tabel 5.2 Analisis Performa Random Forest pada Variasi Max Depth Max Depth Accuracy Precision Recall F1-Score AUC 3 99.83 99.83 99.83 99.83 99.72 4 99.83 99.83 99.83 99.83 99.77 5 99.83 99.83 99.83 99.83 99.74 6 99.83 99.83 99.83 99.83 99.77 7 99.83 99.83

99.83 99.83 99.79 Tabel 5.2 menunjukkan parameter max_depth yang bervariasi tidak memberikan peningkatan signifikan terhadap performa model dalam memprediksi kebutuhan air pada tanaman pada data pengujian, karena menghasilkan nilai metrik seperti akurasi, precision, recall, dan f1-score secara konsisten sebesar 99.83%. Meskipun nilai AUC (Area Under Curve) mengalami sedikit peningkatan, yang tidak memberikan dampak terhadap kinerja model. Sementara itu, dalam data pelatihan, max_depth = 3 hingga 5 menghasilkan akurasi sebesar 99.96%, sedangkan max_depth = 6 dan 7 menghasilkan akurasi sebesar 100%. 74 Gambar 5.30 Kurva ROC-AUC pada Variasi Max Depth 75 Gambar 5.31 Confusion Matrix pada Variasi Max Depth Gambar 5.31 menunjukkan setiap max_depth yang meningkat menghasilkan klasifikasi yang sama, dengan TP (True Positive) sebesar 297, False Negative (FN) sebesar 1, FP (False Positive) sebesar 0, dan TN (True Negative) sebesar 302. 76 Tabel 5.3 Analisis Konsumsi Memori Random Forest pada Variasi Max Depth Max Depth Memory Size 3 94 KB 4 137 KB 5 184 KB 6 216 KB 7 251 KB Tabel 5.3 menunjukkan peningkatan nilai max_depth yang menyebabkan kenaikan konsumsi memori secara signifikan. Hal ini disebabkan seiring kedalaman pohon keputusan, semakin besar kompleksitas model sehingga memori yang dibutuhkan akan meningkat. Hasil ini dapat disimpulkan peningkatan nilai max_depth tidak dapat meningkatkan kemampuan model Random Forest dalam memprediksi kebutuhan air pada tanaman pada testing data, karena nilai seperti akurasi, precision, recall, dan f1-score tetap konsisten. Meskipun akurasi dalam data pelatihan dan AUC (Area Under Curve) mengalami peningkatan, namun tidak meningkatkan kemampuan generalisasi model tersebut. Hal ini dapat dilihat pada Gambar 5.17 menunjukkan confusion matrix secara konsisten menghasilkan klasifikasi yang sama. Sementara itu, peningkatan max_depth dapat meningkatkan kompleksitas model tersebut sehingga konsumsi memori juga meningkat. Maka dari itu nilai max_depth = 3 dipilih sebagai parameter terbaik yang memberikan performa dalam memprediksi yang setara dengan kompleksitas yang memengaruhi konsumsi memori. 77 5.2.2 Pengujian Aplikasi Berikut menunjukkan hasil berbagai aspek pengujian pada aplikasi mobile yang dapat dilihat pada Tabel 5.4. Tabel 5.4 Hasil Pengujian Aplikasi Mobile No Aspek Pengujian Hasil Pengujian Status Memasukkan email dan password dengan benar dan 1 Approved berhasil akses ke halaman utama. Menampilkan halaman utama seperti nama user, daftar sektor dan perangkat, menu 2 Approved sektor manager dan tombol add, hingga navigasi bawah home dan profile. 78 No Aspek Pengujian Hasil Pengujian Status Menampilkan menu sektor 3 Approved manager. Menampilkan menu tambah 4 Approved sektor dan perangkat Menampilkan halaman kelola sektor yang terdiri dari menu tambah dan pengaturan, serta 5 Approved daftar sektor yang terdiri dari nama dan jumlah perangkat yang terdaftar. 79 No Aspek Pengujian Hasil Pengujian Status Menampilkan form tambah sektor, menambah sektor 6 baru, serta menampilkan Approved notifikasi jika berhasil maupun gagal. Menampilkan menu 7 pengaturan yang terdiri dari Approved opsi edit, hapus, dan batal. 80 No Aspek Pengujian Hasil Pengujian Status Menampilkan form edit sektor, mengubah nama 8 sektor, dan notifikasi Approved ditampilkan jika berhasil maupun gagal. Menghapus sektor yang 9 dipilih, serta notifikasi jika Approved berhasil maupun gagal. 81 No Aspek Pengujian Hasil Pengujian Status Menampilkan halaman untuk memulai proses penambahan perangkat dengan menampilkan daftar 10 perangkat hasil pemindaian, Approved kemudian memilih perangkat yang ditambahkan, serta menampilkan notifikasi jika berhasil maupun gagal. Menampilkan form yang terdiri dari ssid dan password Wi-Fi, memproses koneksi 11 Approved Wi-Fi, serta menampilkan notifikasi jika berhasil maupun gagal. 82 No Aspek Pengujian Hasil Pengujian Status Menampilkan form nama perangkat, kemudian mengubah nama perangkat 12 Approved yang baru ditambahkan, serta menampilkan notifikasi jika berhasil maupun gagal. Menampilkan form sektor, melakukan pemilihan sektor untuk perangkat yang telah ditambahkan, serta 13 Approved menampilkan notifikasi jika berhasil maupun gagal. User dapat melewati tahap ini dengan sektor default. 83 No Aspek Pengujian Hasil Pengujian Status Menampilkan halaman dashboard atau detail 14 Approved perangkat, serta data sensor dan kontrol. Menekan tombol untuk pengaturan perangkat seperti 15 Approved mengubah dan menghapus perangkat. 84 No Aspek Pengujian Hasil Pengujian Status Menampilkan form dan 16 mengubah nama perangkat, Approved serta notifikasi ditampilkan. Menampilkan form dan mengganti jaringan wifi pada 17 Approved perangkat, serta menampilkan notifikasi. 85 No Aspek Pengujian Hasil Pengujian Status Menampilkan form dan memindahkan sektor pada 18 Approved perangkat, serta menampilkan notifikasi. Menghapus perangkat keras, 19 serta menampilkan notifikasi Approved jika berhasil maupun gagal. 86 No Aspek Pengujian Hasil Pengujian Status Menampilkan halaman riwayat irigasi yang terdiri 20 dari daftar riwayat, tanggal, Approved dan tombol filter berdasarkan tanggal. Melakukan filter riwayat 21 Approved irigasi berdasarkan tanggal. 5.2.3 Pengujian Perangkat Keras Tabel 5.5 menunjukkan hasil dari berbagai aspek

pengujian pada perangkat keras yang dapat dilihat sebagai berikut. 87 Tabel 5.5 Hasil Pengujian Perangkat Keras No Aspek Pengujian Hasil Pengujian Status Inisialisasi dan eksekusi Sistem berhasil menginisialisasi dan menjalankan layanan Wi-Fi, Bluetooth, dan 1 layanan Wi-Fi, Bluetooth, dan MQTT pada saat Approved MQTT saat startup dan startup dan reboot secara otomatis. reboot. Sensor capacitive soil Sensor capacitive soil moisture dan DHT22 moisture dan DHT22 dapat membaca dan mengirim data ke ESP32 dengan 2 Approved membaca serta mengirim baik, meliputi data kelembaban tanah, suhu, dan data ke ESP32. kelembaban udara. ESP32 dapat menjalankan ESP32 berhasil menjalankan model Random model Random Forest untuk Forest, sehingga mampu memprediksi kebutuhan 3 Approved memprediksi kebutuhan air air pada tanaman berdasarkan data yang diperoleh pada tanaman. dari sensor. ESP32 mengirim data Sistem berhasil mengirim data kelembaban tanah, kelembaban tanah, suhu 4 suhu udara, dan kelembaban udara melalui mqtt Approved udara, kelembaban udara publish. melalui mqtt publish. ESP32 menerima perintah untuk mengaktifkan dan Sistem berhasil menerima perintah untuk 5 menonaktifkan model dalam mengaktifkan dan menonaktifkan model dalam Approved memprediksi kebutuhan air memprediksi kebutuhan air pada tanaman. pada tanaman. ESP32 menerima perintah Sistem berhasil menerima perintah untuk memulai untuk menyiram tanaman penyiraman tanaman manual selama 15 detik, 6 manual selama 15 detik dan Approved kemudian mengirim data riwayat irigasi ke mengirim data riwayat irigasi database. ke database. ESP32 menerima perintah Sistem berhasil menerima perintah untuk 7 untuk menghentikan Approved menghentikan penyiraman tanaman secara manual. penyiraman tanaman. 88 5.2.4 Pengujian Kepuasan Aplikasi Tahap pengujian kepuasan produk dilakukan untuk memastikan produk mampu menyelesaikan masalah yang diangkat. Penilaian tersebut dilaksanakan dengan menyebarkan kuesioner kepada organisasi di bidang pertanian, kemudian hasil akan dihitung menggunakan skala Likert untuk mengetahui tingkat kepuasan pengguna. Tabel 5.6 menjelaskan indikator penilaian skala Likert sebagai berikut. Tabel 5.6 Keterangan Penilaian Skala Likert Skala Keterangan

Plagiarism detected: 0,43% <https://web-crawler.plagiarism-detector.com/ge...> + 3 id: 13

1 Sangat Tidak Setuju 2 Tidak Setuju 3 Biasa Saja 4 Setuju 5 Sangat Setuju

Perhitungan total skor Likert dilakukan dengan menjumlahkan hasil perkalian antara jumlah responden pada setiap kategori skala Likert dengan nilai skala masing-masing kategori. Total skor Likert dapat dihitung dengan persamaan (5.1). $\sum \text{skor} = \sum (\text{jumlah responden} \times \text{nilai skala})$ (5.1) di mana $\sum$ adalah jumlah responden dan skor adalah penilaian skala Likert. Setelah mendapatkan total skor Likert, selanjutnya menghitung nilai maksimum dengan menggunakan persamaan (5.2). $\text{skor maksimum} = \text{jumlah responden} \times \text{nilai maksimum}$ (5.2) di mana skor maksimum adalah nilai maksimum. Langkah terakhir, persentase skor Likert dapat dihitung melalui persamaan (5.3). $\text{persentase skor} = \frac{\text{skor total}}{\text{skor maksimum}} \times 100\%$ (5.3) di mana persentase skor adalah persentase skor. Tabel 5.7 menyajikan kriteria penilaian skor Likert dalam bentuk persentase. Tabel 5.7 Kriteria Skor Likert No Skor Kriteria Keterangan 1 81% - 100% Sangat Setuju 2 61% - 80% Setuju 3 41% - 60% Biasa Saja 4 21% - 40% Tidak Setuju 5 0% - 20% Sangat Tidak Setuju Tabel 5.8 Analisis Penilaian Pengguna Sangat Pertanyaan Kriteria Tidak Biasa Sangat No Tidak Setuju Skor Penilaian Setuju Saja Setuju Setuju Apakah aplikasi mudah 1 0 0 0 2 3 23 digunakan? Apakah aplikasi sudah 2 berjalan baik secara fungsi 0 0 0 2 3 23 dan logika? Apakah desain User Interface 3 pada aplikasi sudah

Plagiarism detected: 2% <https://web-crawler.plagiarism-detector.com/ge...> + 2 id: 14

0 0 0 4 1 21 memuaskan? Apakah sistem perangkat keras mampu memproses 4 data sensor dan menentukan 0 0 0 3 2 22 kebutuhan air tanaman secara otomatis? Apakah sistem perangkat 5 keras berjalan dengan stabil 0 0 0 3 2 22 dan lancar? 90 Sangat Pertanyaan Kriteria Tidak Biasa Sangat No Tidak Setuju Skor Penilaian Setuju Saja Setuju Setuju Apakah desain hardware 6 0 0 0 4

1 21 sudah memuaskan? Apakah implementasi aplikasi dan hardware mampu 7 0 0 0 5 0 20 menyelesaikan permasalahan irigasi tanaman? Tabel 5.9 Analisis Penilaian Persentase Skala Likert No Pertanyaan Kriteria Penilaian Skor Kriteria Keterangan 1 Apakah aplikasi mudah digunakan? 92% Sangat Setuju Apakah aplikasi sudah berjalan baik secara fungsi 2 92% Sangat Setuju dan logika? Apakah desain User Interface pada aplikasi sudah 3 84% Sangat Setuju memuaskan? Apakah sistem perangkat keras mampu 4 memproses data sensor dan menentukan 88% Sangat Setuju kebutuhan air tanaman secara otomatis? Apakah sistem perangkat keras berjalan dengan 5 88% Sangat Setuju stabil dan lancar? 6 Apakah desain hardware sudah memuaskan? 84% Sangat Setuju Apakah implementasi aplikasi dan hardware 7 mampu menyelesaikan permasalahan irigasi 80% Setuju tanaman? 91 5.3 Analisis Aspek Pengujian 5.3.1

Analisi Aspek Ekonomis Selama proses penelitian dan pengembangan sistem, total biaya yang dikeluarkan melebihi Rp 859.000, yang disebabkan oleh kendala pada sistem seperti cacat produksi dan short. Tidak hanya itu, biaya cloud server VPS dengan paket KVM 2 mengalami perubahan harga di mana harga pembelian pertama sebesar Rp 215.229/bulan, sementara perpanjangan dikenakan harga normal sebesar Rp 345.009/bulan, sehingga total biaya dikeluarkan selama 5 bulan mencapai Rp 1.595.625. 5.3.2 Analisa Aspek Manufakturabilitas Proses penilaian dan pengembangan produk dilakukan selama 5 bulan 1 minggu, dengan rincian waktu untuk setiap tahapan dapat dilihat pada Tabel 5.10. Tabel 5.10 Hasil Analisis Aspek Manufakturabilitas Aspek Waktu Pengerjaan Membangun Perangkat Keras 1 Bulan Membangun Kecerdasan Buatan 2 Minggu Membangun Database 1 Minggu Membangun REST API Laravel 2 Minggu Membangun Aplikasi Android 3 Bulan Total Waktu Pengerjaan 5 Bulan 1 Minggu 92 5.3.3 Analisa Aspek Sustainabilitas Hasil penilaian terhadap aspek sustainabilitas menunjukkan produk mampu berfungsi dengan baik, sehingga memberikan dan mempertahankan manfaat bagi pengguna sesuai dengan kriteria yang ditetapkan. Tabel 5.11 menyajikan hasil analisis aspek terhadap sustainabilitas. Tabel 5.11 Hasil Analisis Aspek Sustainabilitas Aspek Status Sistem membaca data kelembaban tanah, suhu udara, dan kelembaban udara dari sensor ✓ dalam 2 detik Sistem melakukan prediksi kebutuhan air pada ✓ tanaman dalam 2 detik

Disclaimer:

This report must be correctly interpreted and analyzed by a qualified person who bears the evaluation responsibility!

Any information provided in this report is not final and is a subject for manual review and analysis. Please follow the guidelines:
Assessment recommendations

Plagiarism Detector - Your right to know the authenticity! © SkyLine LLC

Plagiarism Detector v. 2942 - Originality Report 6/10/2026 2:23:27 PM

Analyzed document: BAB 6.pdf Licensed to: STIE MDP_License10

[?](#) Comparison Preset: Rewrite [?](#) Detected language: Id[?](#) Check type: Internet Check

TEE and encoding: PdfPig

Detailed document body analysis:


[?](#) Relation chart:

Plagiarism 0%

Original 100%

Quotes 0%

AI 0%

[?](#) Distribution graph:[?](#) Top sources of plagiarism: 0[?](#) Processed resources details: 63 - Ok / 1 - Failed[?](#) Important notes:

Wikipedia:	Google Books:	Ghostwriting services:	Anti-cheating:
			
[not detected]	[not detected]	[not detected]	[not detected]

[?](#) UACE: UniCode Anti-Cheat Engine report:

1. Status: Analyzer **On** Normalizer **On** character similarity set to **100%**
2. Detected UniCode contamination percent: **0%** with limit of: 30%
3. Document not normalized: percent not reached 5%
4. All suspicious symbols will be marked in purple color: **Abcd...**
5. Invisible symbols found: 0

Assessment recommendation:

No special action is required. Document is Ok.

Alphabet stats and symbol analyzes:

UACE does not support the doc language! UACE logics skipped!

[?](#) Active References (Urls Extracted from the Document):

No URLs detected

[?](#) Excluded Urls:

No URLs detected
 Included Urls:
No URLs detected

 Detailed document analysis:

BAB VI KESIMPULAN Berdasarkan hasil penelitian serta proses pengembangan dan implementasi sistem yang dilakukan, dapat disimpulkan sebagai berikut: 1. Hyperparameter pada Random Forest, seperti max_depth dapat memengaruhi kinerja prediksi dan kompleksitas model, yang berdampak pada kebutuhan komputasi. 2. Setiap parameter max_depth menunjukkan tidak ada perubahan atau peningkatan hasil kinerja dalam memprediksi dengan mempertahankan akurasi, precision, recall, f1-score masing-masing sebesar 99.83%, serta hasil klasifikasi pada confusion matrix yang tetap konsisten, meskipun nilai AUC mengalami kenaikan. 3. Random Forest dengan parameter max_depth = 3 dipilih sebagai konfigurasi parameter terbaik yang menghasilkan akurasi, precision, recall, f1-score masing-masing sebesar 99.98%, serta AUC sebesar 99.72%. Selain itu, model membutuhkan memori yang lebih rendah sebesar 94 KB dibandingkan dengan variasi max_depth. Selain itu, terdapat beberapa saran yang bisa dijadikan sebagai bahan perbaikan dan peningkatan apabila dilakukan penelitian dengan topik serupa di masa mendatang, yaitu: 1. Pengembangan dataset irigasi khusus untuk wilayah Indonesia, mengingat letak geografis setiap negara memiliki karakteristik tanah yang beragam dapat 93 94 memengaruhi kebutuhan irigasi tanaman. Saat ini, ketersediaan dataset irigasi berdasarkan kondisi tanah di Indonesia masih minim.

Disclaimer:

This report must be correctly interpreted and analyzed by a qualified person who bears the evaluation responsibility!

Any information provided in this report is not final and is a subject for manual review and analysis. Please follow the guidelines:
[Assessment recommendations](#)

Plagiarism Detector - Your right to know the authenticity!  SkyLine LLC