


BAB III

METODOLOGI

Pada bagian ini, metodologi penelitian memiliki peran penting dalam memulai suatu penelitian dan pengembangan produk. Metodologi ini memberikan kerangka sistematis yang mencakup setiap tahapan yang harus dilalui, sehingga mendapatkan solusi dan tujuan yang diharapkan. Gambar 3.1 mengilustrasikan proses penelitian dan pengembangan produk yang dilakukan.



Gambar 3.1 Alur Metodologi Penelitian

3.1 Identifikasi Masalah

Identifikasi masalah adalah memainkan peran yang krusial sebelum merancang sebuah sistem. Tahapan ini dilakukan dengan mengeksplorasi berbagai masalah dari sumber seperti jurnal penelitian dan berita. Di samping itu, masalah juga didapatkan dari pengalaman pribadi dalam menghadapi tantangan dalam

menyiram tanaman. Untuk menemukan dan memverifikasi masalah tersebut dilakukan wawancara dengan berbagai narasumber yang ahli dalam pertanian.

Dari hasil masalah yang didapatkan, petani mengalami kesulitan dalam menyiram tanaman karena metode pengelolaan tanaman masih dilakukan secara tradisional dan memiliki berbagai keterbatasan waktu, tenaga, dan sumber daya manusia. Metode ini menjadi masalah serius yang menyebabkan kegagalan panen dan mengurangi produktivitas pertanian, sehingga petani mengalami kerugian dan dapat mengancam keberlangsungan usaha.

3.2 Analisis Solusi

Analisis solusi pada Bab 2 yang akan dievaluasi lebih lanjut dengan membandingkan akurasi, ketangguhan terhadap kualitas data yang beragam, biaya implementasi terkait kebutuhan komputasi. Hal ini dilakukan untuk menentukan metode mana yang terbaik, berdasarkan kemampuan mempelajari pola, memprediksi hasil yang akurat. Kebutuhan komputasi juga dilihat, namun bersifat opsional dan harus melihat spesifikasi mikrokontroler terlebih dahulu.

Hasil akhir yang ditentukan *Random Forest* dipilih karena menghasilkan akurasi terbaik sebesar 99,98% (IORLIAM, 2022). Sedangkan *K-Nearest Neighbors* dan *Support Vector Machine* menghasilkan akurasi sebesar 99,3% (Kaur, 2024). Hal ini membuktikan metode ini lebih unggul pada kemampuan generalisasi dan melakukan prediksi waktu dan kebutuhan air pada tanaman untuk menyiram tanaman secara otomatis.

3.3 Pengumpulan Data

Pengumpulan data memiliki peran penting dalam membangun machine learning untuk mempelajari pola data sebelum melakukan prediksi dan pengambilan keputusan. Dataset ini diambil dari penelitian yang dilakukan (Kaur, 2024) yang tersedia di *Mendeley Data* dan dapat diakses <https://data.mendeley.com/datasets/fpdwmm7nrb/1>. Dataset ini berisi 3000 sampel yang berisi kelembaban tanah, temperatur, dan kelembaban udara digunakan sebagai fitur data. Sedangkan target klasifikasi yaitu kondisi pompa, yaitu 0 dan 1. Tabel 3.1 menjelaskan karakteristik dan atribut pada data irigasi tanaman.

Tabel 3.3 Penjelasan Atribut pada Data Irigasi

Atribut	Tipe Data	Keterangan
<i>Soil Moisture</i>	<i>float64</i>	Data kelembaban tanah yang bernilai 314,511 – 984,828.
<i>Temperature</i>	<i>float64</i>	Data suhu udara yang bernilai 28,443 – 38,992.
<i>Air Humidity</i>	<i>float64</i>	Data kelembaban udara yang bernilai 59,367 – 81,267.
<i>Pump Data</i>	<i>int64</i>	Label klasifikasi kondisi pompa dengan status 0 dan 1.

3.4 Pengembangan Model

3.4.1 *Preprocessing Data*

Preprocessing data adalah langkah penting dalam mengelola data sebelum melatih metode *machine learning*. Tahapan ini dimulai dengan mencari *missing data*. Ada tiga jenis missing data, yaitu hilang sepenuhnya secara acak (*missing*

completely at random), hilang secara acak (*missing at random*), dan hilang tidak secara acak (*missing not at random*). Gambar 3.2 menunjukkan analisis jumlah sampel data yang terindikasi missing data pada setiap fitur.

Jumlah sampel yang terindikasi missing value
pada fitur data:

Fitur Data	Jumlah missing
Soil Moisture	0
Temperature	0
Air Humidity	0
Pump Data	0

Gambar 3.2 Jumlah Missing Value Pada Fitur Data


Hasil analisis tersebut menunjukkan, fitur kelembaban tanah, suhu udara, dan kelembaban udara memiliki sampel data yang hilang, sehingga tidak diperlukan proses penanganan terhadap missing data.

Selanjutnya, memilih fitur (X), yaitu kelembaban tanah, suhu udara, dan kelembaban udara, sedangkan target (y) adalah status pompa. Data kemudian dibagi menjadi 80% untuk *training* dan 20% untuk *testing* data. Gambar 3.3 menunjukkan *training* data memiliki 2400 sampel dengan 3 fitur, sedangkan *testing* data memiliki 600 sampel.

```
x_train shape (features): (2400, 3)
y_train shape (targets): (2400,)
X_test shape (features): (600, 3)
y_test shape (targets): (600,)
```


Gambar 3.3 Hasil Pembagian Data *Training* dan *Testing*

Data *training* digunakan untuk melatih model *machine learning*. Untuk data *training* dilakukan pengecekan *outlier* menggunakan *matplotlib* dan ketidakseimbangan data dapat dilihat melalui distribusi *plot*.



Gambar 3.4 Identifikasi Outlier Menggunakan Boxplot

Gambar 3.4, hasil identifikasi menunjukkan setiap fitur tidak terindikasi *outlier* karena masih didalam batas *whisker*. Selain itu, distribusi data masih normal, dengan median yang relatif seimbang didalam rentang *interquartile (IQR)*. Oleh karena itu, penerapan *preprocessing* tambahan tidak diperlukan.



Gambar 3.5 Analisis Keseimbangan Data Menggunakan Plot

Gambar 3.5 menunjukkan kelas target memiliki perbedaan sedikit, hal ini dibuktikan distribusi kelas target 0 mempunyai jumlah 1133 dengan persentase 52,79%, dan 1 mempunyai jumlah 1271 artinya hanya 55,8%. sehingga tidak

diperlukan penanganan *imbalance*. Tabel 3.5 menyajikan distribusi kelas target berdasarkan jumlah dan persentase.

Tabel 3.5 Distribusi Kelas Target

Target	Jumlah	Persentase
0 (ON)	1133	52.79%
1 (OFF)	1267	47.21%

Dalam evaluasi kemampuan model dalam memprediksi status pompa dilakukan berdasarkan kondisi yang sudah dikategorikan dari data sensor. Sensor tersebut menghasilkan nilai dalam bentuk sinyal analog yang kemudian diubah menjadi sinyal digital menggunakan ADC (*Analog to Digital Converter*), sehingga data dari sensor dapat dibaca oleh sistem. Tabel 3.4 menyajikan nilai sensor dan kondisi kelembaban, yang dijelaskan oleh (Rosyid, 2022).

Tabel 3.6 Kategori pada Kelembaban Tanah

Nilai ADC	Kondisi
289 - 397	Sangat Basah
398 – 507	Basah
508 – 617	Normal
618 - 726	Kering
≥ 727	Sangat Kering

Tabel 3.5 menyajikan nilai sensor dan kondisi suhu udara, yang dijelaskan oleh (Pradana, 2023).

Tabel 3.7 Kategori pada Suhu Udara

Nilai ADC	Kondisi
$\leq 23^{\circ}\text{C}$	Dingin
$24^{\circ}\text{C} - 30^{\circ}\text{C}$	Normal
$\geq 31^{\circ}\text{C}$	Panas

Tabel 3.6 menyajikan nilai sensor dan kondisi kelembaban udara, yang dijelaskan oleh (Kusnadi, 2023).

Tabel 3.8 Kategori pada Kelembaban Udara

Nilai ADC	Kondisi
$\leq 55\%$	Kering
$\geq 56\%$	Lembab

Terakhir, untuk kelas klasifikasi disesuaikan dengan kategori kelembaban tanah, suhu udara, dan kelembaban udara yang dijelaskan dalam tabel. Namun kelembaban tanah adalah unsur yang memengaruhi terhadap pertumbuhan tanaman. Oleh karena itu, status kelas 1 sebagai *OFF* dan 0 sebagai *ON*. Gambar 3.6 menunjukkan hasil pengelompokan data irigasi ke dalam kategori yang telah dijelaskan sebelumnya.

Soil Moisture	Soil Moisture Category	Temperature	Temperature Category	Air Humidity	Air Humidity Category	Pump Data	Pump Data Category
904.010567	Sangat Kering	36.437388	Panas	45.943540	Kering	0	Hidup
712.948906	Kering	27.784112	Normal	72.418063	Lembab	0	Hidup
936.291835	Sangat Kering	31.569001	Panas	74.514258	Lembab	0	Hidup
968.903367	Sangat Kering	38.965269	Panas	54.469896	Kering	0	Hidup
324.277473	Sangat Basah	26.030362	Normal	76.347692	Lembab	1	Mati
913.180235	Sangat Kering	18.312291	Dingin	55.694261	Lembab	0	Hidup
513.896668	Normal	26.844001	Normal	38.437523	Kering	1	Mati
438.570864	Basah	34.798523	Panas	59.963820	Lembab	1	Mati
479.149079	Basah	35.376513	Panas	58.645799	Lembab	1	Mati
756.236072	Sangat Kering	38.409771	Panas	78.450592	Lembab	0	Hidup
362.667297	Sangat Basah	38.242742	Panas	54.790690	Kering	1	Mati
604.454506	Normal	20.007003	Dingin	72.031064	Lembab	1	Mati
883.084539	Sangat Kering	27.054185	Normal	63.933662	Lembab	0	Hidup
763.805514	Sangat Kering	34.644965	Panas	78.417435	Lembab	0	Hidup
936.624424	Sangat Kering	30.076570	Panas	68.188881	Lembab	0	Hidup
634.688173	Kering	38.773692	Panas	58.171497	Lembab	1	Mati
809.420996	Sangat Kering	24.281108	Normal	41.160053	Kering	0	Hidup

Gambar 3.6 Hasil Pengelompokan Data Irigasi

3.4.2 Rancangan *Random Forest*

Perancangan *Random Forest* menggunakan bahasa pemrograman *Python* dan *library sklearn* untuk memudahkan dalam pengembangan model. Implementasi *RandomForestClassifier* dengan *hyperparameter tuning* seperti *n_estimators* = 100, *criterion* = 'gini', *max_features* = 'sqrt', dan *bootstrap* = *True*. Secara umum, *Random Forest* membangun *Decision Tree* tanpa pemangkasan atau dibatasi. Namun, peningkatan pohon dapat meningkatkan kebutuhan komputasi. Untuk menghemat kebutuhan komputasi dapat dilakukan dengan *hyperparameter tuning* seperti *max_depth* (Akbar, 2023). Dalam proyek ini, *hyperparameter max_depth* ditentukan dalam rentang nilai 3 hingga 7.

Berdasarkan penelitian yang dilakukan oleh (Oktafiani, 2024), *Random Forest* dengan $max_depth = 3$ mencapai akurasi 86,34%, $max_depth = 4$ mencapai akurasi 86,34%, nilai 5 mencapai akurasi 91,70%, $max_depth = 6$ mencapai akurasi 97,07%, dan $max_depth = 7$ mencapai akurasi 98,53%.

Penelitian yang dilakukan oleh (Baig, 2022) menunjukkan *hyperparameter* diatur dengan $max_depth = 3$ menghasilkan akurasi 97,96%, presisi 98,18%, *recall* 86,66%, *AUC* 0,932, dan waktu pelatihan 0,22 detik. $Max_depth = 4$ yang diatur menghasilkan akurasi 97,82%, presisi 99,79%, *recall* 84,21%, *AUC* 0,971, dan waktu pelatihan 0,259 detik. $Max_depth = 5$ yang diatur menghasilkan akurasi 99,14%, presisi 99,30%, *recall* 94,36%, *AUC* 0,971, dan waktu pelatihan 0,38 detik. $Max_depth = 6$ yang diatur menghasilkan akurasi 99,47%, presisi 99,60%, *recall* 96,53%, *AUC* 0,982, dan waktu pelatihan 0,44 detik.

3.5 Pengujian

Pengujian dilakukan untuk memvalidasi kemampuan metode ini dalam menganalisis pola dan melakukan prediksi yang akurat sebelum mengintegrasikan ke dalam sistem. Parameter dalam pengujian menggunakan pengukuran metrik seperti *confusion matrix*, akurasi, presisi, *recall*, *f1-score*, dan *AUC score*.

Confusion matrix adalah sebuah alat yang menyajikan informasi komparatif mengenai hasil klasifikasi yang dilakukan oleh sistem dengan membandingkan hasil klasifikasi yang sebenarnya dan model yang digunakan.

		Actual Values	
		Positive (1)	Negative (0)
Predicted Values	Positive (1)	TP	FP
	Negative (0)	FN	TN

Gambar 3.7 Confusion Matrix

TP (True Positive) mencerminkan jumlah prediksi yang benar untuk data positif, sedangkan *TN (True Negative)* mencerminkan jumlah prediksi yang benar untuk data negatif. Di sisi lain, *FP (False Positif)* menunjukkan jumlah prediksi yang salah untuk data positif, sementara *FN (False Negative)* menggambarkan jumlah prediksi yang salah untuk data negatif. Kedua kondisi ini menunjukkan adanya kesalahan dalam memprediksi pola data.

Akurasi adalah ukuran yang menunjukkan seberapa kemampuan prediksi yang benar secara keseluruhan. Akurasi dapat dihitung dengan persamaan (3.1).

$$Accuracy = \frac{T_p + T_n}{T_p + T_n + F_p + F_n} \quad (3.1)$$

Presisi untuk mengukur seberapa kemampuan model dalam memprediksi kelas positif dengan benar dari keseluruhan kelas positif. Presisi dapat hitung dengan persamaan (3.2).

$$Precision = \frac{T_p}{T_p + F_p} \quad (3.2)$$

Recall untuk mengukur sejauh mana kemampuan model dalam prediksi yang benar untuk kelas positif dari data positif secara keseluruhan. *Recall* dapat dihitung dengan persamaan (3.3).

$$Recall = \frac{T_p}{T_p + F_n} \quad (3.3)$$

F1-score adalah alat ukur yang menggambarkan keseimbangan antara presisi dan recall. *F1-score* dapat dihitung melalui persamaan (3.4).

$$F1 - score = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (3.4)$$

AUC (Area Under Curve) score untuk mengevaluasi sejauh mana model mampu membedakan kelas positif dan negatif dengan benar. *AUC* ditemukan dari kurva *ROC (Receiver Operating Characteristic)*. Terdapat berbagai indikator nilai *AUC*, yaitu sangat baik (0.9 - 1), baik (0.8 - 9), cukup (0.7 – 0.8), buruk (0.6 – 0.7) dan tidak memadai (<0.6).

3.6 Implementasi Model *Random Forest*

Pada proyek ini, implementasi *Random Forest* ke dalam sistem dilakukan untuk menciptakan sebuah sistem otomatisasi penyiraman atau irigasi cerdas. Proses ini dimulai dengan menggunakan *micromlgen* adalah pustaka sumber terbuka yang dikembangkan untuk menghadirkan *machine learning* ke mikrokontroler. Pada dasarnya, pustaka ini mengubah kode dari model *ML* seperti *Random Forest* yang sudah dilatih menjadi kode *C++* yang dioptimalkan agar mikrokontroler dapat berjalan.

Dalam proses ini, parameter *max_depth* dari masing-masing nilai akan dipilih berdasarkan hasil kinerja dalam memprediksi dan pengguna memori yang

dievaluasi. Hal ini dilakukan untuk mengurangi pengguna memori dan meningkatkan efisiensi komputasi, namun dengan hasil kinerja yang terbaik.

3.7 Hasil

Hasil yang diharapkan dari implementasi sistem penyiraman otomatis atau irigasi cerdas menggunakan *Random Forest* adalah terciptanya sistem prediksi yang akurat mengenai waktu dan kebutuhan air yang tepat untuk penyiraman tanaman. Sistem ini diharapkan dapat menjadi solusi untuk meringankan pekerjaan petani, menjaga dan meningkatkan produktivitas pertanian, hingga mendukung keberlanjutan usaha dalam pertanian.