

PROPOSAL TUGAS AKHIR

PERANCANGAN SISTEM OTOMATISASI PENYIRAMAN
TANAMAN MENGGUNAKAN METODE MACHINE
LEARNING



Oleh:

Kevin Pratama 2024250070

PROGRAM STUDI INFORMATIKA
FAKULTAS ILMU KOMPUTER DAN REKAYASA
UNIVERSITAS MULTI DATA PALEMBANG
PALEMBANG
2024

PROPOSAL TUGAS AKHIR
PERANCANGAN SISTEM OTOMATISASI PENYIRAMAN
TANAMAN MENGGUNAKAN METODE
MACHINE LEARNING

HALAMAN PENGESAHAN

Disusun Oleh :

Kevin Pratama

NPM 2024250070

Disetujui Oleh :

Menyetujui,
Dosen Pembimbing Utama

Mengetahui,
Ketua Program Studi Informatika

Dedy Hermanto, S.Kom., M.T.I.
NIK.

Derry Alamsyah, S.Si., M.Kom., M.Pd.
NIK. 111069

KATA PENGANTAR

Dengan ini saya mengucapkan puji syukur kepada Tuhan Yang Maha Esa atas segala rahmat dan karunia, yang telah memungkinkan saya sebagai penulis untuk menyelesaikan Proposal Tugas Akhir dengan judul “Perancangan Sistem Otomatisasi Penyiraman Tanaman Menggunakan Metode Machine Learning”

Saya ingin mengucapkan terima kasih kepada semua pihak yang telah membantu saya dalam proses penulisan proposal ini, baik secara langsung maupun tidak langsung. Terima kasih juga kepada mereka yang telah memberikan bimbingan, arahan, dan ide selama proses penulisan proposal Tugas Akhir, terutama kepada:

1. Bapak Dr. Johannes Petrus, S.Kom., M.T.I., selaku Rektor Universitas Multi Data Palembang.
2. Ibu Yulistia, S.Kom., M.T.I., selaku Wakil Rektor I Universitas Multi Data Palembang.
3. Ibu Kathryn Sugara, S.E., M.Si., selaku Wakil Rektor II Universitas Multi Data Palembang.
4. Bapak Dedy Hermanto, S. Kom., M.T.I., selaku Wakil Rektor III Universitas Multi Data Palembang.
5. Ibu Charisma Ayu P, M.HRM., selaku Wakil Rektor IV Universitas Multi Data Palembang.
6. Bapak Dr. Wijang Widhiarso, M.Kom., selaku Dekan Fakultas Ilmu Komputer dan Rekayasa.
7. Ibu Yoanita, M.Kom. Wakil Dekan Fakultas Ilmu Komputer dan Rekayasa
8. Bapak Derry Alamsyah, S.Si., M.Kom., M.Pd., selaku Ketua Program Studi informatika
9. Bapak Daniel Udjulanawa, S.Kom.,M.T.I., selaku Pembimbing Akademik.
10. Bapak Dedy Hermanto, S. Kom., M.T.I., selaku Pembimbing tugas akhir yang telah memberikan arahan, saran, dan motivasi yang sangat berharga dalam proses penyusunan Proposal Tugas Akhir.

11. Keluarga dan teman-teman yang telah memberikan dukungan dan saran selama proses pengerjaan tugas akhir.
12. Terima kasih kepada Aldo Kadafi, Muhammad Fadli dan Kartiva yang telah membantu saya menyelesaikan proposal saya ini.

Laporan ini diharapkan dapat memberikan solusi yang efektif dan mengurangi beban permasalahan yang dihadapi oleh masyarakat, sekaligus memberikan panduan yang berguna bagi mahasiswa Universitas Multi Data Palembang dan Universitas lainnya dalam menyusun Tugas Akhir yang lebih baik di masa depan.

Palembang, 18 Maret 2024

Penulis

DAFTAR ISI

HALAMAN JUDUL	I
HALAMAN PENGESAHAN	II
KATA PENGANTAR.....	III
DAFTAR ISI.....	V
DAFTAR TABEL	VII
DAFTAR GAMBAR	VIII
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	6
1.3 Analisis Terhadap Batasan	6
1.3.1 Analisis dari Aspek Ekonomis	6
1.3.2 Analisis dari Aspek Manufakturabilitas	8
1.3.3 Analisis dari Aspek Sustainbilitas	9
1.4 Analisis Terhadap Karakteristik Solusi	10
1.5 Pemilihan Solusi	11
1.6 Skenario Pemanfaatan Produk Oleh Pengguna.....	14
1.7 Tujuan.....	14
BAB II PEMILIHAN SOLUSI	15
2.1 Alternatif Solusi	15
2.1.1 K-Nearest Neighbors	15
2.1.2 Support Vector Machine	17
2.1.3 Random Forest.....	21
2.2 Analisis Pemilihan Solusi	25
BAB III METODOLOGI	28

3.1	Identifikasi Masalah	28
3.2	Analisis Solusi.....	29
3.3	Pengumpulan Data	30
3.4	<i>Preprocessing</i> Data	31
3.5	Perancangan <i>Random Forest</i>	32
3.6	Pengujian.....	33
3.7	Implementasi Model <i>Random Forest</i>	35
3.8	Hasil	35
BAB IV PERANCANGAN.....		37
4.1	Spesifikasi Solusi	37
4.2	Rencana Pengujian	38
4.3	Perancangan Sistem	38
4.3.1	Perancangan Aplikasi Mobile.....	38
4.3.2	Perancangan Model Random Forest	39
4.3.3	Perancangan Sistem Perangkat Keras	40
4.4	Proses Verifikasi Perancangan	43
DAFTAR PUSTAKA.....		50
LAMPIRAN.....		53

DAFTAR TABEL

Tabel 1.1 Analisis dari Aspek Ekonomis.....	6
Tabel 1.2 Analisis dari Aspek Manufakturabilitas	8
Tabel 1.3 Analisis dari Aspek Ekonomis.....	9
Tabel 1.4 Analisis dari Karakteristik Solusi.....	10
Tabel 2.1 Analisis Pemilihan Solusi.....	25
Tabel 3.1 Penjelasan Atribut pada Data Irigasi	30
Tabel 4.1 Rencana Pengujian Data <i>Preparation</i>	Kesalahan! Bookmark tidak ditentukan.
Tabel 4.2 Rencana Pengujian Model <i>Random Forest</i>	Kesalahan! Bookmark tidak ditentukan.
Tabel 4.3 Rencana Pengujian Sistem ESP32	Kesalahan! Bookmark tidak ditentukan.
Tabel 4.4 Rencana Pengujian <i>REST API Laravel</i>	Kesalahan! Bookmark tidak ditentukan.
Tabel 4.5 Rencana Pengujian Aplikasi Mobile	Kesalahan! Bookmark tidak ditentukan.

DAFTAR GAMBAR

Gambar 2.1 K-Nearest Neighbors.....	16
Gambar 2.2 Support Vector Machine.....	18
Gambar 2.3 Random Forest	23
Gambar 3.1 Alur Metodologi Penelitian	28

BAB I

PENDAHULUAN

1.1 Latar Belakang

Pertanian adalah suatu kegiatan yang dilakukan oleh individu atau kelompok dengan memanfaatkan sumber daya alam untuk menghasilkan berbagai jenis bahan baku yang diperlukan untuk memenuhi kebutuhan dasar serta kebutuhan tambahan bagi manusia (Kynta, 2024). Salah satu cabang dari sektor pertanian adalah hortikultura, yang mencakup penanaman tanaman di kebun atau halaman rumah untuk memenuhi kebutuhan sehari-hari akan produk segar, seperti sayur-sayuran, buah-buahan, dan tanaman hias (Bharata, 2023).

Jumlah rumah tangga yang terlibat dalam pertanian pada tahun 2023 mengalami peningkatan menjadi 8,74%, yang setara dengan 28.419.398 rumah tangga. Namun demikian, sektor hortikultura justru mengalami penurunan sebesar 10,44%, dengan total 9.495.675 rumah tangga (Badan Pusat Statistik, 2023). Hal ini menunjukkan bahwa pertanian memiliki peranan yang krusial dalam perekonomian negara serta memenuhi kebutuhan masyarakat dan industri.

Tanaman hortikultura dapat ditanam baik di daratan rendah maupun tinggi. Meskipun demikian, para petani masih mengandalkan musim hujan sebagai waktu yang tepat untuk memulai penanaman (Makmur, 2023). Hal ini disebabkan oleh kelembaban tanah yang sangat penting untuk menentukan ketersediaan air yang sangat dibutuhkan untuk tanaman (Hermanto, 2023).

Berbagai elemen dapat memengaruhi kondisi ini, di antaranya adalah curah hujan, tipe tanah, dan tingkat evapotranspirasi (Hermanto, 2023). Proses

evapotranspirasi terdiri dari dua komponen utama, yaitu evaporasi, yang merupakan perubahan air menjadi uap, dan transpirasi, yang mengacu pada penguapan air dari permukaan tanah (Sofia, 2023). Tingkat evapotranspirasi sangat dipengaruhi oleh faktor-faktor iklim serta jenis tanaman yang ada (Fausan, 2021). Oleh karena itu, ketersediaan air dan kelembaban tanah menjadi aspek yang krusial untuk menggantikan air yang hilang selama proses ini.

Dengan demikian, pengendalian dan pemantauan kelembaban lahan sangat penting untuk memastikan hasil panen yang optimal. Kelembaban tanah yang tidak sesuai dapat menghambat pertumbuhan tanaman bahkan berisiko menyebabkan kegagalan panen (Hermanto, 2023). Untuk memenuhi kebutuhan air dan kelembaban pada tanaman, penyiraman perlu dilakukan dengan mempertimbangkan tingkat kelembaban tanah (Subagja, 2023).

Di berbagai wilayah, proses penyiraman tanaman masih dilakukan secara manual dengan menggunakan alat sederhana. Apabila jumlah tanaman yang dirawat cukup besar, sering kali timbul kesulitan dalam mendistribusikan air dengan merata. Selain itu, pemilik tanaman sering kali terpaksa meninggalkan tanaman dalam kurung waktu yang lama tanpa pengawasan, yang dapat berpotensi mengakibatkan kematian tanaman akibat kurangnya perawatan yang diperlukan (Hasani, 2023).

Tantangan lebih lanjut muncul ketika mereka mengalami kesulitan dalam memprediksi kelembaban tanah secara akurat akibat perubahan cuaca yang mendadak (Ningrum, 2023). Hal ini disebabkan oleh metode pengukuran yang masih dilakukan secara visual dengan menggunakan alat sederhana, yang tidak mampu memberikan data secara real-time (Firmansyah, 2023). Mereka sering

bergantung pada pengalaman pribadi untuk menentukan waktu dan jumlah air yang dibutuhkan dalam proses penyiraman tanaman (Anggarda, 2023).

Hasil wawancara dengan Syamsul Bahri, selaku pemilik Toko Panen Raya Cinde menjelaskan bahwa tantangan utama petani seperti ketidakpastian musim, peningkatan hama, dan keterbatasan air sering mengakibatkan kegagalan panen. Hal ini berdampak pada penurunan pendapatan dan motivasi petani, terutama di daerah dengan akses air yang sulit, mengancam keberlangsungan usaha pertanian.

Hasil wawancara dengan Havizman, SP., M.Si., selaku kepala bidang produksi Dinas Perkebunan Sumatera Selatan, mengungkapkan bahwa petani kesulitan memantau suhu dan kapasitas air tanah karena keterbatasan peralatan. Penyiraman manual juga memerlukan biaya tenaga kerja tinggi, yang sering menyebabkan ketidakakuratan pengaturan air, sehingga tanaman rentan terhadap penyakit dan pertumbuhan terhambat.

Hasil wawancara dengan Kemas Muhammad Ridhuan, selaku penyuluh pertanian UPTD Balai Pengembangan Dan Produksi Benih Tanaman Pangan Dan Hortikultura, menunjukkan bahwa petani sering kali menghadapi kesulitan dalam memantau musim dan kelembaban tanah secara manual. Metode ini dianggap tidak efisien dan sangat bergantung pada fisik. Ketergantungan pada teknik tradisional ini sering kali berujung kegagalan panen dan krisis ekonomi, terutama dengan adanya pengaruh fenomena alam seperti El Nino, yang semakin memperburuk efisiensi dan akurasi dalam pengelolaan tanaman.

Hasil wawancara dengan Lili Rozali, S.Kom., SP, selaku kasubbag umum dan kepegawaian Dinas Pertanian Tanaman Pangan dan Hortikultura Provinsi Sumatera

Selatan menjelaskan bahwa petani mengalami tantangan dalam memprediksi cuaca, yang berdampak pada akurasi pemantauan tanaman. Metode manual untuk memeriksa kadar air tanah dan pembuatan saluran air yang efisien dan memakan banyak waktu serta tenaga. Akibatnya, pemantauan dan penyiraman manual menjadi sering tidak tepat dalam pemberian air dan pemupukan, sehingga pertumbuhan tanaman tidak optimal dan efisiensi waktu petani menurun.

Hasil wawancara dengan Denny Satria Mandala Putra, selaku direktur Quranic Farm menjelaskan bahwa pemantauan kelembaban tanah secara konvensional tidak akurat dan memerlukan banyak tenaga, sedangkan penyiraman manual sering tidak merata, terutama di musim kemarau. Akibatnya, pertumbuhan tanaman menjadi tidak seragam dan risiko penyakit tanaman meningkat. Pemantauan secara manual yang memakan waktu juga mengganggu aktivitas lain di perkebunan yang cukup besar.

Hasil wawancara dengan Ir. Sahat Simanjuntak, M.Si. selaku manajer penjualan regional di CV. Jaya Agung, mengungkapkan bahwa petani menghadapi tantangan dalam pengelolaan tanaman manual, terutama terkait keterbatasan sumber air, kebutuhan tenaga kerja, dan waktu pemantauan serta penyiraman. Proses manual dianggap tidak efisien penggunaan air, pemborosan tenaga kerja, dan meningkatkan biaya operasional.

Dalam beberapa tahun terakhir, kemajuan teknologi *Internet of Things* dan kecerdasan buatan memberikan dampak yang signifikan pada berbagai sektor pertanian. Salah satu teknologi yang diimplementasikan dalam bidang pertanian adalah *Machine Learning*, yang merupakan bagian dari kecerdasan buatan yang

melibatkan proses pembelajaran melalui komputasi dan identifikasi pola untuk melakukan prediksi serta pengambilan keputusan secara otomatis berdasarkan data yang tersedia (Anggarda, 2023).

Konsep sistem irigasi cerdas didasarkan pada *Internet of Things*, yang memanfaatkan sensor *Automatic Weather Station* (AWS), kelembaban tanah, dan berbagai faktor lingkungan lainnya. Setiap sensor menghasilkan data yang dikirimkan ke mikrokontroler untuk analisis atau prediksi (Kaur, 2024). Dengan memanfaatkan *Machine Learning*, sistem ini dapat memprediksi kebutuhan penyiraman dan memberikan rekomendasi terkait waktu serta volume air yang diperlukan, berdasarkan dataset yang mencakup informasi mengenai cuaca hujan, suhu udara, kelembaban tanah, dan faktor-faktor lainnya (Anggarda, 2023).

Pengembangan sistem irigasi cerdas seperti prediksi penyiraman yang memanfaatkan *Machine Learning* untuk memprediksi waktu penyiraman optimal memiliki berbagai keuntungan. Pertama, sistem ini dapat menghemat waktu dan usaha petani dalam memerlukan kebutuhan air. Kedua, dengan tingkat akurasi prediksi yang tinggi, sistem ini berkontribusi dalam mengoptimalkan penggunaan air dan mengurangi pemborosan. Ketiga, rekomendasi yang akurat dari sistem ini dapat meningkatkan produktivitas pertanian dengan memastikan pemenuhan kebutuhan air yang tepat waktu untuk tanaman (Anggarda, 2023).

Secara keseluruhan, dapat disimpulkan bahwa sistem irigasi cerdas yang memanfaatkan teknologi *Internet of Things* dan *Machine Learning* memberikan keuntungan signifikan bagi para petani. Sistem ini memungkinkan pemantauan, pengendalian, dan perencanaan irigasi yang lebih efisien dalam waktu, tenaga, dan

sumber daya manusia, serta berpotensi mengurangi biaya dan penggunaan air, dan meningkatkan hasil panen. Dengan demikian, penulis tertarik untuk merancang sebuah sistem yang dapat membantu petani di masa yang akan datang.

1.2 Rumusan Masalah

Analisis menunjukkan bahwa petani menghadapi tantangan signifikan dalam pengelolaan irigasi akibat metode penyiraman dan pemantauan cuaca yang konvensional serta keterbatasan alat. Hal ini sering menyebabkan kesalahan dalam penggunaan air, mengakibatkan pemborosan sumber daya dan mengurangi produktivitas serta berkelanjutan usaha pertanian.

1.3 Analisis Terhadap Batasan

1.3.1 Analisis dari Aspek Ekonomis

Aspek ekonomi menganalisis keterbatasan dalam pengembangan produk tersebut untuk pengembang dan pengguna. Tujuannya adalah menetapkan harga produk berdasarkan biaya pengembangan dan manfaat pengguna. Perencanaan biaya mencakup harga perangkat keras antara Rp 200.000 hingga Rp 800.000 dan biaya langganan bulanan antara 10.000 hingga 50.000. Tabel 1.1 menyajikan hasil kesepakatan masing-masing organisasi terkait produk yang akan dipasarkan.

Tabel 1.1 Analisis dari Aspek Ekonomis

No.	Organisasi	Aspek Ekonomis
1	Toko Panen Raya	Biaya perangkat keras berkisar Rp 600.000 hingga Rp 800.000, tetapi bagi petani, diupayakan untuk semurah mungkin, bahkan gratis. Untuk layanan

		berlangganan diperkirakan sekitar Rp 20.000 per bulan
2	Dinas Perkebunan Provinsi Sumatera Selatan	Harga perangkat keras diusulkan antara Rp 300.000 – Rp 500.000, sedangkan biaya langganan berkisar antara Rp 15.000 – Rp 30.000 per bulan.
3	UPTD Balai Pengembangan dan Produksi Benih Tanaman Pangan dan Hortikultura	Rekomendasi harga jual belum dapat diberikan karena masih diperlukan evaluasi perangkat keras dan perangkat lunak melalui dinas pertanian serta pengujian produk melalui demonstrasi.
4	Dinas Pertanian Tanaman Pangan dan Hortikultura	Penentuan harga hardware belum bisa dilakukan karena sistem masih harus dipertimbangkan akurasi, kompleksitas, dan manfaat bagi petani, serta kebutuhan perangkat smartphone dan kualitas internet. Saat ini, layanan berlangganan yang diusulkan adalah Rp 10.000 per bulan.
5	Qur'anic Farm	Menentukan harga perangkat keras belum dipastikan karena biaya harus sepadan dengan manfaat yang diberikan bagi petani. Namun, untuk biaya langganan, disarankan sebesar Rp 20.000 per bulan.
6	CV Jaya Agung	Harga untuk perangkat keras ditetapkan sebesar Rp 300.000, sementara biaya berlangganan adalah Rp 10.000 per bulan.

Tabel 1.1 menunjukkan bahwa biaya perangkat keras yang diusulkan bervariasi antara Rp 300.000 hingga Rp 800.000, dengan beberapa usulan lebih

rendah atau tanpa biaya. Biaya layanan berlangganan diusulkan antara Rp 10.000 hingga Rp 30.000 per bulan, optimal di sekitar Rp 20.000. Penetapan harga ini perlu evaluasi lebih lanjut untuk memastikan keseimbangan biaya dan manfaat bagi petani. Produk harus didemo dan diuji coba sebelum harga akhir ditetapkan.

1.3.2 Analisis dari Aspek Manufakturabilitas

Aspek manufakturabilitas memainkan peranan krusial dalam penetapan jadwal yang realistis untuk pengembangan produk. Hal ini mencakup penentuan batas waktu yang harus diikuti untuk menyelesaikan produk dengan efisien. Tabel 1.2 memberikan penjelasan mengenai hasil jadwal pengembangan produk yang telah ditentukan oleh masing-masing organisasi.

Tabel 1.2 Analisis dari Aspek Manufakturabilitas

Aspek	Toko Panen Raya	Dinas Perkebunan Provinsi Sumatera Selatan	UPTD Balai Pengembangan dan Produksi Benih Tanaman Pangan dan Hortikultura	Dinas Pertanian Tanaman Pangan dan Hortikultura	Dinas Pertanian Tanaman Pangan dan Hortikultura	CV. Jaya Agung
Membangun Perangkat Keras (1 Bulan)	✓	✓	✓	✓	✓	✗
Membangun Database (3 Minggu)	✓	✓	✓	✓	✓	✗
Membangun Aplikasi (1 Bulan)	✓	✓	✓	✓	✓	✓

Implementasi Kecerdasan Buatan (1 Bulan)	✓	✓	✓	✓	✓	✓
Membangun Server (1 Bulan)	✓	✓	✓	✓	✓	✓
Final (1 Bulan)	✓	✓	✓	✓	✓	✓

Pada Tabel 1.2 menunjukkan bahwa sebagian besar organisasi setuju dengan jadwal pengembangan produk yang mencakup berbagai tahapan. Namun, CV. Jaya Agung berpendapat bahwa jadwal pembangunan perangkat keras harus disesuaikan dengan kebutuhan petani, seperti luas lahan yang diawasi, dan waktu pembangunan database harus mempertimbangkan data yang diperlukan petani.

1.3.3 Analisis dari Aspek Sustainbilitas

Aspek sustainbilitas bertujuan untuk menilai sejauh mana produk dapat bertahan dalam penggunaannya, dengan harapan untuk meningkatkan dan menjaga citra produk. Untuk memulai proses evaluasi berkelanjutan, pengguna akan diberikan kesempatan untuk melakukan uji coba gratis selama dua bulan. Tabel 1.3 menguraikan hasil kesepakatan yang ditetapkan oleh setiap organisasi.

Tabel 1.3 Analisis dari Aspek Ekonomis

Aspek	Toko Panen Raya	Dinas Perkebunan Provinsi Sumatera Selatan	UPTD Balai Pengembangan dan Produksi Benih Tanaman	Dinas Pertanian Tanaman Pangan dan Hortikultura	Dinas Pertanian Tanaman Pangan dan Hortikultura	CV Jaya Agung
-------	-----------------------	--	---	--	---	------------------

			Pangan dan Hortikultura			
Sistem irigasi cerdas dapat digunakan selama 2 bulan	✓	✓	✓	✓	✓	✓

1.4 Analisis Terhadap Karakteristik Solusi

Pada Tabel 1.4 akan menjelaskan mengenai tantangan yang dihadapi oleh para petani serta solusi yang telah ditemukan untuk mengatasi tantangan tersebut.

Tabel 1.4 Analisis dari Karakteristik Solusi

No.	Masalah	Fungsi
1	Petani kesulitan menghadapi tantangan dalam mengukur kelembaban dan kondisi cuaca secara manual.	Sistem ini memanfaatkan sensor kelembaban tanah dan sensor cuaca secara otomatis dan real-time untuk memberikan data yang akurat.
2	Ketika jumlah tanaman yang disiram sangat banyak, petani mengalami kesulitan menyiram tanaman secara merata	Sistem ini dapat mendistribusi air secara merata ke seluruh tanaman dengan menghubungkan jaringan air dan pompa yang sudah dirancang.
3	Risiko kehilangan tanaman akibat kekurangan perawatan dan perhatian yang memadai, terutama saat petani tidak berada di lokasi dalam jangka waktu lama.	Sistem ini menggunakan teknologi <i>Internet of Things</i> memungkinkan petani dapat merawat tanaman secara jarak jauh dan kecerdasan buatan untuk merencanakan penyiraman secara otomatis.
4	Metode pemeliharaan tanaman yang bersifat tradisional memerlukan waktu, tenaga, dan	Sistem kombinasi <i>Internet of Things</i> dan kecerdasan buatan seperti <i>machine learning</i> dapat mengubah metode pemeliharaan tradisional menjadi modern, meningkatkan

	biaya yang cukup besar, serta dapat menurunkan produktivitas pertanian.	efisiensi waktu, tenaga, dan biaya serta produktivitas pertanian.
5	Para petani kesulitan menyiram tanaman berdasarkan kebutuhan air pada tanaman.	Penerapan kecerdasan buatan memungkinkan sistem ini memberikan rekomendasi dan melakukan penyiraman secara otomatis.

1.5 Pemilihan Solusi

Dalam perancangan sistem irigasi cerdas, terdapat tiga metode machine learning yang akan dipertimbangkan, yaitu *K-Nearest Neighbors* (KNN), *Support Vector Machine* (SVM), dan *Random Forest* (RF). Pemilihan metode ini akan didasarkan pada tinjauan jurnal penelitian terkait yang menjelaskan penggunaan masing-masing metode. Penelitian tersebut mengkaji berbagai aspek seperti karakteristik dataset, *preprocessing* data, dan *hyperparameter tuning*.

Penelitian yang pertama kali dilakukan oleh (Tace, 2022) untuk mengembangkan sistem irigasi cerdas berbasis IoT dan *machine learning* yang dapat menghemat air dan biaya. Data diperoleh dari sensor mengukur kelembaban tanah, suhu udara, kelembaban, serta curah hujan. Metode *K-Nearest Neighbors* dengan $k = 3$ menunjukkan akurasi sebesar 98,3% dan RMSE 0,12.

Penelitian yang kedua dilakukan oleh (Singh, 2022) menunjukkan bahwa penerapan metode *Random Forest* (RF) hanya mencapai akurasi sebesar 85%, *precision* 88%, *recall* 82%, dan *f1-score* 85%. Sementara itu, metode *Support Vector Machine* (SVM) menghasilkan kinerja yang lebih baik dengan akurasi 90%,

precision 92%, *recall* 88%, dan *f1-score* 90%. Dalam sistem penyiraman yang diterapkan, terdapat dua kelas label klasifikasi, yaitu *on* dan *off*.

Penelitian yang ketiga dilakukan oleh (Mohammed, 2023) memanfaatkan dataset yang mencakup beberapa variabel lingkungan seperti kelembaban tanah, suhu, dan kelembaban udara, pH tanah, dan jenis tanaman. Dataset tersebut digunakan untuk melakukan klasifikasi kebutuhan irigasi dengan lima kategori: *highly not needed*, *not needed*, *average*, *needed*, dan *highly needed*. Metode *K-Nearest Neighbors* dengan nilai $k = 5$ dan *euclidean distance* menghasilkan akurasi sebesar 98,6% dan RMSE sebesar 0,10, menunjukkan kinerja yang baik dalam memprediksi kebutuhan irigasi tanaman.

Penelitian yang keempat dilakukan oleh (Mujawar, 2024) bertujuan untuk memantau dan memprediksi kebutuhan air pada lahan pertanian padi. Sistem ini dirancang untuk mengoptimalkan irigasi berdasarkan kondisi lingkungan secara real-time dengan harapan dapat meningkatkan produktivitas pertanian padi. Parameter utama yang digunakan dalam penelitian ini meliputi kelembaban tanah, suhu, kelembaban udara, dan tingkat ketinggian air. Hasil penelitian menunjukkan bahwa SVM menghasilkan akurasi sebesar 93,2%, sementara RF menunjukkan akurasi sebesar 86,5%, mengindikasikan bahwa SVM memiliki performa yang lebih baik dalam memprediksi kebutuhan irigasi pada skenario ini.

Penelitian kelima yang dilakukan oleh (Kaur, 2024) menggunakan data yang diperoleh dari sensor kelembaban tanah, suhu, kelembaban udara, dan aktivitas pompa. Data tersebut dibagi menjadi 80% untuk pelatihan dan 20% untuk pengujian. Hasil penelitian ini menunjukkan bahwa metode RF mencapai akurasi

sebesar 99,8%, sementara metode SVM dengan *kernel linear* dan KNN dengan *manhattan distance* dan $k = 5$ masing-masing mencapai akurasi 99,3%. Hal ini menunjukkan bahwa *Random Forest* sedikit lebih unggul dalam hal akurasi dibandingkan metode SVM dan KNN dalam skenario ini.

Penelitian keenam yang dilakukan oleh (Rafrin, 2024) menggunakan data yang mencakup *soil moisture*, *temperature*, dan *humidity*, dengan label yang terbagi menjadi tiga kelas yang terdiri dari 1.387 sampel data. Data tersebut dibagi menjadi 70% untuk pelatihan dan 30% untuk pengujian. Metode *Random Forest* dengan 100 pohon, *min_samples_split*: 2, dan *gini* indeks menghasilkan akurasi sebesar 94%.

Penelitian ketujuh yang dilakukan oleh (Bhavani, 2022) mengumpulkan data dari sensor yang mencakup kelembaban tanah, suhu udara, dan kelembaban udara. Data tersebut kemudian dikelompokkan menggunakan metode *K-Means Clustering* untuk membagi data menjadi dua kelompok, yaitu *needs irrigation* dan *not needed*. Hasil dari metode SVM menunjukkan akurasi sebesar 89,11%, *precision* sebesar 90,01%, dan *recall* sebesar 87,03%. Sementara itu, metode KNN mencapai akurasi 91,05%, *precision* 92,16%, dan *recall* 91,11%.

Penelitian kedelapan yang dilakukan oleh (Sumarudin, 2020) menunjukkan bahwa dataset yang digunakan terdiri dari tiga kelas pada kolom label, yaitu 10% katup terbuka, 25% katup terbuka, dan 50% katup terbuka. Dataset tersebut dibagi dengan proporsi 90% untuk *training* dan 10% untuk *testing*. Metode *Support Vector Machine* (SVM) dengan *kernel linear*, *gamma auto*, dan *cost* (C) = 2 mencapai akurasi sebesar 95%, *precision* 94,3%, *recall* 91%, dan *f1-score* 92,7%.

Penelitian kesembilan yang dilakukan oleh (Kumar, 2023) menerapkan *Correlation-Based Feature Selection* (CFS) dan *K-Means Clustering*. Metode SVM dengan *kernel radial basic function* (*rbf*) mencapai akurasi sebesar 98,5, *precision* 98,3%, *recall* 99,6%, *f1-score* 97%, dan *specificity* 98,7%. Penerapan metode SVM ini juga berhasil mengurangi penggunaan air hingga 42% jika dibandingkan dengan metode irigasi tradisional.

Penelitian kesepuluh yang dilakukan oleh (IORILAM, 2022) dengan menggunakan 100.000 sampel data yang mencakup kelembaban tanah, suhu, kelembaban udara, dan waktu, serta label status pompa (*On* = 1, *Off* = 0). Dataset ini dibagi menjadi 70% untuk *training* dan 30% untuk *testing*. Metode RF dengan 100 pohon dan *gini* indeks menghasilkan akurasi sebesar 99,98%, *precision* 99,96%, *recall* 99,99%, dan *f1-score* 99,97%.

1.6 Skenario Pemanfaatan Produk Oleh Pengguna

Proyek ini menggunakan perangkat keras berupa sensor dan mikrokontroler. Sensor berfungsi untuk mengukur kondisi lingkungan yang memengaruhi tanaman. Mikrokontroler digunakan untuk memproses data dari sensor dan mengendalikan sistem irigasi secara otomatis, dengan bantuan machine learning untuk rekomendasi dan otomatisasi. Selain itu, aplikasi Mobile akan dikembangkan agar pengguna dapat memantau tanaman dan merencanakan irigasi jarak jauh melalui internet.

1.7 Tujuan

Tujuan dari capstone project ini adalah mengembangkan sistem irigasi cerdas yang memanfaatkan *internet of things* dan *machine learning* untuk mendukung

praktik pertanian yang lebih berkelanjutan. Sistem ini akan memberikan rekomendasi dan otomatisasi penyiraman tanaman berdasarkan kebutuhan air tanaman, sehingga dapat meningkatkan efisiensi penggunaan air, serta mengurangi biaya pengeluaran, waktu, dan tenaga yang diperlukan dalam pengelolaan irigasi.

BAB II

PEMILIHAN SOLUSI

2.1 Alternatif Solusi

2.1.1 K-Nearest Neighbors

Solusi pertama adalah menggunakan *K-Nearest Neighbors* (KNN) sebagai metode *supervised learning* yang sederhana dalam *machine learning*. Metode ini bekerja dengan mengklasifikasikan data baru berdasarkan kesamaan dengan data yang telah dilatih sebelumnya, di mana kesamaan tersebut dihitung dari jarak antara data menggunakan nilai k sebagai jumlah tetangga terdekat (Kaur, 2023). Untuk menentukan kesamaan berdasarkan jumlah tetangga terdekat, KNN mengukur jarak antara data latih dan data uji dengan menggunakan beberapa jenis perhitungan jarak (Tace, 2022). Salah satu metrik jarak yang digunakan adalah persamaan *manhattan* yang didefinisikan persamaan berikut:


$$d(x, y) = \sum_{i=1}^n |x_i - y_i| \quad (2.1)$$

di mana $d(x, y)$ adalah jarak antara vektor x (sebagai sampel data latih) dan y (sebagai data uji), n adalah jumlah atribut, dan i adalah indeks atribut.

Kelebihan KNN terletak pada kesederhanaannya, ditentukan oleh jumlah tetangga terdekat (k) dan metode pengukuran jarak. Metode ini efektif pada jumlah sampel data yang besar, meskipun dapat memengaruhi waktu (Ayabe, 2020). Namun, pemilihan nilai k harus dilakukan dengan cermat. Nilai k yang kecil sangat sensitif terhadap *noise* dan dapat menyebabkan overfitting, sementara nilai k yang

besar dapat mengurangi pengaruh *noise*, tetapi meningkatkan kompleksitas perhitungan (Choil, 2021).

Kelemahan utama dari KNN adalah ketergantungannya pada kualitas dan ukuran dataset. Metode ini sangat rentan terhadap *outlier* dan data yang hilang (*missing*), serta kurang efektif untuk data berdimensi tinggi (Rahmadini, 2022). Di samping itu, KNN memerlukan komputasi yang intensif dan waktu pemrosesan akan meningkat seiring dengan penambahan ukuran dataset (Ayabe, 2022).



Gambar 2.1 K-Nearest Neighbors

Gambar 2.1 menunjukkan metode *K-Nearest Neighbors* (KNN) terdiri dari beberapa tahapan dalam proses klasifikasi, yaitu:

1. Menentukan jumlah tetangga terdekat (k) yang akan digunakan dalam proses klasifikasi.
2. Menghitung jarak antara setiap data uji dengan seluruh data latih menggunakan *manhattan distance*.
3. Mengurutkan hasil perhitungan jarak antara data uji dan data latih, dimulai dari jarak terkecil hingga jarak terbesar.

4. Menentukan kelas dari data uji berdasarkan mayoritas kelas yang paling muncul di antara (k) tetangga terdekat.


Pada solusi pertama, perancangan sistem irigasi cerdas menggunakan *K-Nearest Neighbors* (KNN), parameter yang digunakan adalah $k = 5$ dan jenis jarak yang digunakan adalah *manhattan*. Dataset ini dibagi menjadi 80% data latih dan 20% data uji, menghasilkan akurasi sebesar 99,8% (Kaur, 2024).

2.1.2 Support Vector Machine

Solusi kedua adalah menggunakan *Support Vector Machine* (SVM) sebagai metode *supervised learning* dalam *machine learning*, yang dapat diterapkan untuk menyelesaikan masalah klasifikasi dan regresi. SVM bekerja dengan mencari *hyperplane* yang terbaik untuk memisahkan dua kelas data, dilakukan dengan cara memaksimalkan *margin* antara kelas-kelas tersebut. Metode ini dapat memisahkan data linier maupun non-linier dengan menggunakan *kernel trick* (Ayabe, 2020).

SVM memiliki kelebihan dalam menghasilkan generalisasi yang baik dan mengurangi risiko *overfitting*. Metode ini juga tahan terhadap *noise* dan *outlier*, serta mampu mengelola data yang tidak seimbang. Selain itu, SVM dapat menangani data berdimensi tinggi dengan jumlah sampel terbatas (Ayabe, 2020).

Kelemahan dari SVM adalah tidak cocok untuk himpunan data dengan jumlah sampel dan dimensi yang besar. Kinerja SVM juga dipengaruhi oleh pemilihan *kernel* dan nilai regulasi (C), yang memengaruhi akurasi, kebutuhan komputasi dan waktu pemrosesan secara bervariasi (Ayabe, 2020).



Gambar 2.2 Support Vector Machine

Gambar 2.2 menunjukkan proses kerja dalam menentukan *hyperplane* dan memaksimalkan *margin*. SVM terdiri dari tiga komponen utama, yaitu *hyperplane* sebagai bidang pemisah terbaik antara dua kelas, *margin* yang merupakan jarak *hyperplane* dan jarak terdekat dari masing-masing kelas, serta *support vector* yang merupakan data yang paling dekat dengan *hyperplane* (Junus, 2023).

Proses pelatihan SVM dimulai dengan himpunan data pelatihan $(x_1, y_1), (x_2, y_2), \dots, (x_i, y_i)$, di mana $x_i \in R^n$ mewakili vektor fitur, dan $y_i \in R^n$ menunjukkan label kelas. Dua kelas data dipisahkan secara sempurna oleh *hyperplane*, yang didefinisikan dengan persamaan:

$$w^T \cdot x + b = 0 \quad (2.2)$$

di mana w adalah vektor bobot yang terkait dengan masing-masing fitur data, x adalah vektor fitur data, dan b adalah nilai bias.

Tujuan dari SVM adalah menemukan *hyperplane* yang memaksimalkan *margin*, yaitu jarak antara dua kelas terhadap *hyperplane*. *Margin* tersebut dihitung sebagai $\frac{2}{\|w\|}$, di mana $\|w\|$ merupakan norma dari vektor bobot w .

Untuk menemukan *hyperplane* terbaik, dilakukan proses optimasi melalui *Quadratic Programming* dengan meminimalkan:

$$\min \frac{1}{2} \|w\|^2 \quad (2.3)$$

dengan syarat:

$$y_i(w \cdot x_i + b) \geq 1, \quad i = 1, 2, 3, \dots, n \quad (2.5)$$

Optimalisasi ini dapat diselesaikan menggunakan metode *Lagrange Multiplier* dengan menambahkan parameter α , sehingga fungsi *Lagrange* dinyatakan sebagai:

$$L_p(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i [y_i(w \cdot x_i + b) - 1] \quad (2.6)$$

di mana $\alpha_i \geq 0$ adalah nilai *Lagrange Multiplier*.

Untuk memperoleh nilai optimal dari w dan b , dilakukan penurunan fungsi *Lagrange* L_p terhadap w dan b , kemudian menetapkan turunan tersebut sama dengan nol, yang menghasilkan persamaan berikut:

$$\frac{\delta L}{\delta w} = 0 \rightarrow \sum_{i=1}^n \alpha_i x_i y_i = w \quad (2.7)$$

$$\frac{\delta L}{\delta b} = 0 \rightarrow \sum_{i=1}^n \alpha_i y_i = 0 \quad (2.8)$$

Dengan substitusi nilai w dan b , fungsi *Lagrange* dapat diubah menjadi bentuk *dual* yang memaksimalkan sebagai berikut:

$$\max_{\alpha} L_p = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) \quad (2.9)$$

dengan syarat: $\alpha_i \geq 0$; $i = 1, 2, 3, \dots, n$; $\sum_{i=1}^n \alpha_i y_i = 0$.

Hasil dari optimasi ini adalah α_i , di mana data yang memiliki $\alpha_i > 0$ disebut sebagai *support vector*, yang berperan sebagai menentukan posisi *hyperplane*. Sedangkan $\alpha_i = 0$ disebut *non-support vector*, karena tidak mempengaruhi posisi

hyperplane dan terletak jauh dari *hyperplane*. Setelah pelatihan selesai, fungsi prediksi untuk data baru dinyatakan sebagai:

$$f(x) = \left(\sum_{i,j=1}^n \alpha_i y_i x_s x_t \right) + b \quad (2.10)$$

di mana x_s adalah *support vector*, dan x_t merupakan vektor fitur dari data baru yang akan diprediksi.

Dalam kasus ketika kedua kelas data tidak dapat dipisahkan secara sempurna, SVM menawarkan *kernel trick* untuk memisahkan data non-linier dengan mentransformasikan data dari ruang *input* ke ruang fitur berdimensi lebih tinggi (Kaur, 2024). Namun, dalam penelitian ini, parameter yang diterapkan pada SVM adalah kernel linear yang berfokus pengukuran produk titik dari vektor data di ruang aslinya, tanpa melakukan transformasi ke ruang fitur yang lebih tinggi (Rabbani, 2023). Persamaan kernel linear didefinisikan sebagai:

$$k(x_i \cdot x_j) = x_i \cdot x_j \quad (2.11)$$

Kernel linear memisahkan data secara linier dengan waktu pemrosesan yang lebih singkat dan lebih tahan terhadap overfitting (Ayabe, 2020).

Selain itu, SVM dapat dimodifikasi dengan menambahkan variabel *slack* $\xi > 0$ untuk mengukur kesalahan klasifikasi (Junus, 2023). Modifikasi ini diterapkan melalui metode *soft margin* (Rahmi, 2024). Pada persamaan *Quadratic Programming* yang dimodifikasi menjadi:

$$\min \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i \quad (2.12)$$

dengan syarat:

$$y_i(w \cdot x_i + b) \geq 1 - \xi_i, \quad i = 1, 2, 3, \dots, n \quad (2.13)$$

Masalah optimasi dengan *Lagrange Multiplier* pada (2.6) kemudian dimodifikasi menjadi persamaan berikut:

$$L_p(w, b, \alpha) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i + \sum_{i=1}^n \alpha_i [y_i(w \cdot x_i + b) - 1 + \xi_i] - \sum_{i=1}^n \mu_i \xi_i \quad (2.14)$$

Turunan *dual Lagrange Multiplier* pada (2.9) kemudian dimodifikasi menjadi persamaan berikut:

$$\max_{\alpha} L_p = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) \quad (2.15)$$

dengan syarat: $0 \leq \alpha_i \leq C$; $i = 1, 2, 3, \dots, n$; $\sum_{i=1}^n \alpha_i y_i = 0$.

Parameter C yang berfungsi untuk menyeimbangkan antara dua aspek penting, yaitu pengurangan kesalahan pelatihan dan pengaturan lebar *margin*. Semakin besar C (*soft margin*), semakin besar penalti terhadap kesalahan, membuat metode menjadi lebih ketat dalam memisahkan data, namun berisiko *overfitting*. Sebaliknya, nilai C (*hard margin*) yang kecil memberikan toleransi yang lebih tinggi terhadap kesalahan, menghasilkan *margin* yang lebih lebar, namun berpotensi menyebabkan *underfitting* (Aryawan, 2023).

Pada solusi kedua, perancangan sistem irigasi menggunakan *Support Vector Machine* (SVM), *kernel* yang digunakan adalah *linear*. Dataset ini dibagi menjadi 80% data latih dan 20% data uji, menghasilkan akurasi sebesar 99,3% (Kaur, 2024).

2.1.3 Random Forest

Solusi ketiga adalah menggunakan *Random Forest* (RF) adalah metode *ensemble learning* yang populer untuk klasifikasi dan regresi. Metode ini bekerja dengan menggabungkan beberapa *Decision Tree* secara terpisah, di mana setiap


pohon menggunakan subset data yang dipilih secara acak melalui teknik bagging. Prediksi akhir diperoleh dengan menggabungkan hasil dari setiap pohon (Ayabe, 2020). *Random Forest* dikembangkan dari metode *Classification* dan *Regression Tree* (CART), yang merupakan teknik klasifikasi yang menganalisis data menggunakan *Decision Tree* (Lestari, 2023).

Setiap *Decision Tree* terdiri dari beberapa jenis simpul, yaitu simpul akar, simpul internal, dan simpul daun. Simpul akar, yang dikenal sebagai *root node*, adalah simpul yang terletak di puncak pohon. Simpul internal berfungsi sebagai titik percabangan dengan setidaknya satu masukan dan dua keluaran. Di sisi lain, simpul daun atau *terminal node* adalah simpul terakhir yang hanya memiliki satu masukan tanpa menghasilkan keluaran tambahan (Rakhmat, 2023).

Random Forest memiliki kemampuan generalisasi yang tinggi dengan membangun sejumlah *Decision Tree* yang beragam, sehingga dapat mengurangi risiko *overfitting*. Metode ini juga efektif dalam menangani fitur kategoris, data berdimensi tinggi, serta dataset dengan jumlah sampel besar melalui pemrosesan paralel. Selain itu, metode ini tahan terhadap *outlier* dan *noise*, serta mampu mengelola data yang tidak seimbang dengan baik (Ayabe, 2020). *Random Forest* juga mampu menangani *missing data* (Zhu, 2020).

Kelemahan *Random Forest* meliputi kebutuhan komputasi dan waktu pemrosesan yang meningkat seiring bertambahnya jumlah dan kedalaman pohon, terutama pada dataset besar. Metode ini juga memerlukan spesifikasi prosesor tinggi untuk pemrosesan paralel. Oleh karena itu, pengaturan *hyperparameter*

seperti jumlah pohon dan kedalaman maksimum sangat penting untuk efisiensi komputasi (Zhu, 2020).



Gambar 2.3 Random Forest

Berdasarkan Gambar 2.3, *Random Forest* membangun sejumlah *Decision Tree* secara terpisah menggunakan teknik *bagging* (*bootstrap aggregating*), di mana setiap pohon dibangun dengan sampel acak dari data pelatihan yang dipilih dengan penggantian (*replacement*). Setiap pohon dibangun tanpa pemangkasan dan menggunakan *random feature selection*. Proses ini diulangi hingga membentuk jumlah *Decision Tree* yang ditentukan tercapai (Lestari, 2023).

Saat membangun *Decision Tree*, dilakukan pemilihan jumlah fitur yang diambil secara acak (*random feature selection*) pada setiap simpul. Pengaturan nilai lebih rendah meningkatkan variasi pohon dan mengurangi korelasi antar pohon, memperkuat stabilitas model saat semua pohon akan digabungkan (Yulianto, 2024). Untuk masalah klasifikasi, nilai ini sering diatur pada $\sqrt{p}$ untuk, di mana p adalah jumlah total fitur dalam dataset (Junus, 2022).

Proses pembentukan setiap *Decision Tree* dimulai dengan pemisahan data pada setiap simpul berdasarkan kriteria tertentu, diikuti dengan penentuan terminal,

dan diakhiri dengan penetapan label kelas untuk simpul tersebut (Yulianti, 2023). Kualitas pemisahan simpul yang terbaik dihitung menggunakan *Gini Index*, yang berfungsi untuk mengukur ketidakmurnian data pada simpul tersebut. Semakin rendah nilai *Gini Index*, semakin baik pemisahan yang dilakukan, karena menandakan bahwa data pada tersebut lebih homogen. Perhitungan *Gini Index* dan *Gini Split* dapat dilihat pada persamaan (2.16) dan (2.17).

$$Gini\ Index\ (D) = 1 - \sum_{i=1}^n P_i^2 \quad (2.16)$$

di mana P_i adalah probabilitas dari kelas ke- i dalam simpul D , dan n adalah jumlah total kelas.

$$Gini\ Split\ (D) = \frac{N_1}{N} Gini\ Index(D_1) + \frac{N_2}{N} Gini\ Index(D_2) \quad (2.17)$$

di mana N_1 dan N_2 adalah jumlah sampel dalam subset setelah pemisahan, D_1 dan D_2 adalah simpul hasil pemisahan, serta N adalah jumlah total sampel pada simpul (*node*) tersebut.

Proses pembentukan pohon berhenti, dan simpul terminal ditetapkan, jika jumlah pengamatan pada simpul lima atau kurang ($n \leq 5$) atau kedalaman maksimum pohon telah tercapai. Penetapan label kelas pada simpul terminal mengikuti aturan mayoritas, di mana kelas dalam jumlah sampel terbanyak dipilih sebagai label kelas pada simpul tersebut, sesuai dengan persamaan berikut:

$$P(j_0|t) = \max_j P(j|t) = \max_j \frac{N_j(t)}{N(t)} \quad (2.18)$$

di mana $N_j(t)$ adalah jumlah sampel dari kelas j pada simpul t , dan $N(t)$ adalah total sampel pada simpul tersebut.

Pada solusi ketiga, perancangan sistem irigasi menggunakan *Random Forest* (RF), dengan membangun 100 pohon dan menggunakan *Gini* indeks. Dataset ini dibagi menjadi 80% data latih dan 20% data uji, menghasilkan akurasi sebesar 99,98%, *precision* 99,96%, *recall* 99,99%, dan *f1-score* 99,97% (IORILAM, 2022).

2.2 Analisis Pemilihan Solusi

Tabel 2.2 Analisis Pemilihan Solusi

Solusi	Karakteristik Pendekatan Berdasarkan Aspek Analisis	Solusi Terpilih
Pendekatan-1 Preprocessing: - <i>train_test_split</i> (80 : 20) - <i>StandarScaler</i> Classifier: <i>K-Nearest Neighbors</i> <i>(k: 5, metric: manhattan)</i>	Aspek Ekonomis Selama proses pelatihan <i>K-Nearest Neighbors</i> (KNN), kebutuhan komputasi dapat meningkat secara signifikan seiring dengan bertambahnya ukuran dataset (Ayabe, 2020). Aspek Manufakturabilitas Selama proses pelatihan <i>K-Nearest Neighbors</i> (KNN), waktu pemrosesan dapat menjadi lebih lama seiring bertambahnya ukuran dataset (Ayabe, 2020). Aspek Sustainabilitas <i>K-Nearest Neighbors</i> (KNN) menghasilkan akurasi sebesar 99,3%, yang memungkinkan sistem ini memprediksi kebutuhan irigasi dengan baik dan mendukung berkelanjutan penggunaan air dalam pertanian (Kaur, 2024).	-
Pendekatan-2 Preprocessing:	Aspek Ekonomis	-


- <i>train_test_split</i> (80 : 20) - <i>StandarScaler</i> Classifier: <i>Support Vector Machine</i> (<i>kernel: linear</i>)	Selama pelatihan, <i>Support Vector Machine</i> (SVM) menghemat memori dengan hanya menggunakan <i>support vectors</i> (Palaniappan, 2024). Namun, pemilihan <i>kernel</i> yang kompleks dan ukuran dataset yang besar dapat meningkatkan kebutuhan komputasi (Ayabe, 2020). Aspek Manufakturabilitas Penggunaan <i>kernel linear</i> dalam <i>Support Vector Machine</i> (SVM) memang memerlukan waktu pelatihan yang lebih cepat dibandingkan <i>kernel non-linear</i>. Namun, ketika menghadapi dataset yang sangat besar, durasi proses pelatihan dapat menjadi sangat lama (Ayabe, 2020). Aspek Sustainabilitas <i>Support Vector Machine</i> (SVM) menghasilkan akurasi sebesar 99,3%, yang memungkinkan sistem ini memprediksi kebutuhan irigasi dengan baik dan mendukung berkelanjutan penggunaan air dalam pertanian (Kaur, 2024).	
Pendekatan-3 Preprocessing: <i>train_test_split</i> (80 : 20) Classifier: <i>Random Forest</i> (<i>n_estimators</i>: 100 , <i>criterion</i>: 'gini',	Aspek Ekonomis Penggunaan komputasi <i>Random Forest</i> (RF) dapat meningkat seiring bertambahnya jumlah pohon yang dibangun dan kedalaman pohon yang lebih dalam. Pemrosesan paralel yang diterapkan dalam RF dapat membantu mempercepat proses pelatihan pada dataset besar, namun bisa menambah biaya komputasi menjadi tinggi (Zhu, 2022).	✓

<i>max_features: 'sqrt',</i> <i>bootstrap: True,</i> <i>n_job: -1)</i>	Aspek Manufakturabilitas Selama pelatihan, <i>Random Forest</i> (RF) setidaknya ada dua parameter dapat mempengaruhi waktu pelatihan yaitu jumlah pohon dan kedalaman pohon, terutama dataset yang lebih besar, namun bisa dipercepat dengan menerapkan pemrosesan paralel meskipun memakan kebutuhan komputasi (Zhu, 2020). Aspek Sustainabilitas <i>Random Forest</i> (RF) menghasilkan akurasi sebesar 99,98%, yang memungkinkan sistem ini memprediksi kebutuhan irigasi dengan akurasi tinggi. Prediksi yang tepat ini mendukung penggunaan air yang berkelanjutan, membantu pemborosan dan mengoptimalkan sumber daya dalam pertanian dalam pertanian (IORILAM, 2022).	
---	--	--

BAB III

METODOLOGI

Pada bagian ini, metodologi penelitian dijelaskan sebagai elemen kunci dalam perancangan sistem irigasi cerdas. Metodologi ini memberikan kerangka sistematis yang mencakup langkah-langkah penelitian dan mekanisme yang akan dilalui. Ilustrasi dari metodologi yang digunakan ditampilkan pada Gambar 3.1, yang menggambarkan alur perancangan dan pengembangan sistem secara keseluruhan.



Gambar 3.1 Alur Metodologi Penelitian

3.1 Identifikasi Masalah

Identifikasi masalah merupakan langkah awal yang krusial dalam perancangan sistem irigasi cerdas. Proses ini dimulai dengan menganalisis penelitian, berita, serta melakukan observasi pribadi terhadap tantangan dalam kegiatan menyiram tanaman. Selain itu, wawancara dengan organisasi dan ahli

pertanian dilakukan untuk memverifikasi dan memahami permasalahan yang dihadapi dalam praktik irigasi saat ini. Dari hasil identifikasi, ditemukan bahwa aktivitas merawat tanaman, seperti mengawasi dan menyiram secara manual, membutuhkan waktu, tenaga, dan biaya yang besar. Di samping itu, petani sering kali tidak mampu mengukur dan memprediksi secara akurat waktu penyiraman yang tepat, sehingga manajemen irigasi yang kurang optimal ini mengakibatkan kegagalan panen dan pemborosan air. Oleh karena itu, diperlukan sebuah sistem yang dapat mengurangi beban kerja dan membantu petani dalam merawat tanaman.

3.2 Analisis Solusi

Analisis solusi dari Bab 2 akan dievaluasi lebih mendalam dengan membandingkan akurasi, ketangguhan terhadap variasi kualitas data, dan biaya implementasi terkait kebutuhan komputasi. Proses ini bertujuan untuk menentukan metode terbaik berdasarkan kemampuan dalam mempelajari pola, memprediksi hasil secara akurat, serta efisiensi dalam komputasi.

Hasil akhir yang dipilih adalah RF karena menghasilkan akurasi sebesar 99,98% (IORILAM, 2022). Dibandingkan SVM dan KNN masing-masing menghasilkan akurasi sebesar 99,3% (Kaur, 2024). Hal ini menunjukkan bahwa RF lebih unggul dalam memprediksi dan mengklasifikasikan kebutuhan air pada tanaman dalam sistem irigasi cerdas.

RF memiliki ketangguhan dalam mengelola dataset dengan jumlah sampel dan dimensi yang besar. Sebagai perbandingan, meskipun SVM mampu menangani dimensi yang tinggi, metode ini tidak cocok untuk himpunan data yang sangat besar

(Ayabe, 2020). KNN dapat menangani jumlah sampel yang besar, namun tidak efektif untuk data berdimensi tinggi (Rahmadini, 2022).

RF dan SVM sama-sama unggul dalam menangani *outlier*, *noise*, dan *imbalanced* data (Ayabe, 2020). Sementara KNN sangat sensitif terhadap *outlier*, *noise*, dan *missing* data yang memengaruhi metode (Rahmadini, 2020). SVM juga memiliki kelemahan dalam menangani *missing* data (Putri, 2023). Berbeda dengan RF mampu menangani *missing* data (Zhu, 2020). Dengan demikian, RF memiliki keunggulan dalam menangani *outlier*, *noise*, *missing* data, dan ketidakseimbangan (*imbalanced*), serta mampu mengelola dataset dari ukuran kecil hingga besar, membuatnya lebih cocok dalam berbagai kasus.

3.3 Pengumpulan Data

Pengumpulan data memiliki peran penting dalam metode *machine learning* untuk mempelajari pola sebelum melakukan prediksi dan pengambilan keputusan. Dalam proyek ini, dataset diambil dari penelitian yang dilakukan oleh (Kaur, 2024), yang tersedia di *Mendeley* Data dan dapat diakses melalui <https://data.mendeley.com/datasets/fpdwmm7nrb/1>. Dataset ini berisi 3000 sampel data yang mencakup informasi tentang jadwal irigasi tanaman, dengan 4 fitur utama seperti kelembaban tanah, temperatur, dan kelembaban udara. Setiap fitur dalam dataset tersebut memiliki satu dari dua target klasifikasi, yaitu kondisi pompa, di mana nilai 0 menunjukkan pompa mati dan nilai 1 menunjukkan pompa hidup. Penjelasan lebih lanjut tentang atribut pada data irigasi dapat dilihat pada Tabel 3.1.

Tabel 3.3 Penjelasan Atribut pada Data Irigasi

Atribut	Tipe Data	Keterangan
<i>Soil Moisture</i>	<i>float64</i>	Data kelembaban tanah yang bernilai 314,511 – 984,828.
<i>Temperature</i>	<i>float64</i>	Data suhu udara yang bernilai 28,443 – 38,992.
<i>Air Humidity</i>	<i>float64</i>	Data kelembaban udara yang bernilai 59,367 – 81,267.
<i>Pump Data</i>	<i>int64</i>	Label klasifikasi kondisi pompa; 0 = pompa hidup, 1 = pompa mati.

3.4 Preprocessing Data

Preprocessing data merupakan langkah penting dalam pengelolaan data sebelum melatih metode *machine learning*. Tahapan ini dimulai dengan mengidentifikasi dan menangani *missing* data, yang dapat digunakan adalah metode imputasi median. Terdapat tiga tipe kehilangan data, yaitu hilang sepenuhnya secara acak (*missing completely at random*), hilang secara acak (*missing at random*), dan hilang tidak secara acak (*missing not at random*).

Setelah penanganan *missing* data, langkah selanjutnya adalah memilih fitur (X) yang terdiri dari *Soil Moisture*, *Temperature*, dan *Air Humidity*, sementara label (y) yang dijadikan target adalah *Pump Data*, kemudian data tersebut dibagi menjadi 80% untuk *training* dan 20% untuk *testing* data. Setelah pembagian dataset, data *training* akan diperbaiki menggunakan *SMOTE* (*Synthetic Minority Over-sampling Technique*) untuk menangani *outlier* dan ketidakseimbangan data.

Kategorisasi data dilakukan untuk mengevaluasi kondisi dalam pengambilan keputusan model selama pengujian. Untuk parameter kelembaban tanah, nilai 289

dikategorikan sebagai sangat basah, 398 sebagai basah, 508 sebagai normal atau lembab, 618 sebagai kering, dan 727 sebagai sangat kering (Rosyid, 2022). Suhu udara dengan nilai $\leq 23^{\circ}\text{C}$ dikategorikan dingin, $24^{\circ}\text{C} - 30^{\circ}\text{C}$ sebagai normal, dan $\geq 30^{\circ}\text{C}$ sebagai panas (Pradana, 2023). Untuk kelembaban udara, nilai $\leq 55\%$ dikategorikan kering, dan $\geq 56\%$ dikategorikan lembab (Yohanes, 2023). Terakhir, untuk label kelas klasifikasi pada *pump* data, sesuai dengan kategori kelembaban tanah yang telah dijelaskan, nilai 1 sebagai *OFF* dan nilai 0 sebagai *ON*.

3.5 Perancangan *Random Forest*

Perancangan *Random Forest* menggunakan bahasa pemrograman *Python* dan library *scikit-learn* (*sklearn*), yang menyediakan berbagai metode *machine learning* dengan antarmuka sederhana dan efisien, sehingga memudahkan dalam proses pengembangan dan implementasi model. Implementasi *Random Forest* dilakukan dengan memanggil *RandomForestClassifier* berserta beberapa *hyperparameter*, antara lain *n_estimators*=100 untuk jumlah pohon, *criterion*='gini', *max_features*='sqrt', *bootstrap*=True untuk pengambilan sampel dengan penggantian, dan *n_jobs*=-1 untuk memaksimalkan CPU.

Secara umum, *Random Forest* membangun *Decision Tree* tanpa melakukan pemangkasan, yang berarti tidak ada batasan yang diterapkan pada kedalaman pohon. Peningkatan kedalaman pohon dapat meningkatkan biaya komputasi baik memori maupun waktu. Oleh karena itu, pemangkasan melalui *hyperparameter* *max_depth* penting untuk membatasi kedalaman pohon (Akbar, 2023). Pembatasan kedalaman diterapkan untuk meningkatkan efisiensi dalam kebutuhan komputasi.

Hyperparameter max_depth akan ditentukan dalam rentang nilai 3 hingga 7. Berdasarkan penelitian yang dilakukan oleh (Oktafiani, 2024), *Random Forest* dengan *max_depth* = 3 mencapai akurasi 86,34%, *max_depth* = 4 mencapai akurasi 86,34%, nilai 5 mencapai akurasi 91,70%, *max_depth* = 6 mencapai akurasi 97,07%, dan *max_depth* = 7 mencapai akurasi 98,53%.

Penelitian yang dilakukan oleh (Baig, 2022) menunjukkan bahwa *max_depth* = 3 menghasilkan akurasi sebesar 97,96%, presisi 98,18%, *recall* 86,66%, *AUC* 0,932, dan waktu pelatihan 0,22 detik. Sementara itu, dengan *max_depth* = 4, akurasi yang diperoleh adalah 97,82%, presisi 99,79%, *recall* 84,21%, *AUC* 0,971, dan waktu pelatihan 0,259 detik. Pada pengaturan *max_depth* = 5, akurasi meningkat menjadi 99,14%, dengan presisi 99,30%, *recall* 94,36%, *AUC* 0,971, dan waktu pelatihan 0,38 detik. Terakhir, pada *max_depth* = 6, akurasi mencapai 99,47%, presisi 99,60%, *recall* 96,53, *AUC* 0,982, dan waktu pelatihan 0,44 detik.

3.6 Pengujian

Pengujian metode ini merupakan langkah validasi penting sebelum diimplementasikan ke dalam sistem mikrokontroler *ESP32*. Pengujian dilakukan untuk memastikan bahwa metode ini mampu mempelajari pola-pola dan melakukan prediksi dengan baik serta memenuhi standar yang diperlukan. Parameter pengujian mencakup pengukuran akurasi, presisi, *recall*, *f1-score*, dan *AUC score*.

Akurasi dapat diartikan sebagai ukuran yang menunjukkan seberapa baik kemampuan klasifikasi dalam menghasilkan prediksi yang tepat secara keseluruhan. Akurasi dapat dihitung melalui persamaan (3.1).

$$Accuracy = \frac{T_p + T_n}{T_p + T_n + F_p + F_n} \quad (3.1)$$

Presisi mengacu pada proporsi hasil yang relevan dibandingkan dengan total hasil yang dihasilkan oleh metode klasifikasi. Presisi dapat dihitung melalui persamaan (3.2).

$$Precision = \frac{T_p}{T_p + F_p} \quad (3.2)$$

Recall adalah rasio yang menunjukkan seberapa banyak data relevan yang hasil diidentifikasi kembali oleh metode klasifikasi dibandingkan dengan total data relevan yang ada. *Recall* dapat dihitung melalui persamaan (3.3).

$$Recall = \frac{T_p}{T_p + F_n} \quad (3.3)$$

F1-score merupakan ukuran yang menunjukkan keseimbangan antara presisi dan recall, di mana *F1-score* terbaik adalah 1 dan terendah adalah 0. *F1-score* dapat dihitung melalui persamaan (3.4).

$$F1 - score = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (3.4)$$

AUC (*Area Under the Curve*) untuk mengevaluasi dan performa model machine learning, terutama dalam kasus ketidakseimbangan kelas. *AUC* diperoleh dari kurva *ROC* (*Receiver Operating Characteristic*). Semakin tinggi nilai *AUC*, Semakin baik performa model dalam klasifikasi. Terdapat beberapa kategori untuk nilai *AUC*, yaitu: sangat baik (0.9 - 1), baik (0.8 - 9), cukup (0.7 – 0.8), buruk (0.6 – 0.7) dan tidak memadai (0.6 – 0.7) (Sari, 2020).

TP (*True Positive*) mencerminkan jumlah prediksi yang benar untuk data positif, sedangkan *TN* (*True Negative*) mencerminkan jumlah prediksi yang benar untuk data negatif. Di sisi lain, *FP* (*False Positif*) menunjukkan jumlah prediksi yang salah untuk data positif, sementara *FN* (*False Negative*) menggambarkan jumlah

prediksi yang salah untuk data negatif. Kedua kondisi ini menunjukkan adanya kesalahan dalam memprediksi pola data.

3.7 Implementasi Model *Random Forest*

Setelah tahap pengujian, langkah berikutnya adalah menerapkan model *Random Forest* ke mikrokontroler *ESP32* dengan mengonversi model yang sudah dikembangkan dan dilatih menggunakan *Python* ke dalam bahasa *C++*. Konversi ini dilakukan dengan memanfaatkan pustaka sumber terbuka *micromlgen*, yang dirancang khusus untuk integrasi model *machine learning* ke dalam mikrokontroler. Implementasi *Random Forest* dilakukan dengan memilih nilai *max_depth* berdasarkan evaluasi kinerja dan efisiensi memori pada pengujian, sehingga memungkinkan penggunaan model yang optimal pada mikrokontroler *ESP32*.

3.8 Hasil

Hasil yang diharapkan dari perancangan dan implementasi *Random Forest* ke dalam mikrokontroler *ESP32* adalah terciptanya sistem *hybrid* berbasis *internet of things* dan *machine learning* yang mampu memprediksi kebutuhan air pada tanaman berdasarkan faktor-faktor yang mempengaruhi tanaman. Sistem ini akan memberikan rekomendasi dan menyiram tanaman secara otomatis tanpa intervensi manusia, sehingga menghemat waktu, tenaga, dan biaya. Selain itu, sistem ini diharapkan dapat meningkatkan efisiensi penggunaan air.

BAB IV

PERANCANGAN

4.1 Spesifikasi Solusi

Pada bagian ini menjelaskan beberapa spesifikasi solusi yang harus memenuhi fungsi, kinerja, dan karakteristik sesuai standar untuk mendukung kebutuhan petani dalam merancang aplikasi *mobile* dan perangkat keras dengan menggunakan *internet of things* dan *machine learning*.

1. Aplikasi *mobile* menyediakan antarmuka dalam memantau kondisi tanaman dan mengatur sistem irigasi.
2. Aplikasi *mobile* memungkinkan pengguna melakukan konfigurasi serta pengelolaan perangkat keras dengan mudah.
3. Mikrokontroler ESP32 yang dilengkapi dengan model *Random Forest* dari *machine learning*, digunakan untuk memprediksi dan mengambil keputusan secara otomatis dalam irigasi berdasarkan kebutuhan air, dengan mempertimbangkan berbagai faktor lingkungan.
4. Mikrokontroler ESP32 yang sudah terintegrasi dengan *internet of things* (IoT) terhubung dengan sensor. Data dari sensor ini diproses oleh sistem dan dapat diakses melalui aplikasi *mobile*.
5. Mikrokontroler ESP32 dapat berkomunikasi dengan server melalui koneksi internet, memungkinkan penyimpanan dan tampilan data secara *real-time* serta pengendalian perangkat dari jarak jauh.

4.2 Rencana Pengujian


Setelah tahap pengembangan sistem selesai, langkah berikutnya adalah melakukan pengujian sistem yang memiliki peranan krusial sebelum sistem tersebut digunakan oleh petani. Rencana pengujian ini akan menerapkan metode *blackbox testing*, yang berfokus pada analisis *input* dan *output* tanpa perlu memahami struktur kode yang mendasarinya. Proses pengujian ini bertujuan untuk memastikan bahwa setiap fitur beroperasi sesuai dengan spesifikasi yang telah ditetapkan dan untuk mengevaluasi kesiapan produk untuk digunakan.

4.3 Perancangan Sistem

4.3.1 Perancangan Aplikasi Mobile

Aplikasi mobile memainkan peran krusial sebagai antarmuka bagi pengguna dalam memantau dan mengelola irigasi tanaman, serta memungkinkan pengguna mengonfigurasi perangkat dengan mudah. Desain aplikasi ini memanfaatkan *framework Dart*, yaitu *Flutter*, yang memungkinkan pengembangan aplikasi *multiplatform* dengan satu baris kode. *Flutter* terkenal karena kinerja yang tinggi, responsivitas yang baik, dan antarmuka yang menarik, serta mempermudah dan mempercepat proses pengembangan aplikasi.


Aplikasi ini dirancang khusus untuk platform *Android* dan *iOS*, mengingat tingginya jumlah petani yang memanfaatkan smartphone. Selain itu, aplikasi ini akan dilengkapi dengan pustaka *Bluetooth Low Energy (BLE)*, yang memungkinkan koneksi langsung dengan *ESP32* untuk melakukan konfigurasi perangkat.



Gambar 4.5 Rancangan Random Forest

4.3.2 Perancangan Model Random Forest

Sesuai dengan penjelasan sebelumnya, metode *machine learning* merupakan bagian dari teknologi kecerdasan buatan yang memungkinkan mesin untuk mempelajari pola-pola data, kemudian melakukan prediksi dan pengambilan keputusan secara otomatis berdasarkan pola-pola data yang sudah dipelajari. Dalam bidang pertanian penerapan *machine learning* pada sistem irigasi merupakan solusi yang bermanfaat, untuk mengurangi waktu, tenaga, dan sumber daya manusia, serta meningkatkan efisiensi penggunaan air dan penghematan biaya.



Gambar 4.5 Rancangan Random Forest

Berdasarkan Gambar 4.5, perancangan model ini diawali dengan pengambilan dataset terkait irigasi. Langkah berikutnya adalah melakukan *preprocessing* data, termasuk pembagian data dan terakhir penerapan *SMOTE* untuk menyeimbangkan kelas. Proses *preprocessing* ini telah dijelaskan pada bagian 3.4. Setelah proses *preprocessing* selesai, model *Random Forest* dibangun dengan *hyperparameter* yang telah ditentukan pada bagian 3.5.

4.3.3 Perancangan Sistem Perangkat Keras

Perancangan sistem perangkat keras diawali dengan membangun komponen perangkat keras utama, yaitu:

1. Mikrokontroler ESP32

Mikrokontroler ESP32 adalah mikrokontroler *System on Chip* (SoC) yang dilengkapi dengan kemampuan konektivitas *WiFi* dan *Bluetooth*. Mikrokontroler ini mencakup CPU, memori, dan akses ke GPIO (*General Purpose Input/Output*)

(Nizam, 2022). Oleh karena itu, ESP32 sering digunakan dalam pengembangan sistem *Internet of Things* (IoT) (Yonatan, 2024).


Mikrokontroler ESP32 menggunakan CPU Xtensa LX16 *dual-core*, dengan 448 KB ROM, 520 KB SRAM, dua memori RTC sebesar 8KB, dan *flash* memori sebesar 4MB. Mikrokontroler ini memiliki beberapa keunggulan, di antaranya harga yang terjangkau, kemudahan dalam pengembangan, jumlah pin GPIO yang memadai, efisiensi daya, serta tingkat kesalahan yang rendah (Widayatmika, 2021).

2. *Capactive Soil Moisture Sensor*


3. DHT22 Sensor

4. Relay

Setelah pembangunan perangkat keras selesai, langkah selanjutnya adalah merancang sistem cerdas dengan memasukkan model kecerdasan buatan, yaitu *Random Forest* dari metode *machine learning*. Implementasi *Random Forest* dilakukan sesuai dengan penjelasan pada bagian 3.5 sampai 3.7. Rancangan sistem perangkat keras dapat dilihat pada Gambar 4.6.



Gambar 4.6 Rancangan Sistem Mikrokontroler ESP32



Gambar 4.7 Cara Kerja Sistem Irigasi Cerdas

Pada Gambar 4.7 menunjukkan cara kerja sistem irigasi cerdas pada perangkat keras. Sensor kelembaban tanah, suhu, dan kelembaban udara akan membaca data lingkungan, yang kemudian dikirim ke mikrokontroler untuk diproses menggunakan model *Random Forest* guna memprediksi kebutuhan air pada tanaman. Model ini akan memberikan rekomendasi untuk penyiraman secara otomatis berdasarkan data yang sudah dilatih. Untuk meningkatkan efisiensi pengguna air, sistem ini juga menggunakan sensor hujan untuk mencegah penyiraman saat terdeteksi adanya hujan.

4.4 Proses Verifikasi Perancangan

Tabel 4.1 menyajikan seluruh item yang digunakan untuk memverifikasi rancangan sistem irigasi yang dikembangkan.

Tabel 4.4 Penjelasan Atribut Verifikasi Perancangan

No.	Item	Verifikasi	Keterangan
1	<i>RandomForestClassifier</i>	✓	<i>Random Forest</i> adalah model <i>ensemble learning</i> yang membangun sejumlah <i>Decision Tree</i> yang berbeda melalui teknik <i>bagging</i> dan <i>random feature selection</i> .
2	<i>n_estimators</i>	✓	Menentukan jumlah <i>Decision Tree</i> yang akan dibangun untuk menghasilkan prediksi akhir. Semakin banyak <i>tree</i> yang digunakan, semakin akurat prediksi, meskipun dapat meningkatkan kebutuhan komputasi.

3	<i>criterion</i>	✓	<i>Hyperparameter</i> untuk menentukan kriteria terbaik untuk memisahkan setiap simpul dalam <i>Decision Tree</i> , yaitu pada <i>root node</i> dan <i>terminal node</i> , untuk meminimalkan ketidakmurnian data. Pemilihan kriteria ini bertujuan memastikan ketepatan pemisahan data dalam model prediksi.
4	<i>max_features</i>	✓	Menentukan jumlah fitur acak yang dipilih pada setiap simpul untuk meningkatkan variasi antara pohon dan mengurangi korelasi antar pohon, sehingga model lebih stabil dan generalisasi prediksi lebih baik.
5	<i>bootstrap</i>	✓	Mengatur agar <i>Random Forest</i> menggunakan teknik <i>bagging</i> (pengambilan sampel secara acak dengan penggantian), yang meningkatkan variasi dalam <i>Decision Tree</i> .
6	<i>max_depth</i>	✓	Batasan kedalaman maksimum setiap <i>Decision Tree</i> dalam <i>forest</i> . Mengatur <i>max_depth</i> membantu mengontrol kebutuhan komputasi, seperti memori dan waktu pemrosesan, sekaligus mencegah <i>overfitting</i> .
7	<i>n_jobs</i>	✓	<i>Hyperparameter</i> yang memanfaatkan seluruh CPU bertujuan untuk mempercepat proses pelatihan <i>Random Forest</i> . Dalam situasi ini, hal tersebut bersifat opsional meskipun ukuran dataset tidak terlalu rumit.

8	Mikrokontroler <i>ESP32</i>	✓	ESP32 adalah modul mikrokontroler yang dirancang untuk membangun sistem <i>Internet of Things</i> yang dapat melakukan kontrol dan pemantauan. Modul ini memiliki konektivitas jaringan <i>WiFi</i> dan <i>Bluetooth</i> , yang memungkinkan komunikasi nirkabel serta integrasi berbagai perangkat dalam sistem IoT.
9	<i>Capactive Soil Moisture</i>	✓	
10	<i>DHT22</i>	✓	
11	<i>Rainfall Sensor</i>	✓	

DAFTAR PUSTAKA

- Abo-Zahhad, M. M. (2023). IoT-Based Automated Management Irrigation System Using Soil Moisture Data and Weather Forecasting Adopting Machine Learning Technique. *Sohag Engineering Journal*, 3(2), 122–140. <https://doi.org/10.21608/sej.2023.209528.1037>
- Anggarda, M. F., Kustiawan, I., Nurjanah, D. R., & Hakim, N. F. A. (2023). Pengembangan Sistem Prediksi Waktu Penyiraman Optimal pada Perkebunan: Pendekatan Machine Learning untuk Peningkatan Produktivitas Pertanian. *JURNAL BUDIDAYA PERTANIAN*, 19(2), 124–136. <https://doi.org/10.30598/jbdp.2023.19.2.124>
- Aryawan, I. P. A., Purnama, I. N., & Fredlina, K. Q. (2023). ANALISIS PERBANDINGAN ALGORITMA CNN DAN SVM PADA KLASIFIKASI EKSPRESI WAJAH. *Jurnal Teknologi Informasi Dan Komputer*, 9(4), 399–408. <https://doi.org/10.36002/jutik.v9i4.2545>
- Badan Pusat Statistik Indonesia. (2023). *Hasil Pencacahan Lengkap Sensus Pertanian 2023 - Tahap I*. Bps.go.id; Badan Pusat Statistik Indonesia. <https://www.bps.go.id/id/pressrelease/2023/12/04/2050/hasil-pencacahan-lengkap-sensus-pertanian-2023---tahap-i.html>
- Bharata, W., Sutejo, M. S., Syarah, N. K., Ariani, N. A., Priambodo, F. A., Verdiansyah, V., & Muhammad. (2023). Budidaya Tanaman Hortikultura Sebagai Perwujudan Ketahanan Pangan Masyarakat Desa Liang Ulu. *Darmabakti Jurnal Pengabdian Dan Pemberdayaan Masyarakat*, 4(1), 64–69. <https://doi.org/10.31102/darmabakti.2023.4.1.64-69>
- Bhavani, R., & Thambi, A. (2022). R BHAVANI AND AJOE THAMBI: MANAGING IRRIGATION NEEDS BASED ON SMART DECISIONS USING MACHINE LEARNING MANAGING IRRIGATION NEEDS BASED ON SMART DECISIONS USING MACHINE LEARNING. *ICTACT Journal on Soft Computing*, 12(2), 2540–2544. <https://doi.org/10.21917/ijsc.2022.0363>
- Boateng, E. Y., Otoo, J., & Abaye, D. A. (2020). Basic Tenets of Classification Algorithms K-Nearest-Neighbor, Support Vector Machine, Random Forest and Neural Network: A Review. *Journal of Data Analysis and Information Processing*, 08(04), 341–357. <https://doi.org/10.4236/jdaip.2020.84020>
- Buwarda, S., Lutfi, & Makmur, I. (2023). PENGEMBANGAN SISTEM PENYIRAMAN TANAMAN HORTIKULTURA BERBASIS MIKROKONTROLLER ESP32 DAN APLIKASI TELEGRAM. *Prosiding*

- Seminar Nasional Teknologi Industri (SNTI)*, 10(1), 282–288.
<https://journal.atim.ac.id/index.php/prosiding/article/view/617>
- Cholil, S. R., Handayani, T., Prathivi, R., & Ardianita, T. (2021). Implementasi Algoritma Klasifikasi K-Nearest Neighbor (KNN) Untuk Klasifikasi Seleksi Penerima Beasiswa. *IJCIT (Indonesian Journal on Computer and Information Technology)*, 6(2), 118–127. <https://doi.org/10.31294/ijcit.v6i2.10438>
- Fausan, A., Setiawan, B. I., Arif, C., & Saptomo, S. K. (2021). Analisa Model Evaporasi dan Evapotranspirasi Menggunakan Pemodelan Matematika pada Visual Basic di Kabupaten Maros. *J-Sil (Jurnal Teknik Sipil Dan Lingkungan)*, 5(3), 179–196. <https://doi.org/10.29244/jsil.5.3.179-196>
- Firmansyah, M. R., & Tasqia, F. (2023). Pengukuran Kelembapan Tanah Berbasis IoT pada Greenhouse. *Prosiding Patriot Mengabdi*, 2(01), 331–346. <https://conference.untag-sby.ac.id/index.php/spm/article/view/2873>
- Hasani, M. I., & Wulandari, S. (2023). Implementasi Internet of Things (IoT) Pada Sistem Otomatisasi Penyiraman Tanaman Berbasis Mobile. *ILKOMNIKA: Journal of Computer Science and Applied Informatics*, 5(3), 149–161. <https://doi.org/10.28926/ilkomnika.v5i3.573>
- IORLIAM, A., BUM, S., AONDOAKAA, I. S., IORLIAM, I. B., & SHEHU, Y. (2022). Machine Learning Techniques for the Classification of IoT-Enabled Smart Irrigation Data for Agricultural Purposes. *Gazi University Journal of Science Part A: Engineering and Innovation*, 9(4), 378–391. <https://doi.org/10.54287/gujisa.1141575>
- Jatmiko, W., Ciptadi, P. W., & Hardyanto, R. H. (2021). Sistem Penyiram Tanaman Otomatis Berbasis Mikrokontroler dan Panel Surya. *Seri Prosiding Seminar Nasional Dinamika Informatika*, 5(1), 199–203. <https://prosiding.senadi.upy.ac.id/index.php/senadi/article/view/230>
- Junus, C. Z. V., Tarno, T., & Kartikasari, P. (2022). KLASIFIKASI MENGGUNAKAN METODE SUPPORT VECTOR MACHINE DAN RANDOM FOREST UNTUK DETEKSI AWAL RISIKO DIABETES MELITUS. *Jurnal Gaussian*, 11(3), 386–396. <https://doi.org/10.14710/j.gauss.11.3.386-396>
- Kaur, A., Bhatt, D. P., & Raja, L. (2024). Developing a Hybrid Irrigation System for Smart Agriculture Using IoT Sensors and Machine Learning in Sri Ganganagar, Rajasthan. *Journal of Sensors*, 2024(1), 1–15. <https://doi.org/10.1155/2024/6676907>
- Kumar, G. K., Bangare, M. L., Bangare, P. M., Kumar, C. R., Raj, R., Arias-González, J. L., Omarov, B., & Mia, Md. S. (2024). Internet of things sensors and support vector machine integrated intelligent irrigation system for

- agriculture industry. *Discover Sustainability*, 5(1), 1–10. <https://doi.org/10.1007/s43621-024-00179-5>
- Kynta, D. P., Laksono, I. L., Wijaya, V., Fadli, M., & Hermanto, D. (2024). Perancangan UI/UX Website Pengontrol Kelembapan Tanah Berbasis IoT dan Sensor. *MDP Student Conference*, 3(1), 71–78. <https://doi.org/10.35957/mdp-sc.v3i1.7278>
- Lestari, A. R., Santoso, R., & Suparti. (2024). ANALISIS SENTIMEN PENGGUNA ONLINE TRAVEL AGENT (OTA) PADA PERUSAHAAN PEGIPEGI.COM MENGGUNAKAN RANDOM FOREST. *Jurnal Gaussian*, 12(4), 616–624. <https://doi.org/10.14710/j.gauss.12.4.616-624>
- Mujawar, R. Y., Lakshminarayanan, R., P, J. A., Prabha P, S., Patnaik, S., & Dhayalini, K. (2023). IoT-Enabled Intelligent Irrigation System with Machine Learning-Based Monitoring, for Effective Rice Cultivation. *International Journal of Intelligent Systems and Applications in Engineering*, 12(11s), 557–565. <https://doi.org/10.1016/j.eti.2020.101132>
- Ningrum, N. K., Mulyono, I. U. W., Widyatmoko, K., & Umami, Z. (2023). Monitoring Kondisi Tanaman berdasarkan Data Kelembaban Tanah dan Suhu dan Kelembaban Udara Melalui Website Thinkspeak. *Prosiding Seminar Nasional Informatika*, 1(1), 586–593. <https://conference.upgris.ac.id/index.php/infest/article/view/3832>
- Palaniappan, R. (2024). Comparative Analysis of Support Vector Machine, Random Forest and k-Nearest Neighbor Classifiers for Predicting Remaining Usage Life of Roller Bearings. *Informatica*, 48(7), 39–52. <https://doi.org/10.31449/inf.v48i7.5726>
- Putri, A. L. R., Surarso, B., & SRRM, T. U. (2023). MICE Implementation to Handle Missing Values in Rain Potential Prediction Using Support Vector Machine Algorithm. *JTAM (Jurnal Teori Dan Aplikasi Matematika)*, 7(4), 1167–1167. <https://doi.org/10.31764/jtam.v7i4.16699>
- Qorni, Q. A., Pamungkas, D. P., Wibowo, S. A., & Hermanto, D. (2023). Pemantauan dan Peningkat Kondisi Kelembaban Lahan Menggunakan Esp8266 dan IoT. *MDP Student Conference*, 2(1), 226–233. <https://doi.org/10.35957/mdp-sc.v2i1.4056>
- Rabbani, S. F., Safitri, D. O., Rahmadhani, N., Sani, A. A. F., & Anam, M. K. (2023). Perbandingan Evaluasi Kernel SVM untuk Klasifikasi Sentimen dalam Analisis Kenaikan Harga BBM. *MALCOM Indonesian Journal of Machine Learning and Computer Science*, 3(2), 153–160. <https://doi.org/10.57152/malcom.v3i2.897>

- Rafrin, M., Agus, Muh., & Maharani, P. A. (2024). IoT-Based Irrigation System Using Machine Learning for Precision Shallot Farming. *Jurnal RESTI (Rekayasa Sistem Dan Teknologi Informasi)*, 8(2), 216–222. <https://doi.org/10.29207/resti.v8i2.5579>
- Rahmadini, LorencisLubis, E. E., Priansyah, A., R.W.N, Y., & Meutia, T. (2023). PENERAPAN DATA MINING UNTUK MEMPREDIKSI HARGA BAHAN PANGAN DI INDONESIA MENGGUNAKAN ALGORITMA K-NEAREST NEIGHBOR. *Jurnal Mahasiswa Akuntansi Samudra*, 4(4), 223–235. <https://doi.org/10.33059/jmas.v4i4.7074>
- Rahmi, F., Yanuar, F., & Asdi, Y. (2024). Penggunaan Metode Support Vector Machine (SVM) dalam Mengidentifikasi Tingkat Keparahannya Pada Kecelakaan Lalu Lintas. *STATISTIKA Journal of Theoretical Statistics and Its Applications*, 24(1), 1–10. <https://doi.org/10.29313/statistika.v24i1.1690>
- RAKHMAT, G. A., & MUTOHAR, W. (2023). Prakiraan Hujan menggunakan Metode Random Forest dan Cross Validation. *MIND (Multimedia Artificial Intelligent Networking Database) Journal*, 8(2), 173–187. <https://doi.org/10.26760/mindjournal.v8i2.173-187>
- Singh, S., & Bhardwaj, Dr. A. K. (2022). AN EFFICIENT MACHINE LEARNING INSPIRED SMART IRRIGATION SYSTEM FOR AGRICULTURE. *NeuroQuantology*, 20(13), 4366–4372. <https://doi.org/10.48047/NQ.2022.20.13.NQ88531>
- Sofia, Hidayat, G., Risyardha, Moh. A., & Rasyid, M. M. (2023). ANALISIS KETERSEDIAAN AIR PADA LAHAN PERTANIAN DAERAH PEMATANG PANJANG, KECAMATAN SUNGAI TABUK. *Jukung (Jurnal Teknik Lingkungan)*, 9(2), 55–62. <https://doi.org/10.20527/jukung.v9i2.17572>
- Subagja, F. E., Supriyadi, A. P., Kurniadi, A. R., & Saragih, Y. (2023). PENGUJIAN SISTEM PENYIRAMAN TANAMAN OTOMATIS BERBASIS IOT. *Infotronik : Jurnal Teknologi Informasi Dan Elektronika*, 8(2), 91–97. <https://doi.org/10.32897/infotronik.2023.8.2.3015>
- Sumarudin, A., Ismantohadi, E., Puspaningrum, A., Maulana, S., & Nadi, M. (2021). Implementation irrigation system using Support Vector Machine for precision agriculture based on IoT. *IOP Conference Series: Materials Science and Engineering*, 1098(3), 1–5. <https://doi.org/10.1088/1757-899x/1098/3/032098>
- Tace, Y., Tabaa, M., Elfilali, S., Leghris, C., Bensag, H., & Renault, E. (2022). Smart irrigation system based on IoT and machine learning. *Energy Reports*, 8, 1025–1036. <https://doi.org/10.1016/j.egy.2022.07.088>

- Yulianti, A., Fitri, F., Amalita, N., & None Dodi Vionanda, D. (2023). The SMOTE Application of CART Methods for Coping Imbalanced Data in Classifying Status Work on Labor Force in the City of Padang. *UNP Journal of Statistics and Data Science*, 1(3), 172–179. <https://doi.org/10.24036/ujsds/vol1-iss3/12>
- Zhu, T. (2020). Analysis on the Applicability of the Random Forest. *Journal of Physics: Conference Series*, 1607(1), 1–5. <https://doi.org/10.1088/1742-6596/1607/1/012123>
- Pradana, M. R., Hanafi, H., & Akbar, S. R. (2023). Klasifikasi Kesuburan dan Daya Ukur Cakupan Kelembaban Tanah pada Tanaman Jambu Merah berbasis Arduino. *Jurnal Pengembangan Teknologi Informasi Dan Ilmu Komputer*, 7(4), 1797–1809. <https://j-ptiik.ub.ac.id/index.php/j-ptiik/article/view/12592>

LAMPIRAN

