

PROPOSAL TUGAS AKHIR

PERANCANGAN SISTEM OTOMATISASI PENYIRAMAN
TANAMAN MENGGUNAKAN METODE MACHINE
LEARNING



Oleh:

Kevin Pratama 2024250070

PROGRAM STUDI INFORMATIKA
FAKULTAS ILMU KOMPUTER DAN REKAYASA
UNIVERSITAS MULTI DATA PALEMBANG
PALEMBANG
2024

PROPOSAL TUGAS AKHIR
PERANCANGAN SISTEM OTOMATISASI PENYIRAMAN
TANAMAN MENGGUNAKAN METODE
MACHINE LEARNING

HALAMAN PENGESAHAN

Disusun Oleh :

Kevin Pratama

NPM 2024250070

Disetujui Oleh :

Menyetujui,
Dosen Pembimbing Utama

Mengetahui,
Ketua Program Studi Informatika

Dedy Hermanto, S.Kom., M.T.I.
NIK.

Derry Alamsyah, S.Si., M.Kom., M.Pd.
NIK. 111069

KATA PENGANTAR

Dengan ini saya mengucapkan puji syukur kepada Tuhan Yang Maha Esa atas segala rahmat dan karunia, yang telah memungkinkan saya sebagai penulis untuk menyelesaikan Proposal Tugas Akhir dengan judul “Perancangan Sistem Otomatisasi Penyiraman Tanaman Menggunakan Metode Machine Learning”

Saya ingin mengucapkan terima kasih kepada semua pihak yang telah membantu saya dalam proses penulisan proposal ini, baik secara langsung maupun tidak langsung. Terima kasih juga kepada mereka yang telah memberikan bimbingan, arahan, dan ide selama proses penulisan proposal Tugas Akhir, terutama kepada:

1. Bapak Dr. Johannes Petrus, S.Kom., M.T.I., selaku Rektor Universitas Multi Data Palembang.
2. Ibu Yulistia, S.Kom., M.T.I., selaku Wakil Rektor I Universitas Multi Data Palembang.
3. Ibu Kathryn Sugara, S.E., M.Si., selaku Wakil Rektor II Universitas Multi Data Palembang.
4. Bapak Dedy Hermanto, S. Kom., M.T.I., selaku Wakil Rektor III Universitas Multi Data Palembang.
5. Ibu Charisma Ayu P, M.HRM., selaku Wakil Rektor IV Universitas Multi Data Palembang.
6. Bapak Dr. Wijang Widhiarso, M.Kom., selaku Dekan Fakultas Ilmu Komputer dan Rekayasa.
7. Ibu Yoanita, M.Kom. Wakil Dekan Fakultas Ilmu Komputer dan Rekayasa
8. Bapak Derry Alamsyah, S.Si., M.Kom., M.Pd., selaku Ketua Program Studi informatika
9. Bapak Daniel Udjulanawa, S.Kom.,M.T.I., selaku Pembimbing Akademik.
10. Bapak Dedy Hermanto, S. Kom., M.T.I., selaku Pembimbing tugas akhir yang telah memberikan arahan, saran, dan motivasi yang sangat berharga dalam proses penyusunan Proposal Tugas Akhir.

11. Keluarga dan teman-teman yang telah memberikan dukungan dan saran selama proses pengerjaan tugas akhir.
12. Terima kasih kepada Aldo Kadafi, Muhammad Fadli dan Kartiva yang telah membantu saya menyelesaikan proposal saya ini.

Laporan ini diharapkan dapat memberikan solusi yang efektif dan mengurangi beban permasalahan yang dihadapi oleh masyarakat, sekaligus memberikan panduan yang berguna bagi mahasiswa Universitas Multi Data Palembang dan Universitas lainnya dalam menyusun Tugas Akhir yang lebih baik di masa depan.

Palembang, 18 Maret 2024

Penulis

DAFTAR ISI

HALAMAN JUDUL	I
HALAMAN PENGESAHAN	II
KATA PENGANTAR.....	III
DAFTAR ISI.....	V
DAFTAR TABEL	VII
DAFTAR GAMBAR	VIII
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	6
1.3 Analisis Terhadap Batasan	6
1.3.1 Analisis dari Aspek Ekonomis.....	6
1.3.2 Analisis dari Aspek Manufakturabilitas	8
1.3.3 Analisis dari Aspek Sustainbilitas	9
1.4 Analisis Terhadap Karakteristik Solusi	10
1.5 Pemilihan Solusi	11
1.6 Skenario Pemanfaatan Produk Oleh Pengguna.....	14
1.7 Tujuan.....	14
BAB II PEMILIHAN SOLUSI	16
2.1 Alternatif Solusi	16
2.1.1 K-Nearest Neighbors	16
2.1.2 Support Vector Machine	18
2.1.3 Random Forest.....	22
2.2 Analisis Pemilihan Solusi	24
BAB III METODOLOGI	29

3.1	Identifikasi Masalah	29
3.2	Analisis Solusi.....	30
3.3	Pengumpulan Data	31
3.4	<i>Preprocessing</i> Data	32
3.5	Perancangan <i>Random Forest</i>	33
3.6	Pengujian.....	34
3.7	Implementasi Model <i>Random Forest</i>	36
3.8	Hasil	37
BAB IV PERANCANGAN.....		38
4.1	Spesifikasi Solusi	38
4.2	Rencana Pengujian	39
4.3	Perancangan Sistem	40
4.3.1	Perancangan Aplikasi Mobile.....	40
4.3.2	Perancangan Model Random Forest.....	41
4.3.3	Perancangan Sistem Perangkat Keras.....	42
4.4	Proses Verifikasi Perancangan	48
DAFTAR PUSTAKA.....		50
LAMPIRAN.....		58

DAFTAR TABEL

Tabel 1.1 Analisis dari Aspek Ekonomis.....	6
Tabel 1.2 Analisis dari Aspek Manufakturabilitas	8
Tabel 1.3 Analisis dari Aspek Ekonomis.....	10
Tabel 1.4 Analisis dari Karakteristik Solusi.....	10
Tabel 2.2 Analisis Pemilihan Solusi.....	24
Tabel 3.3 Penjelasan Atribut pada Data Irigasi	31
Tabel 3.4 Kategori pada Kelembaban Tanah.....	32
Tabel 3.5 Kategori pada Suhu Udara	33
Tabel 3.6 Kategori pada Kelembaban Udara	33
Tabel 4.1 Penjelasan Atribut Verifikasi Perancangan.....	48

DAFTAR GAMBAR

Gambar 2.1 K-Nearest Neighbors.....	17
Gambar 2.2 Support Vector Machine.....	19
Gambar 2.3 Random Forest	23
Gambar 3.1 Alur Metodologi Penelitian.....	29
Gambar 3.2 Confusion Matrix	35
Gambar 4.1 Rancangan Aplikasi Mobile	41
Gambar 4.2 Rancangan Random Forest.....	42
Gambar 4.3 Mikrokontroler ESP32	43
Gambar 4.4 Sensor Capacitive Soil Moisture Sensor	44
Gambar 4.5 Sensor DHT22.....	44
Gambar 4.6 Relay.....	45
Gambar 4.7 Rancangan Sistem Mikrokontroler ESP32.....	46
Gambar 4.8 Cara Kerja Sistem Irigasi Cerdas	47

BAB I

PENDAHULUAN

1.1 Latar Belakang

Pertanian adalah kegiatan yang dilakukan oleh individu maupun kelompok untuk menghasilkan berbagai bahan dari sumber daya alam yang dapat memenuhi kebutuhan pokok dan tambahan manusia (Kynta, 2024). Salah satu sub sektor pertanian adalah hortikultura, merujuk pada kegiatan budidaya tanaman di pekarangan atau kebun untuk memenuhi kebutuhan sehari-hari seperti sayuran, buah-buahan, dan tanaman hias (Bharata, 2023).

Jumlah keterlibatan rumah tangga dalam kegiatan pertanian di Indonesia mengalami kenaikan 8,74% dengan 28.419.396 rumah tangga (Badan Pusat Statistik, 2023). Hal ini yang menunjukkan sektor memiliki peran penting dalam menghasilkan bahan pangan dan baku untuk kebutuhan masyarakat dan industri.

Umumnya, Tanaman dapat ditanam di berbagai daerah dengan daratan yang rendah maupun tinggi. Namun, petani masih mengandalkan musim hujan sebagai waktu yang tepat untuk memulai menanam (Makmur, 2023). Hal ini dikarenakan kelembaban tanah memiliki peranan yang penting dalam menyimpan ketersediaan air yang diperlukan bagi tanaman (Hermanto, 2023).

Kondisi kelembaban tanah dapat dipengaruhi berbagai faktor seperti curah hujan, jenis tanah, dan laju evapotranspirasi (Hermanto, 2023). Pada dasarnya Evapotranspirasi terdiri dari dua komponen, yaitu evaporasi sebagai proses penguapan air dari jaringan tanaman menjadi uap, sedangkan transpirasi sebuah proses penguapan air dari permukaan tanah (Sofia, 2023). Laju evapotranspirasi

sangat dipengaruhi dari faktor-faktor tertentu seperti iklim dan jenis tanaman (Fausan, 2021). Oleh karena itu, ketersediaan air dalam tanah menjadi sumber kebutuhan tanaman yang penting untuk menggantikan cairan tanaman yang hilang selama proses tersebut.

Dalam kegiatan pengelolaan kelembaban tanah sangat penting untuk menjaga tanaman tetap sehat dan tumbuh dengan baik, sehingga menghasilkan panen yang maksimal. Kelembaban tanah yang tidak teratur dapat menghambat pertumbuhan tanaman bahkan dapat menyebabkan gagal panen (Hermanto, 2023). Untuk memenuhi kebutuhan air, penyiraman tanaman harus dilakukan yang sesuai dengan tingkat kelembaban tanah (Subagja, 2023).

Namun hingga saat ini, proses menyiram tanaman masih dilakukan secara manual dengan alat sederhana. Hal ini menjadi masalah ketika jumlah tanaman yang dirawat cukup banyak, sehingga kesulitan dalam pemberian air secara merata. Selain itu, pemilik tanaman sering meninggalkan tanaman dalam waktu yang lama tanpa pengawasan, yang dapat menyebabkan tanaman mati akibat kurangnya perawatan yang diperlukan (Hasani, 2023).

Mereka sering mengandalkan pengetahuan dan pengalaman pribadi dalam menentukan jumlah air dan waktu yang dibutuhkan untuk memulai menyiram tanaman (Anggarda, 2023). Namun, perubahan iklim secara mendadak membuat prediksi lahan menjadi tidak akurat (Ningrum, 2023). Kondisi ini mengakibatkan pengelolaan tanaman menjadi kurang efisien dan pemborosan, serta menurunnya produktivitas pertanian (Anggarda, 2023).

Hasil wawancara yang dilakukan dengan Syamsul Bahri, selaku pemilik Toko Panen Raya Cinde menjelaskan bahwa petani menghadapi kendala seperti ketidakpastian musim, peningkatan hama, dan keterbatasan air yang sering mengakibatkan kegagalan panen. Hal ini berdampak pada usaha dalam sektor pertanian, seperti penurunan pendapatan dan motivasi yang dapat mengancam keberlangsungan usaha pertanian.

Hasil wawancara yang dilakukan dengan Havizman SP., M.Si., selaku kepala bidang produksi Dinas Perkebunan Sumatera Selatan, mengungkapkan bahwa petani kesulitan dalam memantau tanaman karena keterbatasan alat dan menyiram tanaman masih dilakukan secara tradisional yang menguras biaya tenaga kerja. Kondisi ini menyebabkan pengaturan air yang tidak akurat, sehingga tanaman rentan terkena penyakit dan lambatnya pertumbuhan.

Hasil wawancara yang dilakukan dengan Kemas Muhammad Ridhuan, selaku penyuluh pertanian UPTD Balai Pengembangan Dan Produksi Benih Tanaman Pangan Dan Hortikultura, mengatakan memantau musim dan kelembaban tanah secara manual dianggap tidak efisien dan bergantung pada fisik. Ketergantungan pada teknik ini sering kali mengalami kegagalan panen yang berdampak krisis ekonomi, terutama adanya fenomena alam seperti El Nino, yang semakin memperburuk efisiensi dalam mengelola tanaman.

Hasil wawancara yang dilakukan dengan Lili Rozali, S.Kom., SP, selaku kasubbag umum dan kepegawaian Dinas Pertanian Tanaman Pangan dan Hortikultura Provinsi Sumatera Selatan, menjelaskan penggunaan cangkul untuk mengukur kadar air dalam tanah dan membuat saluran irigasi selain selang dinilai

memakan waktu dan tenaga. Selain itu, metode manual yang menyebabkan pemberian air dan pupuk pada tanaman menjadi tidak sesuai, hingga mengakibatkan pertumbuhan tanaman menjadi kurang optimal.

Hasil wawancara yang dilakukan dengan Denny Satria Mandala Putra, selaku direktur Quranic Farm, menjelaskan pengukuran kelembaban tanah secara manual memakan waktu lama, terutama di lahan luas. Selama musim kemarau, petani kesulitan menyiram tanaman secara merata dan harus mengeluarkan tenaga ekstra untuk membawa selang. Situasi ini dapat meningkatkan risiko penyakit pada tanaman akibat kelebihan air dan pertumbuhan yang tidak merata.

Hasil wawancara yang dilakukan dengan Ir. Sahat Simanjuntak, M.Si. selaku manajer penjualan regional di CV. Jaya Agung, menjelaskan selama proses mengelola tanaman petani sering dihadapkan keterbatasan sumber air, waktu, dan tenaga kerja. Teknik perawatan tanaman dilakukan secara konvensional ini dinilai tidak efisien dalam tenaga kerja dan pengeluaran biaya.

Kemajuan teknologi seperti *internet of things* dan kecerdasan buatan telah memberikan manfaat yang positif di berbagai sektor pertanian. Salah satu cabang dari kecerdasan buatan yang banyak digunakan adalah *machine learning*. *Machine learning* adalah kemampuan mesin untuk belajar dan melakukan prediksi atau mengambil keputusan secara otomatis berdasarkan data yang tersedia. Pertanian modern sangat membutuhkan teknologi, terutama dalam pengelolaan irigasi maupun penyiraman tanaman (Anggarda, 2023).

Perancangan sistem otomatisasi penyiraman atau irigasi cerdas dengan *internet of things* dari penggabungan dari internet sebagai jaringan komputer dan

things sebagai objek fisik (Hermanto, 2023). Teknologi ini yang diterapkan pada sistem ini memungkinkan petani bisa memantau dan mengelola penyiraman atau irigasi secara jauh. Tidak hanya itu, sistem ini juga dilengkapi fitur untuk melakukan penyiraman tanaman secara otomatis (Omega, 2023).

Sistem ini menggunakan berbagai sensor seperti stasiun *Automatic Weather Stations* (AWS), kelembaban tanah dan sensor faktor lingkungan lainnya yang dapat memengaruhi pertumbuhan tanaman. Setiap sensor melakukan pengumpulan data dan dikirimkan ke mikrokontroler untuk pemantauan dan melakukan prediksi penyiraman tanaman (Kaur, 2024). Penerapan machine learning, sistem melakukan prediksi penyiraman tanaman dengan rekomendasi waktu dan kebutuhan air pada tanaman berdasarkan data cuaca, kelembaban tanah, dan faktor-faktor lainnya memengaruhi tanaman (Anggarda, 2023).

Penggunaan sistem otomatisasi penyiraman atau irigasi cerdas yang berbasis *machine learning* memberikan keuntungan bagi petani. Pertama, sistem ini dapat menghemat waktu dan usaha petani dalam mengukur jumlah air yang diperlukan dan menyiram tanaman. Kedua, tingkat akurasi tinggi sistem ini dapat membantu petani dalam mengurangi pemborosan dan mengoptimalkan pengguna air. Ketiga, sistem memberikan rekomendasi yang akurat, untuk memastikan ketersediaan air tanaman tetap terjaga (Anggarda, 2023).

Sistem otomatisasi penyiraman atau irigasi cerdas tanaman, sebagaimana dijelaskan dalam latar belakang, memberikan kontribusi besar dalam mendukung petani untuk mengelola lahan secara lebih efisien. Teknologi tidak hanya

menawarkan kemudahan dan penghematan, tetapi juga mendukung upaya berkelanjutan di sektor pertanian.

1.2 Rumusan Masalah

Sebagaimana masalah yang ditemukan dalam latar belakang, pengelolaan lahan mereka secara tradisional dinilai tidak efisien dan sering terjadi kesalahan dalam pemberian air tanaman, bahkan mendistribusi air yang tidak merata. Petani tidak bisa meninggalkan tanaman dengan waktu yang lama. Kondisi ini tentunya dirugikan petani, sehingga mengakibatkan kegagalan panen dan penurunan produktivitas pertanian. Oleh karena itu, perlunya digitalisasi pertanian, seperti sistem otomatisasi penyiraman atau irigasi cerdas tanaman.

1.3 Analisis Terhadap Batasan

1.3.1 Analisis dari Aspek Ekonomis

Analisis aspek ekonomis dilakukan untuk menilai keterbatasan ekonomi dari sebuah produk yang akan dikembangkan. Untuk analisis tersebut, perangkat keras akan dijual dengan harga berkisar Rp 200.000 – Rp 800.000, Sementara itu, berlangganan bulanan ditetapkan pada kisaran Rp 10.000 – Rp 50.000. Tabel 1.1 menampilkan hasil penjualan produk yang disepakati melalui hasil wawancara yang telah dilakukan dengan sejumlah organisasi.

Tabel 1.1 Analisis dari Aspek Ekonomis

No.	Organisasi	Aspek Ekonomis
1	Toko Panen Raya	Untuk harga perangkat keras diberikan berkisar Rp 600.000 sampai Rp 800.000, namun bagi petani

		ingin harga penjualan produk semurah mungkin. Sementara langganan bulanan mulai dari Rp 20.000 per bulan.
2	Dinas Perkebunan Provinsi Sumatera Selatan	Harga perangkat keras yang diusulkan mulai dari Rp 300.000 – Rp 500.000, sedangkan berlangganan berkisar Rp 15.000 sampai Rp 30.000 per bulan.
3	UPTD Balai Pengembangan dan Produksi Benih Tanaman Pangan dan Hortikultura	Untuk perangkat keras dan langganan setiap bulan masih belum bisa ditentukan, karena hardware dan software perlu dievaluasi dan demonstrasi terlebih dahulu pada dinas pertanian dan pengguna.
4	Dinas Pertanian Tanaman Pangan dan Hortikultura	Saat ini, biaya layanan berlangganan diusulkan Rp 10.000 per bulan. Namun perangkat keras harus didemonstrasikan dengan mempertimbangkan akurasi, kompleksitas, dan manfaat yang diberikan bagi petani, serta kebutuhan perangkat dan kualitas layanan internet.
5	Qur'anic Farm	Untuk harga perangkat lunak harus sepadan dengan manfaat bagi petani. Sedangkan langganan bulanan yang diusulkan mulai dari Rp 20.000 per bulan.
6	CV Jaya Agung	Harga perangkat keras ditetapkan Rp 300.000, sementara biaya berlangganan adalah Rp 10.000 per bulan.

Seperti yang terlihat pada 1.1, biaya perangkat keras yang diusulkan bervariasi antara Rp 300.000 – Rp. 800.000, beberapa usulan memiliki biaya yang

lebih rendah bahkan gratis. Biaya layanan berlangganan yang diusulkan juga bervariasi antara Rp. 10.000 – Rp 30.000 per bulan. Namun, biaya penjualan tidak bisa ditentukan secara langsung, dikarenakan produk seperti perangkat dan langganan harus dievaluasi lebih lanjut untuk memastikan manfaat yang diberikan petani harus sepadan dengan biaya penjualan. Maka dari itu produk harus diuji coba terlebih dahulu sebelum biaya penjualan akhir ditetapkan.

1.3.2 Analisis dari Aspek Manufakturabilitas

Aspek manufakturabilitas memainkan peranan yang penting dalam menetapkan jadwal yang realistis dalam pengembangan produk. Hal ini mencakup penentuan batas waktu yang harus dipatuhi untuk menyelesaikan produk secara efisien. Tabel 1.2 menjelaskan hasil jadwal *deadline* dalam merancang produk yang sudah ditentukan oleh masing-masing organisasi.

Tabel 1.2 Analisis dari Aspek Manufakturabilitas

Aspek	Toko Panen Raya	Dinas Perkebunan Provinsi Sumatera Selatan	UPTD Balai Pengembangan dan Produksi Benih Tanaman Pangan dan Hortikultura	Dinas Pertanian Tanaman Pangan dan Hortikultura	Dinas Pertanian Tanaman Pangan dan Hortikultura	CV. Jaya Agung
Membangun Perangkat Keras (1 Bulan)	✓	✓	✓	✓	✓	✗
Membangun Database (3 Minggu)	✓	✓	✓	✓	✓	✗

Membangun Aplikasi (1 Bulan)	✓	✓	✓	✓	✓	✓
Implementasi Kecerdasan Buatan (1 Bulan)	✓	✓	✓	✓	✓	✓
Membangun Server (1 Bulan)	✓	✓	✓	✓	✓	✓
Final (1 Bulan)	✓	✓	✓	✓	✓	✓
Total Waktu Pengerjaan	5 Bulan 3 Minggu					

Pada Tabel 1.2 menunjukkan bahwa sebagian besar organisasi setuju dengan jadwal *deadline* pengembangan produk yang berbagai tahapan. Namun, CV. Jaya Agung berpendapat bahwa *deadline* pengembang perangkat keras harus disesuaikan dengan kebutuhan petani, seperti luas lahan yang diawasi, dan waktu pembangunan database harus mempertimbangkan data yang diperlukan petani.

1.3.3 Analisis dari Aspek Sustainbilitas

Aspek sustainbilitas dilakukan untuk menilai sejauh mana produk dapat mempertahankan manfaat bagi pengguna, sekaligus menjaga reputasi yang positif. Untuk memulai proses evaluasi sustainbilitas, pengguna diberikan hak uji coba gratis selama dua bulan. Tabel 1.3 menguraikan hasil kesepakatan sustainbilitas produk yang ditetapkan oleh setiap organisasi.

Tabel 1.3 Analisis dari Aspek Ekonomis

Aspek	Toko Panen Raya	Dinas Perkebunan Provinsi Sumatera Selatan	UPTD Balai Pengembangan dan Produksi Benih Tanaman Pangan dan Hortikultura	Dinas Pertanian Tanaman Pangan dan Hortikultura	Dinas Pertanian Tanaman Pangan dan Hortikultura	CV Jaya Agung
Sistem irigasi cerdas dapat digunakan selama 2 bulan (ketahanan produk)	✓	✓	✓	✓	✓	✓

1.4 Analisis Terhadap Karakteristik Solusi

Pada Tabel 1.4 akan menjelaskan mengenai masalah yang dihadapi petani dan solusi yang telah ditemukan untuk mengatasi masalah tersebut.

Tabel 1.4 Analisis dari Karakteristik Solusi

No.	Masalah	Fungsi
1	Petani menghadapi tantangan dalam mengukur kelembaban tanah dan kondisi cuaca secara manual	Sistem ini menggunakan sensor kelembaban tanah dan sensor cuaca (AWS) yang real-time, sehingga memberikan data yang presisi dan terkini
2	Jumlah tanaman yang perlu disiram cukup banyak, petani merasa kesulitan menyiram secara merata	Sistem ini dapat menyiram tanaman secara merata ke seluruh lahan, dengan membangun jaringan air dan pompa air
3	Petani tidak bisa meninggalkan lahan yang terlalu lama karena meningkatkan risiko kematian pada tanaman	Penerapan <i>internet of things</i> dan <i>machine learning</i> memungkinkan petani dapat meninggalkan tanaman yang cukup lama

4	Metode tradisional dalam memelihara tanaman dapat memerlukan waktu, tenaga, dan biaya yang cukup besar, bahkan menurunkan produktivitas pertanian	Sistem ini menggunakan teknologi hibrida modern seperti <i>internet of things</i> dan <i>machine learning</i> , dapat meningkatkan efisiensi dan produktivitas pertanian
5	Petani kesulitan menentukan kebutuhan air untuk memulai menyiram tanaman	Penerapan kecerdasan buatan seperti machine learning dalam suatu sistem dapat melakukan prediksi, memberikan rekomendasi, dan menyiram secara otomatis

1.5 Pemilihan Solusi

Dalam perancangan sistem irigasi cerdas dengan teknologi kecerdasan buatan, setidaknya tiga metode machine learning yang akan dipertimbangkan, yaitu *K-Nearest Neighbors* (KNN), *Support Vector Machine* (SVM), dan *Random Forest* (RF). Pemilihan metode dilakukan dengan meninjau jurnal penelitian yang membahas pengguna metode *machine learning*, karakteristik dataset, tahapan *preprocessing* data yang dilakukan, dan *hyperparameter tuning*.

Penelitian yang pertama kali dilakukan oleh (Tace, 2022) dalam mengembangkan sistem irigasi cerdas berbasis IoT dan ML dapat menghemat pengguna air dan pengeluaran biaya. Data diperoleh dari sensor mengukur kelembaban tanah, suhu udara, kelembaban, serta curah hujan. Hasil dari metode *K-Nearest Neighbors* dengan $k = 3$ menunjukkan akurasi sebesar 98,3% dan RMSE 0,12.

Penelitian yang kedua dilakukan oleh (Singh, 2022) menunjukkan *Random Forest* (RF) mencapai akurasi 85%, *precision* 88%, *recall* 82%, dan *f1-score* 85%. Sementara *Support Vector Machine* (SVM) menghasilkan kinerja yang lebih baik dengan akurasi 90%, *precision* 92%, *recall* 88%, dan *f1-score* 90%.

Penelitian yang ketiga dilakukan oleh (Abo-Zahhad, 2023) menggunakan dataset yang mencakup parameter lingkungan seperti kelembaban tanah, suhu, dan kelembaban udara. Dataset tersebut digunakan untuk klasifikasi kebutuhan irigasi yang memiliki lima kategori klasifikasi yaitu, *not needed*, *not needed*, *average*, *needed*, dan *highly needed*. Klasifikasi KNN dengan parameter $k = 5$ dan *euclidean distance* menghasilkan akurasi sebesar 98,6% dan *Root Mean Square Error* (RMSE) sebesar 0,10. Hasil ini menunjukkan kinerja KNN dapat memprediksi kebutuhan irigasi pada tanaman.

Penelitian yang keempat dilakukan oleh (Mujawar, 2023) untuk memantau dan memprediksi kebutuhan air pada lahan pertanian padi. Sistem ini dirancang untuk mengoptimalkan irigasi berdasarkan kondisi lingkungan secara real-time dengan harapan dapat meningkatkan produktivitas pertanian padi. Parameter utama yang digunakan dalam penelitian ini meliputi kelembaban tanah, suhu, kelembaban udara, dan tingkat ketinggian air. Hasil penelitian menunjukkan SVM menghasilkan akurasi 93,2%, sementara RF menunjukkan akurasi sebesar 86,5%, mengindikasikan SVM memiliki performa yang lebih baik dalam memprediksi kebutuhan irigasi pada skenario tersebut.

Penelitian kelima yang dilakukan oleh (Kaur, 2024) menggunakan data yang diperoleh dari sensor kelembaban tanah, suhu, kelembaban udara, dan aktivitas pompa. Kemudian data tersebut dibagi menjadi 80% untuk pelatihan dan 20% untuk pengujian. Hasil klasifikasi RF mencapai akurasi sebesar 99,8%, sementara SVM dengan *kernel linear* dan KNN dengan *manhattan distance* dan $k = 5$ masing-

masing mencapai akurasi 99,3%. Hal ini menunjukkan bahwa akurasi klasifikasi *Random Forest* lebih unggul dari SVM dan KNN.

Penelitian keenam yang dilakukan oleh (Rafrin, 2024) menggunakan data berisi 1.387 sampel yang meliputi kelembaban tanah, temperatur, dan kelembaban udara masing-masing mewakili tiga kelas. Data tersebut kemudian dibagi menjadi 70% untuk pelatihan dan 30% untuk pengujian. Metode *Random Forest* dengan *hyperparameter* seperti 100 pohon, *min_samples_split*: 2, dan *gini index* menghasilkan akurasi mencapai 94%.

Penelitian ketujuh yang dilakukan oleh (Bhavani, 2022) menggunakan metode *preprocessing* data seperti *K-Means Clustering* untuk membagi data menjadi dua kelompok, yaitu *needs irrigation* dan *not needed*. Hasil klasifikasi metode SVM menunjukkan akurasi sebesar 89,11%, *precision* sebesar 90,01%, dan *recall* sebesar 87,03%. Sementara metode KNN mencapai akurasi 91,05%, *precision* 92,16%, dan *recall* 91,11%.

Penelitian kedelapan yang dilakukan oleh (Sumarudin, 2021) menunjukkan bahwa dataset yang digunakan terdiri dari tiga kelas pada kolom label, yaitu 10% katup terbuka, 25% katup terbuka, dan 50% katup terbuka. Dataset tersebut dibagi menjadi 90% untuk *training* dan 10% untuk *testing*. Metode *Support Vector Machine* (SVM) dengan kernel *linear*, *gamma auto*, dan *cost* (C) = 2 menghasilkan akurasi sebesar 95%, *precision* 94,3%, *recall* 91%, dan *f1-score* 92,7%.

Penelitian kesembilan yang dilakukan oleh (Kumar, 2024) menerapkan *Correlation-Based Feature Selection* (CFS) dan *K-Means Clustering*. Metode SVM dengan kernel *radial basic function* (*rbf*) menghasilkan akurasi 98,5, *precision*

98,3%, *recall* 99,6%, *f1-score* 97%, dan *specificity* 98,7%. Penerapan metode SVM berhasil menghemat penggunaan air hingga 42% dibandingkan dengan metode irigasi tradisional.

Penelitian kesepuluh yang dilakukan oleh (IORLIAM, 2022) dengan menggunakan 100.000 sampel data yang mencakup kelembaban tanah, suhu, kelembaban udara, dan waktu, serta label status pompa (*On* = 1, *Off* = 0). Dataset ini dibagi menjadi 70% untuk *training* dan 30% untuk *testing*. Metode RF dengan 100 pohon dan *gini index* menghasilkan akurasi 99,98%, *precision* 99,96%, *recall* 99,99%, dan *f1-score* 99,97%.

1.6 Skenario Pemanfaatan Produk Oleh Pengguna

Pada proyek ini untuk perangkat keras yang terdiri dari sensor dan mikrokontroler. Dalam sistem ini, sensor ini akan mengumpulkan data secara *real-time* dan akurat, seperti suhu dan kelembaban, serta sensor lainnya. Data ini dikirimkan ke sistem untuk memantau tanaman dan memprediksi penyiraman tanaman secara otomatis. Untuk perangkat lunak akan digunakan petani dalam memantau dan mengatur irigasi melalui jarak jauh dengan koneksi internet, tidak hanya itu aplikasi dapat dipakai untuk manajemen berbagai perangkat keras.

1.7 Tujuan

Tujuan dari capstone project untuk membangun dan memperkenalkan sistem otomatisasi penyiraman atau irigasi cerdas tanaman dengan teknologi berbasis *internet of things* dan *machine learning* yang menyediakan solusi untuk membantu

petani dalam mengelola lahan, khususnya penyiraman atau irigasi pada tanaman yang sudah dijelaskan sebelumnya.

BAB II

PEMILIHAN SOLUSI

2.1 Alternatif Solusi

2.1.1 K-Nearest Neighbors

Solusi pertama adalah menggunakan *K-Nearest Neighbors* (KNN) sebagai metode *supervised learning* yang sederhana dalam *machine learning*. Metode ini bekerja dengan mengklasifikasikan data baru berdasarkan kesamaan dengan data yang telah dilatih sebelumnya, di mana kesamaan tersebut dihitung dari jarak antara data menggunakan nilai k sebagai jumlah tetangga terdekat (Kaur, 2024).

Dalam menentukan kesamaan berdasarkan jumlah tetangga terdekat, KNN mengukur jarak antara data latih dan uji menggunakan jenis perhitungan jarak (Tace, 2022). Salah satu metrik jarak yang digunakan adalah persamaan *manhattan* yang didefinisikan persamaan sebagai berikut:


$$d(x, y) = \sum_{i=1}^n |x_i - y_i| \quad (2.1)$$

di mana $d(x, y)$ adalah jarak antara vektor x (data pelatihan) dan y (data pengujian), n adalah jumlah atribut, dan i adalah indeks atribut.

Kelebihan KNN terletak pada kesederhanaan dalam menentukan parameter jumlah tetangga terdekat (k) dan metode pengukuran jarak. Metode ini mampu mengelola sampel data yang besar, meski dapat berdampak pada waktu pemrosesan (Abaye, 2020). Namun, pemilihan nilai k harus dipertimbangkan dengan teliti. Nilai k yang kecil sangat rentan terhadap *noise* dan menyebabkan overfitting.

Sementara nilai k yang besar dapat mengurangi pengaruh dari *noise*, meskipun meningkatkan kompleksitas komputasi (Cholil, 2021).

Kelemahan utama dari KNN ketergantungannya pada kualitas dan ukuran dataset. Metode ini sangat sensitif *outlier* dan data yang hilang (*missing*), serta kurang cocok untuk data yang berdimensi tinggi (Rahmadini, 2023). KNN memerlukan komputasi yang intensif dan waktu pemrosesan akan meningkat seiring dengan penambahan ukuran dataset (Abaye, 2020).



Gambar 2.1 K-Nearest Neighbors

Gambar 2.1 menunjukkan metode *K-Nearest Neighbors* (KNN) terdiri dari beberapa tahapan dalam proses klasifikasi, yaitu:


1. Memilih parameter jumlah tetangga terdekat (k).
2. Menghitung jarak setiap data uji dengan data latih menggunakan persamaan *manhattan distance*.
3. Mengurutkan hasil perhitungan jarak *manhattan* dimulai dari yang terkecil hingga yang terbesar.
4. Mengklasifikasikan data uji berdasarkan kelas mayoritas yang paling sering muncul dari (k) tetangga terdekat.

Pada solusi pertama, perancangan sistem irigasi cerdas menggunakan *K-Nearest Neighbors* (KNN), parameter yang digunakan adalah $k = 5$ dan jenis jarak yang digunakan adalah *manhattan*. Dataset ini dibagi menjadi 80% data latih dan 20% data uji, menghasilkan akurasi sebesar 99,8% (Kaur, 2024).

2.1.2 Support Vector Machine

Solusi kedua adalah menggunakan *Support Vector Machine* (SVM) sebagai metode *supervised learning* dalam *machine learning*, yang mampu menyelesaikan masalah klasifikasi dan regresi. SVM bekerja dengan mencari *hyperplane* terbaik yang memisahkan dua kelas dengan memaksimalkan margin. Metode ini mampu memisahkan data secara linier maupun non-linier. SVM memiliki kelebihan dalam menghasilkan generalisasi yang tinggi, tahan terhadap noise dan outlier, serta mampu mengelola data yang tidak seimbang. Tidak hanya itu, SVM dapat menangani data berdimensi tinggi dengan jumlah sampel terbatas (Abaye, 2020).

Kelemahan dari SVM adalah tidak cocok untuk himpunan data dengan jumlah sampel dan dimensi yang besar. Kinerja SVM dipengaruhi dalam pemilihan *kernel* dan nilai regulasi C , sehingga akurasi, kebutuhan komputasi dan waktu pemrosesan bervariasi (Abaye, 2020).



Gambar 2.2 Support Vector Machine

Gambar 2.2 menunjukkan proses kerja dalam menentukan *hyperplane* dan memaksimalkan *margin*. SVM terdiri dari tiga komponen utama, yaitu *hyperplane* sebagai bidang pemisah terbaik antara dua kelas, *margin* yang merupakan jarak *hyperplane* dan jarak terdekat dari masing-masing kelas, serta *support vector* yang merupakan data yang paling dekat dengan *hyperplane* (Junus, 2023).

Proses pelatihan SVM dimulai dengan himpunan data pelatihan $(x_1, y_1), (x_2, y_2), \dots, (x_i, y_i)$, di mana $x_i \in R^n$ mewakili vektor fitur, dan $y_i \in R^n$ menunjukkan label kelas. Kedua kelas dapat memisahkan dengan sempurna oleh *hyperplane*, yang didefinisikan dengan persamaan:

$$w^T \cdot x + b = 0 \quad (2.2)$$

di mana w adalah vektor bobot yang terkait dengan masing-masing fitur data, x adalah vektor fitur data, dan b adalah nilai bias.

Tujuan dari SVM adalah menemukan *hyperplane* yang memaksimalkan *margin*, yaitu jarak antara dua kelas terhadap *hyperplane*. *Margin* tersebut dihitung sebagai $\frac{2}{\|w\|}$, di mana $\|w\|$ merupakan norma dari vektor bobot w .

Untuk menemukan *hyperplane* terbaik, dilakukan proses optimasi melalui *Quadratic Programming* dengan meminimalkan:

$$\min \frac{1}{2} \|w\|^2 \quad (2.3)$$

dengan syarat:

$$y_i(w \cdot x_i + b) \geq 1, \quad i = 1, 2, 3, \dots, n \quad (2.5)$$

Optimalisasi dapat diselesaikan dengan menerapkan metode *lagrange multiplier* sebagai berikut:

$$L_p(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i [y_i(w \cdot x_i + b) - 1] \quad (2.6)$$

di mana $\alpha_i \geq 0$ adalah nilai *lagrange multiplier*.

Untuk memperoleh nilai optimal dari w dan b , dilakukan penurunan fungsi L_p terhadap w dan b , kemudian diubah menjadi nilai nol, sehingga menghasilkan syarat optimal sebagai berikut:

$$\frac{\delta L}{\delta w} = 0 \rightarrow \sum_{i=1}^n \alpha_i x_i y_i = w \quad (2.7)$$

$$\frac{\delta L}{\delta b} = 0 \rightarrow \sum_{i=1}^n \alpha_i y_i = 0 \quad (2.8)$$

Persamaan *lagrange multiplier* diubah dengan substitusi turunan dari persamaan (2.7) dan (2.8), sehingga membentuk dualitas *lagrange*. Kemudian memaksimalkan dengan persamaan berikut:

$$\max_{\alpha} L_d = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) \quad (2.9)$$

dengan syarat: $\alpha_i \geq 0$; $i = 1, 2, 3, \dots, n$; $\sum_{i=1}^n \alpha_i y_i = 0$.

Hasil dari persamaan (2.9) adalah $\alpha_i > 0$, yang disebut sebagai *support vectors* untuk menentukan posisi *hyperplane*. Untuk memprediksi kelas dari data baru yang dimasukkan, dengan menggunakan persamaan sebagai berikut:

$$f(x) = \left(\sum_{i,j=1}^n \alpha_i y_i x_i x_j \right) + b \quad (2.10)$$

di mana x_i adalah *support vector*, dan x_j sebagai vektor data baru yang akan diprediksi.

Untuk kasus kedua kelas yang tidak dapat dipisahkan secara sempurna, SVM menawarkan *kernel trick* untuk memisahkan data non-linier dengan mentransformasikan data ke ruang fitur berdimensi lebih tinggi (Kaur, 2024). Namun, dalam penelitian tersebut, menerapkan *kernel linear* yang pengukuran

produk titik dari vektor data diruang aslinya, tanpa melakukan transformasi (Rabbani, 2023). Umumnya *kernel linear* mampu tahan overfitting dan proses pelatihan lebih cepat dibandingkan kernel non *linear* (Abaye, 2020). Persamaan kernel linear dapat didefinisikan sebagai:

$$k(x_i \cdot x_j) = x_i \cdot x_j \quad (2.11)$$

Selain menerapkan *kernel trick*, SVM juga mampu menyelesaikan kasus tersebut dengan menerapkan *soft margin* dengan menambahkan variabel *slack* $\xi > 0$ yang berfungsi sebagai pengukur kesalahan dalam klasifikasi. Variabel ini dimasukkan ke dalam persamaan *Quadratic Programming*:

$$\min \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i \quad (2.12)$$

dengan syarat:

$$y_i(w \cdot x_i + b) \geq 1 - \xi_i, \quad i = 1, 2, 3, \dots, n \quad (2.13)$$

Masalah optimasi dengan *lagrange multiplier* pada persamaan (2.6) dimodifikasi menjadi persamaan berikut:

$$L_p(w, b, \alpha) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i + \sum_{i=1}^n \alpha_i [y_i(w \cdot x_i + b) - 1 + \xi_i] - \sum_{i=1}^n \mu_i \xi_i \quad (2.14)$$

Persamaan dari maksimum dualitas *lagrange multiplier* dilakukan dengan memodifikasi menjadi:

$$\max_{\alpha} L_p = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) \quad (2.15)$$

dengan syarat: $0 \leq \alpha_i \leq C; \quad i = 1, 2, 3, \dots, n; \quad \sum_{i=1}^n \alpha_i y_i = 0$.

Parameter C yang digunakan untuk mengatur kesalahan klasifikasi yang diperbolehkan pada data latih. Nilai yang besar akan memperketat dan mengurangi

toleransi kesalahan dengan memperkecil margin, namun berisiko *overfitting*. Sebaliknya, nilai yang kecil akan memberikan toleransi kesalahan dengan melebarkan margin, namun berisiko *underfitting* (Aryawan, 2023).

Pada solusi kedua, perancangan sistem irigasi menggunakan *Support Vector Machine* (SVM), *kernel* yang digunakan adalah *linear*. Dataset ini dibagi menjadi 80% data latih dan 20% data uji, menghasilkan akurasi sebesar 99,3% (Kaur, 2024).

2.1.3 Random Forest


Solusi ketiga menggunakan *Random Forest* (RF) adalah metode ensemble learning yang populer untuk klasifikasi maupun regresi. Metode ini bekerja dengan menggabungkan sejumlah *Decision Tree* yang terpisah, di mana setiap pohon menggunakan subset data yang dipilih secara acak melalui teknik bagging dan *random feature selection* (Abaye, 2020). *Random Forest* dikembangkan dari *Classification* dan *Regression Tree* (CART), yang merupakan teknik klasifikasi yang menganalisis data menggunakan *Decision Tree* (Lestari, 2024).

Setiap *Decision Tree* terdiri dari beberapa jenis simpul, yaitu simpul akar yang terletak di puncak dalam pohon. Simpul internal sebagai simpul percabangan yang memiliki satu *input* dan dua *output*, dan simpul daun. Simpul terakhir yang dikenal sebagai simpul daun yang hanya memiliki satu masukan tanpa menghasilkan keluaran tambahan (Rakhmat, 2023).

Random Forest memiliki kemampuan generalisasi yang tinggi dengan membangun pohon yang beragam, sehingga mengurangi *overfitting*. Metode ini mampu memproses data dengan jumlah sampel dan dimensi yang besar, serta fitur kategoris. Keunggulan metode ini tahan terhadap data dengan *outlier*, *noise*, dan

ketidakseimbangan (Abaye, 2020). Tidak hanya itu, *Random Forest* mampu menangani missing data (Zhu, 2020).

Kelemahan dari *Random Forest* terletak pada kebutuhan komputasi dan waktu pemrosesan yang dapat meningkat seiring bertambahnya jumlah dan kedalaman pohon, terutama dataset yang besar. Metode ini juga memerlukan spesifikasi prosesor tinggi untuk pemrosesan paralel. Oleh karena itu, pengaturan *hyperparameter* untuk membatasi jumlah dan kedalaman maksimum pohon yang dibangun sangat penting untuk mengurangi kebutuhan komputasi (Zhu, 2020).



Gambar 2.3 Random Forest

Berdasarkan Gambar 2.3, *Random Forest* membangun sejumlah *Decision Tree* yang secara terpisah melalui teknik *bagging* (*bootstrap aggregating*), di mana sampel acak dari data pelatihan yang dipilih dengan penggantian (*replacement*). Setiap pohon dibangun tanpa pemangkasan dan menggunakan *random feature selection*. Proses ini diulangi hingga jumlah pohon yang ditentukan (Lestari, 2024).

Random feature selection dilakukan untuk memilih sejumlah fitur secara acak yang digunakan pada setiap simpul saat membangun pohon. Dalam pengaturan ini, nilai yang lebih rendah dapat meningkatkan variasi dan mengurangi korelasi antar pohon, yang dapat memperkuat stabilitas saat penggabungan pohon (Yulianto,

2024). Untuk klasifikasi, nilai ini sering diatur dengan $\sqrt{p}$, di mana p adalah jumlah fitur dalam dataset (Junus, 2023).

Proses pembentukan *Decision Tree* dalam *Random Forest* dimulai dengan menentukan simpul akar. Selanjutnya, dilakukan pemisahan pada simpul untuk menentukan simpul terminal dan simpul daun berdasarkan kriteria terbaik dengan menghitung menggunakan *Gini Index* (Yulianti, 2023). Perhitungan *Gini Index* dan *Gini Split* dilakukan menggunakan persamaan (2.16) dan (2.17).

$$Gini\ Index\ (D) = 1 - \sum_{i=1}^n P_i^2 \quad (2.16)$$

di mana P_i adalah probabilitas dari kelas ke- i dalam simpul D , dan n adalah jumlah total kelas.

$$Gini_{split}\ (D) = \frac{N_1}{N} Gini\ Index(D_1) + \frac{N_2}{N} Gini\ Index(D_2) \quad (2.17)$$

di mana N_1 dan N_2 adalah jumlah sampel dalam subset setelah pemisahan, D_1 dan D_2 adalah simpul hasil pemisahan, serta N adalah jumlah total sampel pada simpul.

Pada solusi ketiga, perancangan sistem irigasi menggunakan *Random Forest* (RF), dengan membangun jumlah 100 pohon dan kriteria *Gini Index*. Dataset tersebut akan dibagi menjadi 80% untuk data latih dan 20% untuk data uji. *Random Forest* menghasilkan akurasi sebesar 99,98%, *precision* 99,96%, *recall* 99,99%, dan *f1-score* 99,97% (IORLIAM, 2022).

2.2 Analisis Pemilihan Solusi

Tabel 2.2 Analisis Pemilihan Solusi

Solusi	Karakteristik Pendekatan Berdasarkan Aspek Analisis	Solusi Terpilih
--------	--	--------------------


Pendekatan-1 Preprocessing: - <i>train_test_split</i> (80 : 20) - <i>StandarScaler</i> Classifier: <i>K-Nearest Neighbors</i> (<i>k</i>: 5, <i>metric</i>: <i>manhattan</i>)	Aspek Ekonomis Selama proses pelatihan KNN, kebutuhan komputasi bisa meningkat seiring bertambahnya ukuran dataset (Abaye, 2020). Aspek Manufakturabilitas Waktu pemrosesan untuk melatih KNN menjadi lama seiring bertambahnya ukuran dataset (Abaye, 2020). Aspek Sustainabilitas Kemampuan pada KNN menghasilkan akurasi mencapai 99,3% (Kaur, 2024).	-
Pendekatan-2 Preprocessing: - <i>train_test_split</i> (80 : 20) - <i>StandarScaler</i> Classifier: <i>Support Vector Machine</i> (<i>kernel</i>: <i>linear</i>)	Aspek Ekonomis Pemilihan <i>kernel</i> dan ukuran dataset seperti jumlah sampel yang besar dapat meningkatkan kebutuhan komputasi selama proses pelatihan (Abaye, 2020). Namun, SVM ramah dalam pengguna memori dengan hanya membangun batas keputusan menggunakan subset data pelatihan yang disebut support vector (Palaniappan, 2024). Aspek Manufakturabilitas Pemilihan kernel dan parameter <i>C</i> sangat memengaruhi proses pelatihan SVM. Umumnya, <i>kernel linear</i> jauh lebih cepat dibandingkan <i>non-linear</i>. Sementara itu, ukuran dataset yang sangat besar membuat proses pelatihan menjadi sangat lambat (Abaye, 2020). Aspek Sustainabilitas	-

	Kemampuan pada SVM menghasilkan akurasi sebesar 99,3% (Kaur, 2024).	
Pendekatan-3 Preprocessing: <i>train_test_split</i> (80 : 20) Classifier: <i>Random Forest</i> (<i>n_estimators</i>: 100 , <i>criterion</i>: 'gini', <i>max_features</i>: 'sqrt', <i>bootstrap</i>: True, <i>n_job</i>: -1)	Aspek Ekonomis Selama melatih RF cenderung membutuhkan biaya komputasi tinggi dikarenakan jumlah dataset yang besar serta jumlah pohon dan kedalaman pohon yang terlalu dalam bahkan penerapan pemrosesan paralel untuk mempercepat waktu latih (Zhu, 2020). Aspek Manufakturabilitas Selain ukuran dataset, <i>hyperparameter</i> seperti jumlah pohon dan kedalaman pohon dapat memengaruhi waktu pelatihan. Untuk mempercepat proses tersebut dapat dilakukan dengan menerapkan pemrosesan paralel dan mengatur <i>hyperparameter</i> dengan membatasi jumlah pohon dan kedalaman pohon yang dibangun (Zhu, 2020). Aspek Sustainabilitas Kemampuan pada RF menghasilkan akurasi mencapai 99,98% (IORLIAM, 2022).	✓

BAB III

METODOLOGI

Pada bagian ini, metodologi penelitian memiliki peran penting dalam memulai suatu penelitian dan pengembangan produk. Metodologi ini memberikan kerangka sistematis yang mencakup setiap tahapan yang harus dilalui, sehingga mendapatkan solusi dan tujuan yang diharapkan. Gambar 3.1 mengilustrasikan proses penelitian dan pengembangan produk yang dilakukan.



Gambar 3.1 Alur Metodologi Penelitian

3.1 Identifikasi Masalah

Identifikasi masalah adalah memainkan peran krusial sebelum merancang sebuah sistem. Tahapan ini dilakukan dengan mengeksplorasi berbagai masalah dari sumber seperti jurnal penelitian dan berita. Di samping itu, masalah juga didapatkan dari pengalaman pribadi dalam menghadapi tantangan dalam menyiram tanaman.

Untuk menemukan dan memverifikasi masalah tersebut dilakukan wawancara dengan berbagai narasumber yang ahli dalam pertanian.

Dari hasil masalah yang didapatkan, petani mengalami kesulitan menyiram tanaman karena metode pengelola tanaman dilakukan secara tradisional dan memiliki berbagai keterbatasan waktu, tenaga, biaya produksi, sumber daya alam maupun manusia. Metode ini menjadi masalah serius yang mengakibatkan kegagalan panen dan mengurangi produktivitas pertanian, sehingga petani mengalami kerugian dan dapat mengancam keberlangsungan usaha.

3.2 Analisis Solusi

Analisis solusi pada Bab 2 yang akan dievaluasi lebih lanjut dengan membandingkan akurasi, ketangguhan terhadap kualitas data yang beragam, biaya implementasi terkait kebutuhan komputasi. Hal ini dilakukan untuk menentukan metode mana yang terbaik, berdasarkan kemampuan mempelajari pola, memprediksi hasil yang akurat. Kebutuhan komputasi juga dilihat, namun bersifat opsional dan harus melihat spesifikasi mikrokontroler terlebih dahulu.

Hasil akhir yang ditentukan *Random Forest* dipilih karena menghasilkan akurasi terbaik sebesar 99,98 (IORLIAM, 2022). Sedangkan *K-Nearest Neighbors* dan *Support Vector Machine* menghasilkan akurasi sebesar 99,3% (Kaur, 2024). Hal ini membuktikan metode ini lebih unggul pada kemampuan generalisasi dan prediksi waktu dan kebutuhan air pada tanaman untuk menyiram tanaman otomatis.

Selain itu, RF memiliki ketangguhan dalam mengelola dataset dengan jumlah sampel yang lebih besar. Berbeda dengan SVM mampu menangani dimensi yang tinggi, namun tidak cocok pada jumlah sampel yang besar (Abaye, 2020). KNN

kebalikan dengan SVM, yang dapat menangani jumlah sampel yang besar dan tidak cocok dengan dimensi data yang tinggi (Rahmadini, 2023).

Meskipun RF dan SVM sama unggul dalam menangani outlier, noise, dan ketidakseimbangan pada data. Namun RF mampu menangani *missing* data (Zhu, 2020). Sedangkan SVM tidak cocok pada *missing* data (Putri, 2023). Sementara KNN sangat sensitif terhadap outlier, noise, dan missing data (Rahmadini, 2023).

3.3 Pengumpulan Data

Pengumpulan data memiliki peran penting dalam membangun machine learning untuk mempelajari pola data sebelum melakukan prediksi dan pengambilan keputusan. Dataset ini diambil dari penelitian yang dilakukan (Kaur, 2024) yang tersedia di *Mendeley* Data dan dapat diakses <https://data.mendeley.com/datasets/fpdwmm7nrb/1>. Dataset ini berisi 3000 sampel yang berisi kelembaban tanah, temperatur, dan kelembaban udara digunakan sebagai fitur data. Sedangkan target klasifikasi yaitu kondisi pompa, di mana nilai 0 dengan status pompa mati dan nilai 1 dengan status pompa hidup. Tabel 3.1 menjelaskan karakteristik dan atribut pada data irigasi tanaman.

Tabel 3.3 Penjelasan Atribut pada Data Irigasi

Atribut	Tipe Data	Keterangan
<i>Soil Moisture</i>	<i>float64</i>	Data kelembaban tanah yang bernilai 314,511 – 984,828.
<i>Temperature</i>	<i>float64</i>	Data suhu udara yang bernilai 28,443 – 38,992.
<i>Air Humidity</i>	<i>float64</i>	Data kelembaban udara yang bernilai 59,367 – 81,267.

<i>Pump Data</i>	<i>int64</i>	Label klasifikasi kondisi pompa dengan status 0 dan 1.
------------------	--------------	--

3.4 Preprocessing Data

Preprocessing data adalah langkah penting dalam mengelola data sebelum melatih metode *machine learning*. Tahapan ini dimulai dengan mencari *missing* data dan mengisi nilai hilang dengan nilai median. Ada tiga jenis missing data, yaitu hilang sepenuhnya secara acak (*missing completely at random*), hilang secara acak (*missing at random*), dan hilang tidak secara acak (*missing not at random*).

Selanjutnya, memilih fitur X dan y, yang kemudian dipisahkan menjadi 80% untuk *training* dan 20% *testing* data. Untuk *training* data dilakukan pencarian nilai *outlier* menggunakan *matplotlib*, sedangkan mengecek keseimbangan data menggunakan *plot*. Perbaiki data yang tidak seimbang dan *outlier* dengan menggunakan teknik *SMOTE* (*Synthetic Minority Over-sampling Technique*).

Dalam mengevaluasi kemampuan model untuk memprediksi status pompa berdasarkan kondisi yang sudah dikategorikan. Tabel 3.4 menyajikan nilai sensor dan kondisi kelembaban, yang dijelaskan oleh (Rosyid, 2022).

Tabel 3.4 Kategori pada Kelembaban Tanah

Nilai ADC	Kondisi
≥ 289	Sangat Basah
290 – 398	Basah
399 – 508	Normal
509 – 618	Kering

≥ 727	Sangat Kering
------------	---------------

Tabel 3.5 menyajikan nilai sensor dan kondisi suhu udara, yang dijelaskan oleh (Pradana, 2023).

Tabel 3.5 Kategori pada Suhu Udara

Nilai ADC	Kondisi
$\leq 23^{\circ}\text{C}$	Dingin
$24^{\circ}\text{C} - 30^{\circ}\text{C}$	Normal
$\geq 31^{\circ}\text{C}$	Panas

Tabel 3.6 menyajikan nilai sensor dan kondisi kelembaban udara, yang dijelaskan oleh (Kusnadi, 2023).

Tabel 3.6 Kategori pada Kelembaban Udara

Nilai ADC	Kondisi
$\leq 55\%$	Kering
$\geq 56\%$	Lembab

Terakhir, untuk kelas klasifikasi disesuaikan dengan kategori kelembaban tanah, suhu udara, dan kelembaban udara yang dijelaskan dalam tabel. Namun kelembaban tanah adalah unsur yang memengaruhi terhadap pertumbuhan tanaman. Oleh karena itu, status kelas 1 sebagai *OFF* dan 0 sebagai *ON*.

3.5 Perancangan *Random Forest*

Perancangan Random Forest menggunakan bahasa pemrograman *Python* dan *library sklearn* untuk memudahkan dalam pengembangan model. Implementasi

RandomForestClassifier dengan *hyperparameter tuning* seperti $n_estimators = 100$, $criterion = 'gini'$, $max_features = 'sqrt'$, $bootstrap = True$, dan $n_jobs = -1$.

Secara umum, *Random Forest* membangun *Decision Tree* tanpa pemangkasan atau dibatasi. Namun, peningkatan pohon dapat meningkatkan kebutuhan komputasi. Untuk menghemat kebutuhan komputasi dapat dilakukan dengan *hyperparameter tuning* seperti max_depth (Akbar, 2023). Dalam proyek ini, *hyperparameter max_depth* ditentukan dalam rentang nilai 3 hingga 7.

Berdasarkan penelitian yang dilakukan oleh (Oktafiani, 2024), *Random Forest* dengan $max_depth = 3$ mencapai akurasi 86,34%, $max_depth = 4$ mencapai akurasi 86,34%, nilai 5 mencapai akurasi 91,70%, $max_depth = 6$ mencapai akurasi 97,07%, dan $max_depth = 7$ mencapai akurasi 98,53%.

Penelitian yang dilakukan oleh (Baig, 2022) menunjukkan *hyperparameter* diatur dengan $max_depth = 3$ menghasilkan akurasi 97,96%, presisi 98,18%, *recall* 86,66%, *AUC* 0,932, dan waktu pelatihan 0,22 detik. $Max_depth = 4$ yang diatur menghasilkan akurasi 97,82%, presisi 99,79%, *recall* 84,21%, *AUC* 0,971, dan waktu pelatihan 0,259 detik. $Max_depth = 5$ yang diatur menghasilkan akurasi 99,14%, dengan presisi 99,30%, *recall* 94,36%, *AUC* 0,971, dan waktu pelatihan 0,38 detik. $Max_depth = 6$ yang diatur menghasilkan akurasi 99,47%, presisi 99,60%, *recall* 96,53%, *AUC* 0,982, dan waktu pelatihan 0,44 detik.

3.6 Pengujian

Pengujian dilakukan untuk memvalidasi kemampuan metode ini dalam menganalisis pola dan melakukan prediksi yang akurat sebelum mengintegrasikan

ke mikrokontroler ESP32. Parameter dalam pengujian menggunakan pengukuran metrik seperti *confusion matrix*, akurasi, presisi, *recall*, *f1-score*, dan *AUC score*.

Confusion matrix adalah sebuah alat yang menyajikan informasi komparatif mengenai hasil klasifikasi yang dilakukan oleh sistem dengan membandingkan hasil klasifikasi yang sebenarnya dan model yang digunakan.

		Actual Values	
		Positive (1)	Negative (0)
Predicted Values	Positive (1)	TP	FP
	Negative (0)	FN	TN

Gambar 3.2 Confusion Matrix

TP (True Positive) mencerminkan jumlah prediksi yang benar untuk data positif, sedangkan *TN (True Negative)* mencerminkan jumlah prediksi yang benar untuk data negatif. Di sisi lain, *FP (False Positif)* menunjukkan jumlah prediksi yang salah untuk data positif, sementara *FN (False Negative)* menggambarkan jumlah prediksi yang salah untuk data negatif. Kedua kondisi ini menunjukkan adanya kesalahan dalam memprediksi pola data.

Akurasi adalah ukuran yang menunjukkan seberapa kemampuan prediksi yang benar secara keseluruhan. Akurasi dapat dihitung dengan persamaan (3.1).

$$Accuracy = \frac{T_p + T_n}{T_p + T_n + F_p + F_n} \quad (3.1)$$

Presisi untuk mengukur seberapa kemampuan model dalam memprediksi kelas positif dengan benar dari keseluruhan kelas positif. Presisi dapat hitung dengan persamaan (3.2).

$$Precision = \frac{T_p}{T_p + F_p} \quad (3.2)$$

Recall untuk mengukur sejauh mana kemampuan model dalam prediksi yang benar untuk kelas positif dari data positif secara keseluruhan. *Recall* dapat dihitung dengan persamaan (3.3).

$$Recall = \frac{T_p}{T_p + F_n} \quad (3.3)$$

F1-score adalah alat ukur yang menggambarkan keseimbangan antara presisi dan recall. Nilai *f1-score* yang terbaik adalah 1 dan terendah adalah 0. *f1-score* dapat dihitung melalui persamaan (3.4).

$$F1 - score = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (3.4)$$

AUC (Area Under Curve) score untuk mengevaluasi sejauh mana model mampu membedakan kelas positif dan negatif dengan benar. AUC ditemukan dari kurva *ROC (Receiver Operating Characteristic)*. Terdapat berbagai indikator nilai *AUC*, yaitu sangat baik (0.9 - 1), baik (0.8 - 9), cukup (0.7 – 0.8), buruk (0.6 – 0.7) dan tidak memadai (0.6 – 0.7).

3.7 Implementasi Model *Random Forest*

Pada proyek ini, implementasi *Random Forest* ke dalam mikrokontroler ESP32 dilakukan untuk menciptakan sebuah sistem irigasi cerdas. Proses ini dimulai mengonversi bahasa *Python* ke C++ dengan menggunakan *library* sumber terbuka *micromlgen*. Dalam implementasi tersebut, parameter *max_depth* dari

masing-masing nilai akan dipilih berdasarkan hasil evaluasi kinerja yang terbaik dan pengguna memori untuk mempertahankan akurat dalam memprediksi dan efisiensi kebutuhan komputasi.

3.8 Hasil

Hasil yang diharapkan dalam merancang sistem penyiraman otomatisasi atau irigasi cerdas dengan menerapkan *Random Forest* yang mampu memprediksi waktu dan kebutuhan air tanaman yang tepat, untuk memulai penyiraman. Sistem ini tidak hanya penyiraman otomatis melainkan pemantauan yang *real-time* dan dilihat secara jarak jauh, yang dapat mengurangi ketergantungan manusia. Dengan demikian, sistem ini dapat membantu meringankan pekerjaan, menjaga dan meningkatkan kualitas dan jumlah hasil pertanian, yang dapat mendukung berkelanjutan usaha petani.

BAB IV

PERANCANGAN

4.1 Spesifikasi Solusi

Pada bagian ini menjelaskan beberapa spesifikasi solusi dari sistem otomatisasi penyiraman atau irigasi cerdas yang harus memenuhi fungsi, kinerja, dan karakteristik sesuai standar:

1. Perangkat Keras :

- Beberapa modul atau komponen dalam mikrokontroler seperti model *machine learning*, *wifi*, *bluetooth*, dan lainnya dapat beroperasi.
- Sensor kelembaban tanah, suhu, dan kelembaban udara mampu membaca dan mengirim ke mikrokontroler secara *real-time*.
- Sistem mampu melakukan prediksi kebutuhan air pada tanaman dengan waktu yang tepat dan menyiram tanaman secara otomatis.
- Sistem ini mengirimkan data sensor ke server untuk disimpan ke dalam database melalui koneksi internet.
- Sistem ini menjalankan perintah dari pengguna dari *server* dan internet, bahkan koneksi *bluetooth* untuk mengonfigurasi perangkat.

2. Aplikasi Mobile :

- Aplikasi dapat dijalankan smartphone yang sistem operasi *Android*.
- Beberapa modul atau komponen pada aplikasi dapat dipastikan berjalan dengan lancar tanpa gangguan.

- Aplikasi dapat menghubungkan perangkat keras dengan koneksi *bluetooth*.
- Aplikasi dapat menampilkan antarmuka yang berisi informasi tanaman, perangkat, dan pengaturan penyiraman atau irigasi.
- Aplikasi dapat mengelola dan konfigurasi perangkat melalui internet dan *bluetooth* (khusus mengganti nama dan mengatur koneksi *wifi*).

4.2 Rencana Pengujian

Setelah pengembangan sistem selesai, langkah berikutnya adalah pengujian sistem. Pengujian ini sangat penting dilakukan sebelum sistem atau produk digunakan oleh petani. Tahapan ini bertujuan untuk menemukan kesalahan, mengevaluasi kinerja dan kualitas pada sistem atau produk. Dengan pengujian tersebut, dapat memastikan sistem atau produk berfungsi dengan baik dan memenuhi spesifikasi serta standar kebutuhan yang ditetapkan.

Pengujian pertama, *Random Forest* dilakukan untuk mengevaluasi kinerja sebelum diimplementasikan ke mikrokontroler ESP32, sebagaimana dijelaskan pada bagian 3.5 sampai 3.7, pengujian ini menentukan nilai *max_depth* yang optimal yang dapat menghemat biaya komputasi. Untuk proses pengujian dilakukan dengan mencoba nilai *max_depth* mulai dari 3 hingga 7. Pada setiap nilai tersebut, berbagai metrik devaluasi dan memilih nilai dari hasil dengan performa terbaik.

Pengujian kedua, sensor-sensor akan diuji dari membaca data, keakuratan dan ketahanan kondisi lingkungan. Berbagai modul atau komponen seperti *wifi*, *bluetooth*, model *Random Forest* pada mikrokontroler ESP32 diuji untuk memastikan sistem dapat beroperasi dengan baik. Selain itu, pengujian *Random*

Forest dilakukan untuk memastikan sistem dapat memprediksi waktu dan kebutuhan air pada tanaman yang tepat.


Pengujian ketiga, aplikasi mobile dimulai dengan memeriksa modul atau komponen dalam aplikasi, kompatibilitas di berbagai perangkat, dan integrasi paket *library*. Tidak hanya itu, pengujian ini juga melibatkan proses autentikasi akun seperti proses login dan register. Terakhir, operasi CRUD (Create, Read, Update, Delete) juga dilakukan. Proses ini dilakukan agar aplikasi ini memenuhi karakteristik, fungsi, dan kinerja yang sesuai dengan standar.

4.3 Perancangan Sistem

4.3.1 Perancangan Aplikasi Mobile

Aplikasi mobile memainkan peran krusial sebagai antarmuka bagi pengguna dalam memantau dan mengelola irigasi tanaman, serta memungkinkan pengguna mengonfigurasi perangkat dengan mudah. Desain aplikasi ini memanfaatkan *framework Dart*, yaitu *Flutter*, yang memungkinkan pengembangan aplikasi *multiplatform* dengan satu baris kode. *Flutter* memiliki kinerja yang tinggi, responsivitas yang baik, dan menariknya antarmuka, serta mempermudah dan mempercepat proses pengembangan aplikasi.


Aplikasi ini dirancang khusus untuk platform *Android*, mengingat tingginya jumlah petani yang memanfaatkan smartphone. Selain itu, aplikasi ini akan dilengkapi dengan pustaka *Bluetooth Low Energy (BLE)*, yang memungkinkan koneksi langsung dengan *ESP32* untuk melakukan konfigurasi perangkat.



Gambar 4.1 Rancangan Aplikasi Mobile

4.3.2 Perancangan Model Random Forest

Sesuai dengan penjelasan sebelumnya, metode *machine learning* merupakan bagian dari teknologi kecerdasan buatan yang memungkinkan mesin untuk mempelajari pola-pola data, kemudian melakukan prediksi dan pengambilan keputusan secara otomatis berdasarkan pola-pola data yang sudah dipelajari. Dalam bidang pertanian penerapan *machine learning* pada sistem penyiraman atau irigasi tanaman merupakan solusi yang bermanfaat, untuk mengurangi waktu, tenaga, dan sumber daya manusia, serta meningkatkan efisiensi penggunaan air dan penghematan biaya, yang dapat meningkatkan produktivitas dan berkelanjutan.



Gambar 4.2 Rancangan Random Forest

Berdasarkan Gambar 4.2, perancangan model ini diawali dengan pengambilan dataset terkait irigasi. Langkah berikutnya adalah melakukan *preprocessing* data, termasuk pembagian data dan terakhir penerapan *SMOTE*. Proses *preprocessing* ini telah dijelaskan pada bagian 3.4. Setelah proses *preprocessing* selesai, model *Random Forest* dibangun dengan *hyperparameter* yang telah ditentukan pada penjelasan bagian 3.5.


4.3.3 Perancangan Sistem Perangkat Keras

Perancangan sistem perangkat keras diawali dengan membangun komponen perangkat keras utama, yaitu:

1. Mikrokontroler ESP32

ESP32 adalah modul mikrokontroler yang memiliki koneksi *WiFi* dan *Bluetooth* yang terintegrasi. Mikrokontroler ini memiliki CPU ditenagai *Xtensa LX16 dual core*. Memori yang digunakan adalah 448 KB ROM, 520 KB SRAM,

dua memori RTC 8KB, dan memori *flash* 4MB. ESP32 memiliki kelebihan yaitu harga yang terjangkau, mempermudah dalam pengembangan, jumlah pin GPIO (*General Purpose Input/Output*) yang memadai. Selain itu, mikrokontroler ini efisiensi daya dan menghasilkan kesalahan yang rendah (Widyatmika, 2021). Gambar 4.3 ini menampilkan penampakan mikrokontroler ESP32.



Gambar 4.3 Mikrokontroler ESP32

2. *Capactive Soil Moisture Sensor*


Sensor kelembaban tanah adalah alat untuk mengukur kadar air dalam tanah. Alat ini memiliki dua *probe* yang mengalirkan arus listrik melalui tanah dan mengukur resistansi untuk menentukan kelembaban. Tanah yang basah memiliki resistansi rendah, sedangkan tanah kering memiliki resistansi tinggi, yang menghambat pengantaran listrik (Darmawan, 2020). Dalam perancangan sistem tersebut, berfokus menggunakan sensor tanah yang kapasitif tipe V2.0. Gambar 4.4 ini menampilkan penampakan sensor tanah yang dipakai.



Gambar 4.4 Sensor Capacitive Soil Moisture Sensor

3. DHT22 Sensor

DHT22 adalah alat sensor untuk mengukur suhu dan kelembaban udara. Sensor ini bekerja dengan memanfaatkan kombinasi dari kapasitor dan termistor untuk mendeteksi kondisi udara, kemudian menghasilkan data melalui pin. DHT22 memiliki tingkat akurasi yang tinggi, kalibrasi otomatis, respons yang cepat dalam proses akuisisi data, serta harga yang terjangkau (Puspasari, 2020). Gambar 4.5 ini menampilkan penampakan sensor DHT22 yang dipakai.



Gambar 4.5 Sensor DHT22

4. *Relay Switch*


Relay adalah alat yang berfungsi untuk menggerakkan kontraktor atau sakelar dengan memindahkan posisi hidup dan mati secara otomatis. Proses terbuka dan

tertutup pada relay terjadi karena adanya efek induksi magnet yang muncul dari kumparan induksi listrik (Omega, 2023). Hal ini dapat disimpulkan mikrokontroler memberikan instruksi pada *relay* dengan reaksi untuk menghidupkan dan mematikan pompa air. Gambar 4.3 ini menampilkan penampakan *relay switch* yang dipakai untuk mengontrol pompa air irigasi.




Gambar 4.6 Relay

Setelah pembangunan perangkat keras selesai, selanjutnya membangun sistem mikrokontroler dengan memasukkan *Random Forest*. Implementasi *Random Forest* dilakukan sesuai dari penjelasan sebelumnya pada bagian 3.5 sampai 3.7. Skema perancangan sistem perangkat keras dapat dilihat pada Gambar 4.7.



Gambar 4.7 Rancangan Sistem Mikrokontroler ESP32



Gambar 4.8 Cara Kerja Sistem Irigasi Cerdas

Pada Gambar 4.8 menunjukkan cara kerja sistem irigasi cerdas pada perangkat keras. Sensor kelembaban tanah, suhu, dan kelembaban udara akan membaca data lingkungan, yang kemudian dikirim ke mikrokontroler untuk diproses menggunakan model *Random Forest* guna memprediksi kebutuhan air pada tanaman. Dalam dataset, kelembaban tanah memiliki pengaruh yang dominan terhadap pertumbuhan tanaman. Sementara itu, suhu udara dan kelembaban udara berperan sebagai faktor pendukung. Ini menunjukkan *Random Forest* lebih cenderung memberikan penilaian berdasarkan kelembaban tanah sebagai faktor utama dalam pengambilan keputusan. Model ini akan memberikan hasil keputusan dan melakukan penyiraman secara otomatis berdasarkan data yang sudah dilatih.

Untuk meningkatkan efisiensi pengguna air, sistem ini juga menggunakan sensor hujan untuk mencegah penyiraman saat terjadinya hujan.

4.4 Proses Verifikasi Perancangan

Tabel 4.1 menyajikan daftar item yang digunakan untuk memverifikasi dalam merancang sistem otomatisasi penyiraman atau irigasi cerdas tanaman.

Tabel 4.1 Penjelasan Atribut Verifikasi Perancangan

No.	Item	Verifikasi	Keterangan
1	<i>RandomForestClassifier</i>	✓	<i>Random Forest</i> adalah model <i>ensemble learning</i> dengan membangun sejumlah <i>Decision Tree</i> yang berbeda melalui teknik <i>bagging</i> dan <i>random feature selection</i> .
2	<i>n_estimators</i>	✓	Menentukan jumlah <i>Decision Tree</i> yang dibangun untuk menghasilkan prediksi akhir. Jumlah pohon yang banyak dapat meningkatkan akurat prediksi, meskipun memerlukan kebutuhan komputasi yang tinggi.
3	<i>criterion</i>	✓	<i>Hyperparameter</i> untuk menentukan kriteria terbaik untuk memisahkan setiap simpul dalam <i>Decision Tree</i> , yaitu pada <i>terminal node</i> dan <i>leaf node</i> , untuk meminimalkan ketidakmurnian data. Pemilihan kriteria ini bertujuan memastikan ketepatan pemisahan data dalam model prediksi.

4	<i>max_features</i>	✓	Menentukan jumlah fitur acak yang dipilih pada setiap simpul dapat meningkatkan variasi dan mengurangi korelasi antar pohon, sehingga model lebih stabil dan generalisasi lebih baik.
5	<i>bootstrap</i>	✓	Mengatur agar <i>Random Forest</i> menggunakan teknik <i>bagging</i> (pengambilan sampel secara acak dengan penggantian), yang meningkatkan variasi setiap <i>Decision Tree</i> .
6	<i>max_depth</i>	✓	Mengatur <i>max_depth</i> untuk membatasi kedalaman pohon sehingga mengurangi kebutuhan komputasi, seperti memori dan waktu pemrosesan, sekaligus mencegah <i>overfitting</i> .
7	<i>n_jobs</i>	✓	<i>Hyperparameter</i> yang memanfaatkan seluruh CPU untuk mempercepat proses pelatihan <i>Random Forest</i> meskipun bersifat opsional.

DAFTAR PUSTAKA

- Abaye, D. A., Boateng, E. Y., & Otoo, J. (2020). Basic Tenets of Classification Algorithms K-Nearest-Neighbor, Support Vector Machine, Random Forest and Neural Network: A Review. *Journal of Data Analysis and Information Processing*, 08(04), 341–357. <https://doi.org/10.4236/jdaip.2020.84020>
- Abo-Zahhad, M. (2023). IoT-Based Automated Management Irrigation System Using Soil Moisture Data and Weather Forecasting Adopting Machine Learning Technique. *Sohag Engineering Journal*, 3(2), 122–140. <https://doi.org/10.21608/sej.2023.209528.1037>
- Akbar, H., & Sanjaya, W. K. (2023). Kajian Performa Metode Class Weight Random Forest pada Klasifikasi Imbalance Data Kelas Curah Hujan. *Jurnal Sains, Nalar, dan Aplikasi Teknologi Informasi*, 3(1). <https://doi.org/10.20885/snati.v3i1.30>
- Anggarda, M. F., Kustiawan, I., Nurjanah, D. R., & Hakim, N. F. A. (2023). Pengembangan Sistem Prediksi Waktu Penyiraman Optimal pada Perkebunan: Pendekatan Machine Learning untuk Peningkatan Produktivitas Pertanian. *JURNAL BUDIDAYA PERTANIAN*, 19(2), 124–136. <https://doi.org/10.30598/jbdp.2023.19.2.124>
- Aryawan, I. P. A., Purnama, I. N., & Fredlina, K. Q. (2023). ANALISIS PERBANDINGAN ALGORITMA CNN DAN SVM PADA KLASIFIKASI EKSPRESI WAJAH. *Jurnal Teknologi Informasi dan Komputer*, 9(4), 399–408. <https://doi.org/10.36002/jutik.v9i4.2545>
- Badan Pusat Statistik. (2023). *Hasil Pencacahan Lengkap Sensus Pertanian 2023 - Tahap I*. Badan Pusat Statistik Indonesia. <https://www.bps.go.id/id/pressrelease/2023/12/04/2050/hasil-pencacahan-lengkap-sensus-pertanian-2023---tahap-i.html>

- Baig, Z., Syed, N., & Mohammad, N. (2022). Securing the Smart City Airspace: Drone Cyber Attack Detection through Machine Learning. *Future Internet*, 14(7), 205. <https://doi.org/10.3390/fi14070205>
- Bharata, W., Sultoni Sutejo, M., Khairinnisa Syarah, N., Alissa Ariani, N., Arbita Priambodo, F., Verdiansyah, V., & Hafidz Alfidhin Hasbar, M. (2023). Budidaya Tanaman Holtikultura Sebagai Perwujudan Ketahanan Pangan Masyarakat Desa Liang Ulu. *Darmabakti: Jurnal Pengabdian dan Pemberdayaan Masyarakat*, 4(1), 64–69. <https://doi.org/10.31102/darmabakti.2023.4.1.64-69>
- Bhavani, R., & Thambi, A. (2022). MANAGING IRRIGATION NEEDS BASED ON SMART DECISIONS USING MACHINE LEARNING. *ICTACT Journal on Soft Computing*, 12(2), 2540–2544. <https://doi.org/10.21917/ijsc.2022.0363>
- Cholil, S. R., Handayani, T., Prathivi, R., & Ardianita, T. (2021). Implementasi Algoritma Klasifikasi K-Nearest Neighbor (KNN) Untuk Klasifikasi Seleksi Penerima Beasiswa. *IJCIT (Indonesian Journal on Computer and Information Technology)*, 6(2), 118–127. <https://doi.org/10.31294/ijcit.v6i2.10438>
- Darmawan, I. G. E., Yadie, E., & Subagyo, H. (2020). Rancang Bangun Alat Ukur Kelembaban Tanah Berbasis Arduino Uno. *PoliGrid*, 1(1), 31–38. <https://doi.org/10.46964/poligrid.v1i1.215>
- Fausan, A., Setiawan, B. I., Arif, C., & Saptomo, S. K. (2021). Analisa Model Evaporasi dan Evapotranspirasi Menggunakan Pemodelan Matematika pada Visual Basic di Kabupaten Maros. *Jurnal Teknik Sipil dan Lingkungan*, 5(3), 179–196. <https://doi.org/10.29244/jsil.5.3.179-196>
- IORLIAM, A., BUM, S., AONDOAKAA, I. S., IORLIAM, I. B., & SHEHU, Y. (2022). Machine Learning Techniques for the Classification of IoT-Enabled Smart Irrigation Data for Agricultural Purposes. *Gazi University Journal of Science Part A: Engineering and Innovation*, 9(4), 378–391. <https://doi.org/10.54287/gujsa.1141575>

- Junus, C. Z. V., Tarno, T., & Kartikasari, P. (2023). KLASIFIKASI MENGGUNAKAN METODE SUPPORT VECTOR MACHINE DAN RANDOM FOREST UNTUK DETEKSI AWAL RISIKO DIABETES MELITUS. *Jurnal Gaussian*, 11(3), 386–396. <https://doi.org/10.14710/j.gauss.11.3.386-396>
- Kaur, A., Bhatt, D. P., & Raja, L. (2024). Developing a Hybrid Irrigation System for Smart Agriculture Using IoT Sensors and Machine Learning in Sri Ganganagar, Rajasthan. *Journal of Sensors*, 2024, 1–15. <https://doi.org/10.1155/2024/6676907>
- Kumar, G. K., Bangare, M. L., Bangare, P. M., Kumar, C. R., Raj, R., Arias-González, J. L., Omarov, B., & Mia, Md. S. (2024). Internet of things sensors and support vector machine integrated intelligent irrigation system for agriculture industry. *Discover Sustainability*, 5(1), 1–10. <https://doi.org/10.1007/s43621-024-00179-5>
- Kynta, P., Laksono, I., Wijaya, V., & Hermanto, D. (2024). Perancangan UI/UX Website Pengontrol Kelembapan Tanah Berbasis IoT dan Sensor. *MDP Student Conference*, 3(1), 71–78. <https://doi.org/10.13140/RG.2.2.19460.33929>
- Lestari, A., Santoso, R., & Suparti, S. (2024). ANALISIS SENTIMEN PENGGUNA ONLINE TRAVEL AGENT (OTA) PADA PERUSAHAAN PEGIPEGI.COM MENGGUNAKAN RANDOM FOREST. *Jurnal Gaussian*, 12(4), 616–624. <https://doi.org/10.14710/j.gauss.12.4.616-624>
- Mujawar, R. Y., Lakshminarayanan, R., P, J. A., Prabha, S. P., Patnaik, S., & Dhayalini, K. (2023). International Journal of INTELLIGENT SYSTEMS AND APPLICATIONS IN ENGINEERING IoT-Enabled Intelligent Irrigation System with Machine Learning-Based Monitoring, for Effective Rice Cultivation. *Original Research Paper International Journal of Intelligent*

- Systems and Applications in Engineering IJISAE*, 12(11s), 557–565.
www.ijisae.org
- Ningrum, N. K., Mulyono, I. U. W., Widyatmoko, K., & Umami, Z. (2023). Monitoring Kondisi Tanaman berdasarkan Data Kelembaban Tanah dan Suhu dan Kelembaban Udara Melalui Website Thinkspeak. *Prosiding Seminar Nasional Informatika*, 1(1), 586–593.
<https://conference.upgris.ac.id/index.php/infest/article/view/3832>
- Oktafiani, R., Hermawan, A., & Avianto, D. (2024). Max Depth Impact on Heart Disease Classification: Decision Tree and Random Forest. *Jurnal RESTI (Rekayasa Sistem dan Teknologi Informasi)*, 8(1), 160–168.
<https://doi.org/10.29207/resti.v8i1.5574>
- Omega, V., Sulistyo, P. A. S., & Hartati, S. (2023). SMART GARDEN BERBASIS INTERNET OF THINGS. *JTIM*, 6(1), 36–42.
<https://journal.unmaha.ac.id/index.php/jtim/article/view/244>
- Palaniappan, R. (2024). Comparative Analysis of Support Vector Machine, Random Forest and k-Nearest Neighbor Classifiers for Predicting Remaining Usage Life of Roller Bearings. *Informatica*, 48(7), 39–52.
<https://doi.org/10.31449/inf.v48i7.5726>
- Pradana, M. R., Hannats, M., Ichsan, H., & Akbar, S. R. (2023). Klasifikasi Kesuburan dan Daya Ukur Cakupan Kelembaban Tanah pada Tanaman Jambu Merah berbasis Arduino. *Jurnal Pengembangan Teknologi Informasi Dan Ilmu Komputer*, 7(4), 1797–1809. <https://j-ptiik.ub.ac.id/index.php/j-ptiik/article/view/12592>
- Puspasari, F., Satya, T. P., Oktawati, U. Y., Fahrurrozi, I., & Prisyanti, H. (2020). Analisis Akurasi Sistem sensor DHT22 berbasis Arduino terhadap Thermohygrometer Standar. *Jurnal Fisika dan Aplikasinya*, 16(1), 40–45.
<https://doi.org/10.12962/j24604682.v16i1.5776>

- Qorni, Q. Al, Pamungkas, D. P., Wibowo, S. A., & Hermanto, D. (2023). Pemantauan dan Peningkat Kondisi Kelembaban Lahan Menggunakan Esp8266 dan IoT. *MDP Student Conference*, 2(1), 226–233. <https://doi.org/10.35957/mdp-sc.v2i1.4056>
- Rabbani, S., Safitri, D., Rahmadhani, N., Sani, A. A. F., & Anam, M. K. (2023). Perbandingan Evaluasi Kernel SVM untuk Klasifikasi Sentimen dalam Analisis Kenaikan Harga BBM. *MALCOM: Indonesian Journal of Machine Learning and Computer Science*, 3(2), 153–160. <https://doi.org/10.57152/malcom.v3i2.897>
- Rafrin, M., Agus, Muh., & Maharani, P. A. (2024). IoT-Based Irrigation System Using Machine Learning for Precision Shallot Farming. *Jurnal RESTI (Rekayasa Sistem dan Teknologi Informasi)*, 8(2), 216–222. <https://doi.org/10.29207/resti.v8i2.5579>
- Rahmadini, R., Enjel Erika LorencisLubis, Aji Priansyah, Yolanda R.W.N, & Tuti Meutia. (2023). PENERAPAN DATA MINING UNTUK MEMPREDIKSI HARGA BAHAN PANGAN DI INDONESIA MENGGUNAKAN ALGORITMA K-NEAREST NEIGHBOR. *Jurnal Mahasiswa Akuntansi Samudra*, 4(4), 223–235. <https://doi.org/10.33059/jmas.v4i4.7074>
- Rakhmat, G. A., & Mutohar, W. (2023). MIND (Multimedia Artificial Intelligent Networking Database Prakiraan Hujan menggunakan Metode Random Forest dan Cross Validation. *Journal MIND Journal | ISSN*, 8(2), 173–187. <https://doi.org/10.26760/mindjournal.v8i2.173-187>
- Rosyid, M. A., Rozaq, I. A., & Gunawan, B. (2022). KELEMBABAN TANAH DAN PENYIRAMAN OTOMATIS PADA BUDIDAYA BIBIT CABAI BERBASIS WEBSITE. *Jurnal Elektro Kontrol (ELKON)*, 2(2), 32–43. <https://doi.org/10.24176/elkon.v2i2.9128>
- S A M, Y., & Kusnadi, H. (2023). MONITORING SUHU, KELEMBABAN, DAN TEKANAN UDARA MENGGUNAKAN WIRELES nRF24L01 DIKAMPUS

- UNPAM VIKTOR. *Journal of Young Electrical Power and Electronics Implementation*, 1(1), 20–29. <https://doi.org/10.32493/yepei.v1i1.28842>
- Singh, S., & Bhardwaj, Dr. A. K. (2022). AN EFFICIENT MACHINE LEARNING INSPIRED SMART IRRIGATION SYSTEM FOR AGRICULTURE. *NeuroQuantology*, 20(13), 4366–4372. <https://doi.org/10.48047/nq.2022.20.13.NQ88531>
- Sofia, E., Hidayat, G., Risyandha, Moh. A., & Rasyid, M. M. (2023). ANALISIS KETERSEDIAAN AIR PADA LAHAN PERTANIAN DAERAH PEMATANG PANJANG, KECAMATAN SUNGAI TABUK. *Jukung (Jurnal Teknik Lingkungan)*, 9(2), 55–62. <https://doi.org/10.20527/jukung.v9i2.17572>
- Subagja, F. E., Supriyadi, A. P., Kurniadi, A. R., & Saragih, Y. (2023). PENGUJIAN SISTEM PENYIRAMAN TANAMAN OTOMATIS BERBASIS IOT. *Infotronik: Jurnal Teknologi Informasi dan Elektronika*, 8(2), 91–97. <https://doi.org/10.32897/infotronik.2023.8.2.3015>
- Sumarudin, A., Ismantohadi, E., Puspaningrum, A., Maulana, S., & Nadi, M. (2021). Implementation irrigation system using Support Vector Machine for precision agriculture based on IoT. *IOP Conference Series: Materials Science and Engineering*, 1098(3), 1–5. <https://doi.org/10.1088/1757-899X/1098/3/032098>
- Tace, Y., Tabaa, M., Elfilali, S., Leghris, C., Bensag, H., & Renault, E. (2022). Smart irrigation system based on IoT and machine learning. *Energy Reports*, 8(9), 1025–1036. <https://doi.org/10.1016/j.egy.2022.07.088>
- Widyatmika, I. P. A. W., Indrawati, N. P. A. W., Prastya, I. W. W. A., Darminta, I. K., Sangka, I. G. N., & Sapteka, A. A. N. G. (2021). Perbandingan Kinerja Arduino Uno dan ESP32 Terhadap Pengukuran Arus dan Tegangan. *Jurnal Otomasi Kontrol dan Instrumentasi*, 13(1), 35–47. <https://doi.org/10.5614/joki.2021.13.1.4>

- Yulianti, A., Fadhilah Fitri, Nonong Amalita, & Dodi Vionanda. (2023). The SMOTE Application of CART Methods for Coping Imbalanced Data in Classifying Status Work on Labor Force in the City of Padang. *UNP Journal of Statistics and Data Science*, 1(3), 172–179. <https://doi.org/10.24036/ujsds/vol1-iss3/12>
- Yulianto, C. (2024). Model Penilaian Tanah Massal Berbasis Bidang Tanah Menggunakan Algoritma Random Forest di Kota Surakarta. *Jurnal Pertanahan*, 14(1), 26–39. <https://doi.org/10.53686/jp.v14i1.204>
- Zhu, T. (2020). Analysis on the Applicability of the Random Forest. *Journal of Physics: Conference Series*, 1607(1), 1–5. <https://doi.org/10.1088/1742-6596/1607/1/012123>

LAMPIRAN

